

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی برق

پایان نامه مقطع کارشناسی ارشد مهندسی پزشکی - بیوالکتریک

طبقه بندی انواع آپنه خواب با استفاده از الگوریتم یادگیری عمیق

مینا معظمی گودرزی

استاد راهنما:

مریم محبی

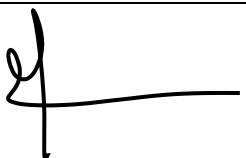
۱۴۰۱ زمستان

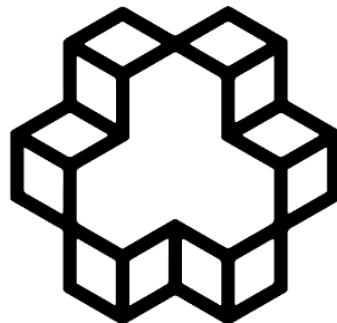
تأییدیه هیات داوران

اعضای هیئت داوران، نسخه نهائی پایاننامه / خانم : مینا معظمی گودرزی

را با عنوان : طبقه بندی انواع آپنه خواب با استفاده از الگوریتم یادگیری عمیق

از نظر شکل و محتوى بررسى نموده و پذيرش آن را برای تكميل درجه کارشناسی ارشد تأييد مى كنند.

اعضاء	رتبه علمی	نام و نام خانوادگی	اعضای هیئت داوران
	دانشیار	دکتر مریم محبی	۱- استاد راهنما
-	-	-	۲- استاد راهنما
-	-	-	۳- استاد مشاور
	استادیار	دکتر مهدی دلربایی	۴- استاد داور
	استاد	دکتر محمد پویان	۵- استاد داور
	استادیار	دکتر مهدی دلربایی	۶- نماینده تحصیلات تکمیلی



دانشگاه صنعتی خواجه نصیرالدین طوسی

اطلاع‌نامه دانشجو

اینجانب مینا معظمی گودرزی دانشجوی مقطع ارشد/دکتری رشته مهندسی پزشکی گواهی می‌نمایم که مطالب
ارائه شده در این پایان نامه/رساله با عنوان:

طبقه‌بندی انواع آپنه خواب با استفاده از الگوریتم یادگیری عمیق

با راهنمایی استاد محترم مریم محبی توسط شخص اینجانب انجام شده است. صحت و اصالت مطالب نوشته
شده در این پایان نامه/رساله تأیید می‌شود و در تدوین متن پروژه قالب مصوب دانشگاه را به طور کامل رعایت
کرده ام.



امضاء دانشجو:

۱۴۰۲/۰۱/۱۵

تاریخ:

حق طبع، نشر و مالکیت نتایج

- ۱- حق چاپ و تکثیر این پایان نامه/رساله متعلق به نویسنده و استاد راهنمای آن است. هرگونه تصویربرداری از کل یا بخشی از پروژه تنها با موافقت نویسنده یا استاد راهنما یا کتابخانه دانشکده های مهندسی برق و کامپیوتر دانشگاه صنعتی خواجه نصیرالدین طوسی مجاز است.
- ۲- کلیه حقوق معنوی این اثر متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی است و بدون اجازه کتبی دانشگاه قابل واگذاری به شخص ثالث نیست.
- ۳- استفاده از اطلاعات و نتایج موجود پروژه بدون ذکر مرجع مجاز نیست.

تقدیم به:

به پاس تعبیر عظیم و انسانی شان از کلمه ایثار و از خودگذشتگان

به پاس عاطفه سرشار و گرمای امیدبخش وجودشان که در این سردترین روزگاران بهترین پشتیبان است

به پاس قلبهای بزرگشان که فریاد رس است و سرگردانی و ترس در پناهشان به شجاعت میگراید

و به پاس محبتها بی دریغشان که هرگز فروکش نمی کند

این مجموعه را به همسر مهربانم و پدر و مادر عزیزم تقدیم میکنم.

تشکر و قدردانی

اکنون که به یاری خداوند این دوره را به پایان رسانیده ام، بر خود واجب میدانم از استاد راهنمای بزرگوارم

سرکار خانم دکتر مریم محبی به پاس زحمات بی شائبه شان در طی انجام این تحقیق سپاسگزاری نمایم.

همچنین از اساتید گرانمایه، جناب آقایان دکتر مهدی دلربایی و دکتر محمد پویان که زحمت داوری این پایان

نامه را بر عهده داشتند نهایت تشکر را دارم.

چکیده

خوابی کافی و با کیفیت یکی از موارد ضروری برای حفظ سلامت انسان می باشد و در صورت کمبود خواب، ریتم شبانه‌روزی بدن مختل شده، خطر ایجاد مشکلات سلامتی از جمله بیماری‌های قلبی عروقی، اختلالات شناختی، زوال حافظه و همینطور خطر چاقی و سکته مغزی افزایش می یابد. اختلال آپنه خواب یکی از شایع ترین اختلالات خواب در جوامع مختلف است که نیازمند شناخت و بررسی از جنبه‌های مختلف می باشد. آپنه خواب به طور کلی به سه دسته آپنه خواب انسدادی^۱ (OSA)، آپنه خواب مرکزی^۲ (CSA) و آپنه خواب مختلط^۳ (MSA) تقسیم می شود. با توجه به تفاوت در درمان انواع آپنه، تمایز سه نوع آپنه از اهمیت زیادی برخوردار است و تشخیص در مراحل اولیه، می تواند باعث افزایش کیفیت زندگی فرد و کاهش هزینه‌های درمان شود. در این پژوهش، برای اولین بار سعی شد تا روشی برای طبقه‌بندی خودکار رویدادهای آپنه انسدادی، آپنه مرکزی، آپنه مختلط و رویدادهای تنفس نرمال تنها با استفاده سیگنال الکتروکاردیوگرام توسعه داده شود. برای این منظور، از سه پایگاه داده NCHSDB، MIT-BIH و CFS استفاده شد. در ابتدا، به منظور حذف نویز، سیگنال‌های الکتروکاردیوگرام با استفاده از یک فیلتر باترورث میان گذر فیلتر شده و بر اساس میانگین صفر و انحراف استاندارد واحد استاندارد شدند. سپس این سیگنال‌ها به بخش‌های ۳۰ ثانیه تقسیم شده و ویژگی‌های مربوط به تغییر پذیری ضربان قلب و سیگنال تنفس مشتق شده از الکتروکاردیوگرام برای هر بخش محاسبه می شود. به منظور کاهش هزینه محاسباتی از روش تجزیه و تحلیل مؤلفه اصلی استفاده و پنج مؤلفه اصلی با بیشترین واریانس انتخاب شدند. در نهایت، برای طبقه‌بندی انواع آپنه از یک شبکه عصبی بازگشتی با دو ورودی مجرزا و واحد‌های حافظه طولانی کوتاه مدت استفاده شد و پنج مؤلفه انتخابی و سیگنال تنفس مشتق شده از الکتروکاردیوگرام به عنوان ورودی به شبکه عصبی داده شدند. همچنین به دلیل نامتوازن بودن تعداد داده‌های هر کلاس، از اعتبار سنجی متقابل ۱۰ برابری در مرحله آموزش شبکه استفاده شد. مدل منتخب مربوط به هر دسته، نتایج آماری مشابه و مناسبی را نشان داد. مدل پیشنهادی این پژوهش در مرحله آزمون به طور میانگین توانست به مقادیر دقت ۰,۷۲۱، ۰,۷۰۹، ۰,۶۹۹ F1، ۰,۸۹۴ AUC و ۰,۸۹۶ AUC دست پیدا کند. نتایج نهایی این مطالعه نشان می دهد که سیگنال الکتروکاردیوگرام به تنها‌ی پتانسیل لازم و کافی برای شناسایی و طبقه‌بندی انواع آپنه خواب را دارد.

کلیدواژه: آپنه انسدادی، آپنه مرکزی، یادگیری عمیق، سیگنال، الکتروکاردیوگرام، شبکه عصبی عمیق، شبکه عصبی بازگشتی

¹ obstructive sleep apnea

² central sleep apnea

³ mixed sleep apnea

فهرست مطالب

۱.....	فصل ۱ - مقدمه
۱.....	۱-۱ پیشگفتار
۵.....	۲-۱ بیان مسئله و هدف پژوهش
۵.....	۳-۱ پیکربندی پایان نامه
۷.....	فصل ۲ - مطالعات پیشین در زمینه طبقه بندی آپنه
۷.....	۲-۱ طبقه بندی دو کلاسه
۷.....	۲-۲-۱ طبقه بندی دو کلاسه آپنه خواب و نرمال
۱۰	۲-۲-۲ طبقه بندی دو کلاسه آپنه انسدادی و آپنه مرکزی
۱۱.....	۲-۲ طبقه بندی سه کلاسه
۱۱.....	۲-۲-۱ طبقه بندی سه کلاسه آپنه خفیف، آپنه شدید و نرمال
۱۳.....	۲-۲-۲ طبقه بندی سه کلاسه نرمال، آپنه انسدادی و آپنه مرکزی
۱۶.....	۳-۲-۲ طبقه بندی سه کلاسه آپنه مرکزی-آپنه انسدادی-آپنه مختلط
۲۲.....	فصل ۳ - روش تحقیق
۲۲.....	۱-۳ مقدمه
۲۲.....	۲-۳ پایگاه داده
۲۲.....	۱-۲-۳ پایگاه داده MIT-BIH polysomnographic
۲۴.....	۲-۲-۳ بانک داده خواب کشوری بیمارستان کودکان (NCHSDB)
۲۶.....	۳-۲-۳ مطالعه خانواده کلیولند (CFS)
۲۷.....	۳-۳-۳ پیش پردازش داده
۲۷.....	۱-۳-۳ فیلتر کردن داده ها
۲۸.....	۲-۳-۳ استاندارد سازی داده ها
۲۹.....	۳-۳-۳ بخش بندی سیگنال
۲۹.....	۴-۳ استخراج ویژگی
۳۰.....	۱-۴-۳ تغییر پذیری ضربان قلب

۳۲.....	۲-۴ سیگنال تنفس مشتق شده از ECG
۳۴.....	۵-۳ کاهش ابعاد ویژگی
۳۴.....	۶-۳ تقسیم مجموعه داده به مجموعه آموزش و آزمون
۳۵.....	۷-۳ ساختار شبکه عصبی
۳۸.....	۱-۷-۳ تابع هزینه
۳۹.....	۲-۷-۳ تابع بهینه ساز آدام
۳۹.....	۸-۳ معیارهای ارزیابی
۳۹.....	۱-۸-۳ ماتریس درهم ریختگی
۴۰.....	۲-۸-۳ معیار دقت
۴۱.....	۳-۸-۳ معیار یادآوری
۴۱.....	۴-۸-۳ امتیاز F1
۴۱.....	۵-۸-۳ منحنی ROC و ناحیه زیر آن
۴۲.....	۹-۳ نرم افزار و سخت افزار مورد استفاده
۴۳.....	فصل ۴- نتایج
۴۳.....	۱-۴ مقدمه
۴۳.....	۲-۴ مرحله استخراج ویژگی
۴۵.....	۳-۴ مرحله تقسیم مجموعه داده
۴۵.....	۴-۴ مرحله آموزش شبکه عصبی
۴۹.....	۴-۴ مرحله آزمون شبکه عصبی
۵۵.....	۶-۴ بحث
۵۷.....	فصل ۵- جمع بندی و پیشنهادها
۵۷.....	۱-۵ جمع بندی
۵۷.....	۲-۵ پیشنهادها

فهرست شکل ها

شکل ۱-۲ تفکیک کلاس بر اساس دقیقه در شب [۱۶].	۱۲
شکل ۲-۲ ساختار روش طبقه‌بندی پیشنهادی [۲۵].	۱۸
شکل ۱-۳ توزیع سنی افراد شرکت کننده در زمان مطالعه خواب [۳۰].	۲۵
شکل ۲-۳ نمودار توزیع سنی افراد شرکت کننده در زمان شروع مطالعه.	۲۷
شکل ۳-۳ نمونه ای از سیگنال ECG بعد از اعمال فیلتر.	۲۸
شکل ۴-۳ نمونه ای از سیگنال استاندارد شده.	۲۹
شکل ۵-۳ الگوریتم پن تامپکینز [۴۰].	۳۰
شکل ۶-۳ معماری معمولی LSTM. یک بلوک LSTM معمولاً دارای یک سلول حافظه، دروازه ورودی (it)، دروازه خروجی ($0t$) و یک دروازه فراموشی (ft) است.	۳۶
شکل ۷-۳ نمای کلی ساختار شبکه پیشنهادی.	۳۷
شکل ۸-۳ نمودار تغییرات تابع هزینه کانونی بر حسب احتمال کلاس صحیح به ازای مقادیر مقیاس ۰ تا ۵ [۴۴].	۳۹
شکل ۹-۳ ماتریس درهم‌ریختگی.	۴۰
شکل ۱-۴ قسمت اول قله های R تشخیص داده شده، قسمت دوم نمودار فواصل R-R مربوط به یک بخش ثانیه ای را نشان می دهدن.	۴۴
شکل ۲-۴ سیگنال تنفس مشتق شده از ECG مربوط به یک بخش ۳۰ ثانیه ای از سیگنال.	۴۴
شکل ۳-۴ نمودار یادآوری و خط آموزش و اعتبار سنجی بر حسب تکرار برای هر دسته.	۴۶
شکل ۴-۴ نمودار دقت و خط آموزش و اعتبار سنجی بر حسب تکرار برای هر دسته.	۴۷
شکل ۵-۴ نمودار امتیاز F1 و AUC آموزش و اعتبار سنجی بر حسب تکرار برای هر دسته.	۴۸
شکل ۶-۴ نمودار کلی مقادیر میانگین وزنی معیار های استفاده شده.	۵۰
شکل ۷-۴ نمودار مقادیر معیار دقت مربوط به هر کلاس.	۵۰
شکل ۸-۴ نمودار مقادیر معیار یادآوری مربوط به هر کلاس.	۵۱
شکل ۹-۴ نمودار مقادیر معیار امتیاز F1 مربوط به هر کلاس.	۵۱
شکل ۱۰-۴ نمودار مقادیر معیار AUC مربوط به هر کلاس.	۵۲
شکل ۱۱-۴ ماتریس درهم ریختگی مربوط به هر دسته.	۵۳
شکل ۱۲-۴ نمودار ROC مربوط به هر دسته.	۵۴

فهرست جدول ها

جدول ۱-۲ عملکرد مدل CNN پیشنهادی برای تشخیص خودکار OSA [۱۷].	۸.....
جدول ۲-۲ پارامترهای عملکرد برای روش پیشنهادی با استفاده از داده های نامتعادل و متعادل [۱۹].	۹.....
جدول ۳-۲ مقایسه عملکرد طبقه‌بندی کننده‌ها در مجموعه داده‌های آزمون در هر کلاس [۱۶].	۱۳.....
جدول ۴-۲ ماتریس درهم ریختگی برای مجموعه آزمون [۲۲].	۱۴.....
جدول ۵-۲ نتایج مربوط به هر طبقه بندی کننده [۲۳].	۱۵.....
جدول ۶-۲ نتایج سه طبقه بندی کننده شامل دقت، یادآوری، امتیاز f1 و ضریب کاپا [۲۳].	۱۶.....
جدول ۷-۲ ماتریس درهم ریختگی [۲۴].	۱۷.....
جدول ۸-۲ عملکرد طبقه بندی شبکه عصبی مصنوعی برای (الف) ضریب مومنتوم ۰,۹۵، (ب) ضریب مومنتوم ۰,۷۵ و (ج) ضریب مومنتوم ۰,۵۰.	۱۸.....[۲۵]
جدول ۹-۲ نتایج عملکرد طبقه‌بندی باینری شدت آپنه با سه مدل طبقه بندی کننده [۲۸].	۲۰.....
جدول ۱۰-۲ نتایج عملکرد طبقه بندی انواع مختلف آپنه خواب با سه مدل طبقه بندی کننده [۲۸].	۲۰.....
جدول ۱-۳ اطلاعات ثبت های پایگاه داده MITBIH [۲۹].	۲۳.....
جدول ۲-۳ برچسب های رویدادها.	۲۴.....
جدول ۳-۳ تعداد کل رویداد های آپنه پایگاه داده MITBIH.	۲۴.....
جدول ۴-۳ توزیع نژادی مربوط به فرد [۳۰] ۳۶۷۳.	۲۵.....
جدول ۵-۳ تعداد کل رویداد های آپنه پایگاه داده NCHSDB.	۲۶.....
جدول ۶-۳ تعداد کل رویداد های آپنه پایگاه داده CFS.	۲۷.....
جدول ۷-۳ ویژگی های مورد استفاده استخراج شده از سیگنال ECG.	۳۲.....
جدول ۸-۳ واریانس مربوط به هر مولفه.	۳۴.....
جدول ۱-۴ تعداد های موجود در هر مجموعه داده به تفکیک کلاس.	۴۵.....
جدول ۲-۴ مقداری خطأ، صحت، یادآوری، امتیاز F1 و AUC مدل منتخب در هر دسته.	۴۹.....
جدول ۳-۴ مقایسه نتایج پژوهش با سایر مطالعات انجام شده.	۵۶.....

فهرست اختصارات

اختصار	عبارة كامل
COPD	Chronic Obstructive Pulmonary Disease
SA	Sleep Apnea
ICSD	International Classification of Sleep Disorders
AASM	American Academy of Sleep Medicine
AHI	Apnea-Hypopnea Index
OSA	Obstructive Sleep Apnea
CSA	Central Sleep Apnea
MSA	Mixed Sleep Apnea
CPAP	Continuous Positive Airway Pressure
HGNS	Hypoglossal Nerve Stimulation
EEG	Electroencephalogram
EOG	Electrooculogram
EMG	Electromyogram
ECG	Electrocardiogram
HR	Heart Rate
HRV	Heart Rate Variability
EDR	ECG-derived Respiration
PAV	Peak Amplitude Variation
RRI	R-R Interval
KNN	K-Nearest Neighbor
MPL	Multilayer Perceptron
SVM	Support Vector Machine
CNN	Convolutional Neural Network
ReLU	Rectified Linear Units
FFT	Fast Fourier Transform
SHHS	Sleep Heart Health Study
ANS	Autonomic Nervous System
HT	Hilbert Transform
DWT	Discrete Wavelet Transform
ANOVA	ANalysis Of VAriance
ANN	Artificial Neural Network
RNN	Recurrent Neural Network
LSTM	Long Short-Term Memory
RF	Random Forest
PCA	Principal Component Analysis
KPCA	Kernel Principal Component Analysis
LDA	Linear Discriminant Analysis
NB	Naive Bayes
NCHSDB	Nationwide Children's Hospital Sleep DataBank
CFS	Cleveland Family Study
BW	Baseline Wander
AUC	Area Under receiver operating characteristic Curve

فصل ۱ - مقدمه

۱-۱ پیشگفتار

خواب یک فعالیت بیولوژیکی است که توسط مغز انسان آغاز و کنترل می‌شود. بدن انسان در طول خواب خود را بهبود می‌بخشد و بازسازی می‌کند و مواد زائد متابولیکی^۱ را که در هنگام بیداری ایجاد می‌شوند از بین می‌برد. خواب همچنین حافظه را سازماندهی کرده و شکل گیری حافظه بلند مدت را پشتیبانی می‌کند. با توجه به فواید فراوان خواب برای انسان، خوابی کافی یکی از موارد ضروری برای حفظ سلامت می‌باشد. در صورت کمبود خواب با کیفیت، ریتم شبانه‌روزی بدن مختل می‌شود، خطر ایجاد مشکلات سلامتی از جمله بیماری‌های قلبی عروقی، اختلالات شناختی، زوال حافظه و همینطور خطر چاقی و سکته مغزی افزایش می‌یابد. کمبود خواب همچنین باعث کاهش بهره‌وری در کار و مطالعه می‌شود. با وجود اینکه انسان‌ها تقریباً یک سوم زندگی خود در خواب هستند، پیش‌تر اهمیت موضوع خواب نادیده گرفته می‌شد. با شروع دهه ۱۹۸۰، اختلالات خواب به طور نظام مند مورد مطالعه، درک و تشخیص گستردۀ تر قرار گرفت و طب خواب به یک تخصص پزشکی تبدیل شد. مشکلات اختلال خواب در سراسر جهان شایع است به طوری که در ایالات متحده آمریکا، ۳۰ درصد از بزرگسالان مبتلا به بی‌خوابی تشخیص داده شده‌اند. همچنین در مطالعه انجام شده در ۵۶ کشور، شیوع کلی مشکلات خواب ۷,۶ درصد گزارش شده است. با توجه به روند فعلی، تعداد افراد مبتلا به اختلال خواب تا سال ۲۰۳۰ به ۲۶۰ میلیون نفر خواهد رسید [۱ و ۲].

تنفس حاصل از انقباض لایه عضلانی دیافراگم که حفره شکم و قفسه سینه را جدا می‌کند، یک حرکت غیر ارادی ضروری برای موجودات زنده است. در طول دم و بازدم، اندازه دیافراگم تغییر می‌کند که این تغییرات می‌تواند سرنخی از بسیاری از بیماری‌ها (غشایی شدن دیافراگم^۳، بیماری مزمن انسدادی ریه^۴ (COPD)، آپنه خواب^۵ (SA) و غیره) را بدهد [۳].

طبقه‌بندی بین‌المللی اختلالات خواب^۶ (ICSD)، اختلالات خواب را به شش دسته اصلی تعریف می‌کند که شامل اختلالات بی‌خوابی^۷، اختلالات تنفسی مرتبط با خواب^۸، اختلالات مرکزی خواب بیش از حد^۹، اختلالات

¹ metabolic waste

² diaphragm eventration

³ chronic obstructive pulmonary disease

⁴ sleep apnea

⁵ International Classification of Sleep Disorders

⁶ insomnia disorders

⁷ sleep-related breathing disorders

⁸ central disorders of hypersomnolence

ریتم شبانه روزی خواب و بیداری^۱، اختلالات حرکتی مرتبط با خواب^۲، ناہنجاری های مرتبط با خواب^۳ می باشد. اختلالات تنفسی مرتبط با خواب شامل اختلالات آپنه، هیپوونتیلاسیون مرتبط با خواب^۴ و اختلال هیپوکسمی^۵ مرتبط با خواب می باشند [۴].

آپنه یک اختلال تنفسی است که با انسدادهای تنفسی مکرر (حداقل ۱۰ ثانیه) در طول خواب مشخص می شود و چندین بار در طول شب، بدون اینکه بیمار از آن مطلع شود رخ می دهد. با توجه به راهنمای امتیاز دهی آپنه آکادمی پزشکی خواب آمریکا^۶ (AASM)، دو معیار برای ارزیابی آپنه خواب در نظر گرفته شده است: ۱. حداقل ۹۰ درصد کاهش در دامنه جریان هوا اتفاق افتاده باشد. ۲. این کاهش باید حداقل ۱۰ ثانیه طول بکشد. هیپوپنه^۷ زمانی اتفاق می افتد که دامنه تنفس حداقل ۳۰ درصد برای بیش از ۱۰ ثانیه کاهش یابد. علاوه بر این، باید کاهش اشباع اکسیژن شریانی حداقل ۳٪ وجود داشته باشد تا قسمتی به عنوان هیپوپنه ثبت شود. برای ساده سازی تشخیص، شاخص آپنه-هیپوپنه^۸ (AHI) معرفی شده است که امکان ارزیابی شدت بیماری را فراهم می کند. شاخص آپنه-هیپوپنه با تقسیم تعداد کل آپنه و هیپوپنه هایی که حداقل ۱۰ ثانیه طول می کشد، بر ساعت خواب محاسبه می شود. شدت آپنه به چهار دسته نرمال ($AHI < 5$)، آپنه خواب خفیف ($5 < AHI < 15$)، آپنه خواب متوسط ($15 < AHI < 30$)، و آپنه خواب شدید ($AHI > 30$) تقسیم می شود. افرادی که آپنه خواب دارند حتی پس از یک خواب کامل شبانه نیز احساس خستگی می کنند. چهار درصد از مردان بالغ و دو درصد از زنان بالغ از این اختلال رنج می برند. اگرچه بروز وقایع آپنه ممکن است فیزیولوژیکی باشد، اما اگر بیش از ۵ رویداد آپنه در هر ساعت خواب رخ دهد، معمولاً به عنوان یک بیماری در نظر گرفته می شود. در آمریکای شمالی، تقریباً ۱۸ میلیون نفر (۶٪) از آپنه خواب رنج می برند. آپنه خواب معمولاً با خواب آلودگی در طول روز، خروپف بلند، خستگی، اختلال شناختی، عدم تمرکز و کاهش توانایی یادگیری، فشار خون بالا، سکته مغزی، بیماری های قلبی عروقی و عصبی، اختلالات متابولیک و افزایش میزان مرگ و میر مرتبط است [۱۴، ۱۳، ۶، ۷، ۵، ۳].

پزشکان آپنه خواب را به سه نوع آپنه خواب انسدادی^۹ (OSA)، آپنه خواب مرکزی^{۱۰} (CSA) و آپنه خواب مختلط^{۱۱} (MSA) تقسیم می کنند. در بین انواع مختلف آپنه خواب، آپنه انسدادی شیوع بیشتری نسبت به سایرین دارد و باعث انسداد مکرر و موقت در محاری تنفسی فوقانی و عدم تغییر در ریتم تنفسی می شود. آپنه انسدادی را می توان به عنوان یک توقف تنفسی کوتاه مدت علیرغم تلاش عضلاتی برای تنفس تعریف

¹ circadian rhythm sleep-wake disorders

² sleep-related movement disorders

³ parasomnia

⁴ sleep-related hypoventilation

⁵ hypoxemia

⁶ American Academy of Sleep Medicine

⁷ hypopnea

⁸ apnea-hypopnea index

⁹ obstructive sleep apnea

¹⁰ central sleep apnea

¹¹ mixed sleep apnea

کرد. در این نوع آپنه، تنفس به دلیل انسداد مجرای هوایی از کار می‌افتد. علیرغم شیوع بالا و شرایط خطرناکی که این بیماری ایجاد می‌کند، در بسیاری از موارد افراد مبتلا به آپنه انسدادی تشخیص داده نشده باقی می‌مانند. علاوه بر این، چاقی یکی از مواردی است که ارتباط نزدیکی با آپنه انسدادی دارد [۳ و ۸].

ماهیچه‌های دیافراگم توسط مغز انسان برای نفس کشیدن در هنگام خواب تحریک می‌شوند. آپنه مرکزی را می‌توان به عنوان توقف کوتاه مدت تنفسی که در نتیجه عدم ارسال سیگنال از مغز ایجاد می‌شود، تعریف کرد و آپنه‌ی مختلط نیز به ترکیب دو آپنه انسدادی و مرکزی گفته می‌شود. در حالی که حرکات شکمی در آپنه انسدادی و آپنه مختلط در زمان بروز آپنه ادامه می‌یابد، در آپنه مرکزی، حرکات شکمی در زمان آپنه به طور قابل توجهی کاهش می‌یابد [۳].

فشار مداوم و مثبت در راه هوایی^۱ (CPAP)، بهترین روش درمانی آپنه انسدادی با اثربخشی ثابت شده می‌باشد. دستگاه CPAP جریان ثابتی از هوا را از طریق ماسکی که هنگام خواب پوشیده می‌شود، عبور می‌دهد و راه هوایی را باز نگه می‌دارد. همینطور چندین گزینه درمانی دیگر مانند جراحی چاقی، جراحی دریچه‌های بینی، تحریک عصب هیپوگلوسال^۲ (HGNS) و تمرینات دهانی حلقوی^۳ در بیماران مبتلا به آپنه خواب نیز وجود دارند [۱۵].

پلی سومنوگرافی شبانه، که در آزمایشگاه خواب انجام می‌شود، استاندارد طلایی برای تشخیص آپنه خواب در نظر گرفته می‌شود و شامل ثبت حداقل یازده کانال از سیگنال‌های فیزیولوژیکی مختلف از جمله الکتروانسفالوگرام^۴ (EEG)، الکترواکولوگرام^۵ (EOG)، الکترومیوگرام^۶ (EMG) و الکتروکاردیوگرام^۷ (ECG) که از حسگرهای مختلف جمع‌آوری شده‌اند، می‌باشد. با این حال، به دلیل تعداد زیاد سیم‌ها و حسگرهای متصل به بدن فرد، گران قیمت بودن، در دسترس نبودن گروه بزرگی از جمعیت افراد و متخصص فنی و زیرساخت‌های تخصصی مانند آزمایشگاه‌های تخصصی خواب، مناسب به نظر نمی‌رسد. علاوه بر این، فرآیند تجزیه و تحلیل زمان بر و پر زحمت است. بنابراین، مستعد خطا است [۷].

در نتیجه، تکنیک متفاوتی مورد نیاز است که می‌تواند به راحتی برای تشخیص آپنه خواب اعمال شود. مطالعات مختلف پیشنهاد کرده اند که به منظور غلبه بر این مشکل، از داده‌های سیگنال تک کانالی (جریان هوای، پالس اکسیمتری، الکتروانسفالوگرافی، الکتروکاردیوگرافی و خروپف) برای تشخیص خودکار آپنه استفاده شود. تنفس و خروپف مستقیماً توسط آپنه خواب و انسداد راه هوایی فوکانی و ECG و SPO2 به طور غیرمستقیم توسط رویدادهای آپنه تحت تأثیر قرار می‌گیرند. این تغییرات فیزیولوژیکی سیگنال ECG در طول آپنه را می‌توان با زمان، فرکانس و تجزیه و تحلیل دامنه غیر خطی مشاهده کرد. بنابراین، بیشتر مطالعات

¹ Continuous positive airway pressure

² Hypoglossal nerve

³ oro-pharyngeal

⁴ Electroencephalogram

⁵ Electrooculogram

⁶ Electromyogram

⁷ Electrocardiogram

جایگزین بر استخراج ویژگی‌های زمانی، طیفی و غیرخطی از سیگنال‌های فیزیولوژیکی و روش‌های مختلف انتخاب ویژگی از جمله تجزیه و تحلیل مؤلفه‌ها، ارزیابی آماری و روش‌هایی برای کاهش ابعاد فضای ویژگی متتمرکز بوده‌اند. آپنه خواب همچنین باعث تغییرات چرخه‌ای در ضربان قلب (HR) می‌شود، به عبارت دیگر زمانی که آپنه خواب باعث توقف در فرآیند تنفسی می‌شود، مقدار اکسیژن برای قلب کافی نیست و در نتیجه سطوح کمتری از اکسیژن به سلول‌های قلب می‌رسد و در نهایت منجر به کاهش و غیر طبیعی شدن ضربان قلب می‌شود. همچنین فاصله بین پیک‌های R افزایش می‌یابد. در نتیجه، مغز با استفاده از پالس‌های فوری به سیستم تنفسی، سرعت تنفس را افزایش می‌دهد و در نتیجه ضربان قلب افزایش می‌یابد. تلاش تنفسی تغییری در موقعیت الکترود ECG ایجاد می‌کند که به طور گستردگی بر دامنه سیگنال ECG تأثیر می‌گذارد. تغییرات در ضربان قلب با تجزیه و تحلیل تغییرپذیری ضربان قلب^۱ (HRV) مشخص می‌شوند. ساده‌ترین راه برای نظارت بر عملکرد ضربان قلب، سیگنال ECG است که می‌تواند سطح اکسیژنی که به قلب می‌رسد را نشان دهد. سیگنال ECG در مقایسه با پلی سومنوگرافی برای بیماران استرس زا نیست و استفاده از تجهیزات ECG مربوطه نیاز به تخصص فنی کمتری دارند. همچنین مشاهده شده است که ECG با قدرت سیگنال ۲-۱ میلی ولت بهترین نسبت سیگنال به نویز را در بین تمام سیگنال‌های فیزیولوژیکی دارد. تغییرپذیری ضربان قلب و سیگنال تنفسی مشتق از ECG^۲ (EDR) را می‌توان از سیگنال ECG محاسبه کرد. این دو سیگنال برای استخراج اطلاعات قلبی-تنفسی مفید هستند و همچنین ویژگی‌های استخراج شده از این دو سیگنال برای تشخیص آپنه خواب استفاده می‌شود. گزارش شده است که ویژگی‌های هر دو سیگنال EDR و HRV برای افراد با آپنه خواب و افراد نرمال متفاوت است. HRV تغییرات فاصله زمانی بین ضربان‌های متوالی قلب را که به عنوان فاصله R-R^۳ (RRI) شناخته می‌شود، ارزیابی می‌کند. تغییر در فاصله R-R نشانه ای از حوادث آپنه است، از این رو می‌تواند پایه فیزیولوژیکی برای تشخیص آپنه را فراهم کند. با توجه به این تفاسیر، از آنجایی که تغییرات ناشی از آپنه خواب در ECG بسیار متنوع و ظریف است، تشخیص آپنه بر اساس داده‌های ECG را به یک کار بسیار پیچیده تبدیل می‌کند. یکی از روش‌هایی که برای حل این مشکل در نظر گرفته شده است استفاده از الگوریتم‌های کامپیوتری است [۶، ۸، ۹، ۱۰، ۱۱، ۱۲].

محققان متعددی بر اساس حسگرهای کمتر و الگوریتم‌های طبقه‌بندی خودکار، فرآیندهای امتیازدهی خودکار را پیشنهاد و اجرا کرده‌اند. یادگیری عمیق به دلیل در دسترس بودن پایگاه داده، تکنیک‌های جدید توسعه یافته، امکان تولید ویژگی‌های ایجاد شده توسط ماشین و قدرت محاسباتی بالاتر که به الگوریتم‌ها اجازه می‌دهد تا عملکرد بهتری نسبت به طبقه‌بندی کننده‌های سطحی داشته باشند، بیشتر مورد توجه قرار گرفته است. بنابراین، تحقیقات آپنه خواب در حال حاضر علاقه قابل توجهی به یادگیری عمیق پیدا کرده است [۷].

¹ heart rate² heart rate variability³ ECG-derived respiration⁴ R-R interval

۱-۲ بیان مسئله و هدف پژوهش

خواب مناسب برای حفظ سلامت روان و همچنین سلامت جسمی ضروری است و عملکرد مغز، خلق و خو و سلامت افراد را بهبود می بخشد. نداشتن میزان خواب کافی و باکیفیت منجر به احساس خستگی در طول روز می شود و در عملکرد شناختی اختلال ایجاد می کند که می تواند منجر به اختلالات یادگیری در کودکان، اختلال حافظه در افراد در هر سنی، تغییرات شخصیتی و افسردگی شود. کم خوابی همچنین می تواند با ایجاد چاقی، دیابت و بیماری قلبی، کیفیت زندگی را تحت تاثیر قرار دهد. آپنه یک اختلال خواب جدی است و به دلیل اهمیت خواب در سلامتی فرد و همچنین استرس ناشی از بیداری های مکرر به دلیل حس خفگی در طول شب، عدم تشخیص آپنه می تواند در دراز مدت به عوارض جدی منجر شود. آپنه خواب به سه نوع آپنه انسدادی، آپنه مرکزی و آپنه مختلط تقسیم می شود. با توجه به تفاوت در درمان انواع آپنه، تمایز سه نوع آپنه از اهمیت زیادی برخوردار است. تشخیص انواع آپنه در مراحل اولیه، می تواند باعث افزایش کیفیت زندگی افراد شده و هزینه های درمان را کاهش دهد. هدف اصلی در این مطالعه توسعه روشی برای طبقه بندی خودکار رویدادهای آپنه انسدادی، آپنه مرکزی، آپنه مختلط و رویدادهای تنفس طبیعی می باشد.

از طرف دیگر، پژوهشکار به طور معمول برای تشخیص و شناسایی انواع آپنه خواب با استفاده از روش های سنتی، به سیگنال های زیستی مختلفی از جمله اشباع اکسیژن خون، تلاش تنفسی، EEG و ECG نیاز دارد. به دلیل پیچیدگی بالا، ثبت این سیگنال ها نیازمند دستگاه های ثبت گران قیمت، به کارگیری تکنسین های متخصص بوده و همچنین نصب تعداد زیادی الکترود به فرد که باید به وسیله سیم به دستگاه های ثبت متصل شوند خود میتواند باعث ایجاد ناراحتی و در نتیجه ایجاد اختلال در روند ثبت سیگنال ها شود. در این پژوهش برای اولین بار، شناسایی و طبقه بندی انواع آپنه خواب تنها با استفاده از سیگنال ECG انجام گرفته است که با توجه به پیشرفت روزافزون تکنولوژی در زمینه سلامت و همچنین فراگیری استفاده از دستگاه های پوشیدنی مانند ساعت های هوشمند، می تواند به سادگی و بدون ایجاد مزاحمت برای فرد، تنها با استفاده از یک ساعت هوشمند ثبت و بررسی شود.

۱-۳ پیکربندی پایان نامه

در فصل دوم این پایان نامه، مطالعات انجام شده در زمینه تشخیص و طبقه بندی انواع آپنه خواب به طور مختصر مرور می شود. بعد از آن، در فصل سوم، پایگاه های داده استفاده شده، پیش پردازش های انجام شده، استخراج ویژگی، کاهش بعد فضای ویژگی، معماری و نحوه آموزش شبکه عصبی عمیق و معیار های ارزیابی عملکرد شبکه بیان شده و مورد بحث قرار می گیرند. در فصل چهارم، نتایج مربوط به مرحله آموزش شبکه

پیشنهادی و عملکرد شبکه بر روی داده های آزمون مورد بررسی قرار می گیرد. در پایان، در فصل پنجم، به جمع بندی مطالب اشاره شده و ارایه پیشنهادهایی در راستای بهبود و ارتقا این پژوهش می پردازیم.

فصل ۲ - مطالعات پیشین در زمینه طبقه بندی آپنه

در این فصل به طور مختصر مروری بر مطالعات پیشین و کارهای انجام شده در زمینه تشخیص و طبقه بندی آپنه خواب انجام گرفته است. این مطالعات را می‌توان با توجه به نتایج نهایی آن‌ها به دو دسته کلی طبقه بندی دو کلاسه و طبقه بندی سه کلاسه تقسیم کرد که در زیر به هر یک از آنها پرداخته شده است:

۱-۲ طبقه بندی دو کلاسه

در این قسمت، مطالعات مربوط به طبقه بندی دو کلاس مورد بررسی قرار می‌گیرند که این طبقه بندی بین دو حالت آپنه - نرمال و آپنه انسدادی - آپنه مرکزی صورت گرفته است.

۱-۱-۲ طبقه بندی دو کلاسه آپنه خواب و نرمال

در مطالعه‌ای که در سال ۲۰۱۸ انجام شد، روشی برای تشخیص خودکار آپنه انسدادی خواب با استفاده از ECG تک کanal و شبکه عصبی کانولوشنی^۱ CNN پیشنهاد شد. برای آموزش و ارزیابی مدل CNN، یک مجموعه داده ECG تک کanal از ۸۲ فرد مبتلا به OSA جمع آوری شد و به مجموعه داده‌های آموزشی (شامل داده‌های ۶۳ بیمار با ۳۴۲۸۱ رویداد) و آزمون (شامل داده‌های ۱۹ بیمار با ۸۵۷۱ رویداد) تقسیم شد. ابتدا یک فیلتر میان گذر (۵ تا ۱۱ هرتز) برای حذف نویز نامطلوب روی داده‌های ECG تک کanal اعمال شد. مدل CNN با شش لایه کانولوشنی بهینه شامل لایه‌های فعال‌ساز^۲، ادغام^۳ و حذف تصادفی^۴ طراحی شد. کانولوشن یک بعدی، واحدهای خطی اصلاح شده^۵ (ReLU)، و ادغام بیشینه^۶ به ترتیب برای لایه‌های کانولوشن، فعال‌سازی و ادغام اعمال شدند. در نهایت، طبقه بندی دو کلاسه در لایه کاملاً متصل با فعال‌سازی بیشینه هموار^۷ انجام شد. با استفاده از این مدل CNN، دقت ۹۹٪، یادآوری^۸ ۹۹٪ و امتیاز F1^۹ ۹۹٪ با مجموعه داده آموزشی به دست آمد. و تمامی این معیارها برای مجموعه داده آزمون برابر ۹۶٪ بودند.

¹ convolutional neural network

² activation

³ pooling

⁴ dropout

⁵ rectified linear units

⁶ maxpooling

⁷ Softmax

⁸ Recall

⁹ F1-score

جدول ۱-۲ عملکرد مدل CNN را برای در تشخیص خودکار OSA با استفاده از سیگنال ECG تک کanal نشان می دهد [۱۷].

جدول ۱-۲ عملکرد مدل CNN پیشنهادی برای تشخیص خودکار OSA [۱۷].

F1 امتیاز	بازیابی	دقت	رویداد ها		مجموعه داده
۰,۹۹	۰,۹۸	۰,۹۹	۱۷۰۹۲	نرمال	مجموعه داده آموزش
۰,۹۹	۰,۹۹	۰,۹۸	۱۷۱۸۹	انسدادی	
۰,۹۹	۰,۹۹	۰,۹۹	میانگین		
۰,۹۶	۰,۹۶	۰,۹۵	۴۳۳۴	نرمال	مجموعه داده آزمون
۰,۹۶	۰,۹۵	۰,۹۶	۴۲۳۷	انسدادی	
۰,۹۶	۰,۹۶	۰,۹۶	میانگین		

در سال ۲۰۲۱ مطالعه ای به منظور تشخیص آپنه انسدادی خواب از طریق سیگنال های EEG به کمک الگوریتم های یادگیری ماشین انجام شد. در این تحقیق ۵ بیمار با شاخص های مختلف آپنه - هیپوپنه مورد بررسی قرار گرفتند. سیگنال های ورودی با فرکانس ۱۲۸ هرتز نمونه برداری و به فریم ۱۰ ثانیه ای تقسیم شدند که هر فریم حاوی رویداد آپنه یا رویداد غیر آپنه بود. سپس حوزه زمان، موجک ها و دامنه فرکانس سیگنال های EEG محاسبه شد و ویژگی ها از این حوزه ها استخراج شدند. تجزیه موجک این فریم ها با اعمال تبدیل موجک ^۱ بعدی انجام شد. ضرایب تقریب ^۲ و ضرایب جزئیات ^۳ برای استخراج ویژگی استفاده شدند. تبدیل فوریه سریع ^۴ (FFT) فریم های EEG نیز محاسبه شد که به عنوان ورودی برای استخراج ویژگی نیز عمل می کرد. برای طبقه بندی دقیق آپنه خواب، ویژگی ها از سه حوزه زمان، موجک و فرکانس محاسبه شدند. ویژگی های مورد استفاده عبارت بودند از: انرژی، واریانس ^۵، چولگی ^۶، حالت، انحراف استاندارد ^۷، میانه ^۸، میانگین هندسی، حداقل، حداکثر، میانگین و آنتروپی ^۹. این ویژگی ها به عنوان ورودی در دو الگوریتم ماشین بردار پشتیبان و KNN استفاده شدند. ۹۰٪ از مجموعه داده برای آموزش طبقه بندی کننده ها و ۱۰٪ برای آزمون استفاده شد. طبقه بندی KNN در طبقه بندی آپنه از رویدادهای غیر آپنه در بیماران از SVM بهتر عمل می کرد و KNN مرتبه ^{۱۰} بالاترین حساسیت عملکرد ۸۵,۹۲٪، اختصاصیت ۸۰٪ و دقت ۸۲,۶۹٪ را نشان داد [۱۸].

^۱ Approximation Coefficients

^۲ Detail Coefficients

^۳ Fast fourier transform

^۴ Variance

^۵ Skewness

^۶ standard deviation

^۷ Median

^۸ Entropy

در سال ۲۰۲۲ مطالعه‌ای به منظور تشخیص خودکار آپنه انسدادی با استفاده از سیگنال‌های تنفسی و اکسیمتری انجام شد. هدف از این مطالعه توسعه یک سیستم خودکار مبتنی بر موجک ساده، برای تشخیص OSA در افراد مسن بود. در این مطالعه، با استفاده از پالس اکسیمتری^۱ (SpO_2) و سیگنال‌های تنفسی از جمله حرکت قفسه سینه^۲ ($ThorRes$), حرکت شکمی^۳ ($AbdoRes$) و جریان هوای^۴ یک سیستم تشخیص خودکار OSA دقیق و قابل اعتماد پیشنهاد شد. این سیگنال‌ها از پایگاه داده مطالعه سلامت قلب خواب^۴ (SHHS) جمع‌آوری شده بودند. پایگاه داده شامل دو گروه SHHS1 و SHHS2 بود که به ترتیب شامل ۵۷۹۳ و ۲۶۵۱ نفر با میانگین سنی بیشتر از ۶۰ سال بودند. دوره‌های ۳۰ ثانیه‌ای سیگنال‌ها با استفاده از بانک فیلتر موجک متعامد بهینه شده به زیر باندها تجزیه شد. مدل پیشنهادی با استفاده از الگوریتم‌های Random under-sampling Boosting (RUSBoosted Tree) و GentleBoost متقابل ۱۰ برابری توسعه داده شد. مدل بالاترین دقت طبقه‌بندی٪ ۸۹,۳۹ و٪ ۸۴,۶۴ را به ترتیب برای مجموعه داده‌های نامتعادل و متعادل با استفاده از تکنیک اعتبارسنجی متقابل ۱۰ برابری به دست آورده است. در این کار، طبقه‌بندی کننده RUSBoost بهترین عملکرد را برای تشخیص OSA با داده‌های نامتعادل انجام داد. معیارهای عملکرد مدل پیشنهادی برای هر مجموعه داده و ترکیبی از مجموعه داده‌ها در جدول ۲-۲ نشان داده شده است [۱۹].

جدول ۲-۲ پارامترهای عملکرد برای روش پیشنهادی با استفاده از داده‌های نامتعادل و متعادل [۱۹].

AUC	کاپا	F1	امتیاز	اختصاصیت	حساسیت	دقت	صحت	کلاس	مجموعه داده
۰,۸۹۱	۰,۲۵۶	۰,۹۰۹	۷۷,۲۲	۸۴,۳۱	۹۸,۶۸	۸۳,۹۷	N	نا متعادل	SHHS-1
		۰,۳۱۲	۸۴,۳۱	۷۷,۲۲	۱۹,۰۸		O		
۰,۹۲۱	۰,۶۸۴	۰,۸۴۳	۸۳,۸۰	۸۴,۶۲	۸۳,۹۳	۸۴,۲۱	N	متعادل	SHHS-1
		۰,۸۴۲	۸۴,۶۲	۸۳,۸۰	۸۴,۴۹		O		
۰,۹۳۲	۰,۲۶۰	۰,۹۴۳	۸۰,۲۰	۸۹,۷۶	۹۹,۳۹	۸۹,۵۰	N	نا متعادل	SHHS-2
		۰,۲۹۳	۸۹,۷۶	۸۰,۲۰	۱۷,۹۱		O		
۰,۹۵۳	۰,۷۶۹	۰,۸۸۴	۸۸,۹۶	۸۷,۹۴	۸۸,۸۵	۸۸,۴۵	N	متعادل	SHHS-2
		۰,۸۸۵	۸۷,۹۴	۸۸,۹۶	۸۸,۰۶		O		
۰,۹۰۴	۰,۲۹۲	۰,۹۴۲	۷۱,۰۰	۹۰,۱۰	۹۸,۷۷	۸۹,۳۹	N	نا متعادل	SHHS-1 + SHHS-2
		۰,۳۳۲	۹۰,۱۰	۷۱,۰۰	۲۱,۶۹		O		
۰,۹۳۲	۰,۶۹۳	۰,۸۴۷	۸۴,۲۱	۸۵,۰۷	۸۴,۳۴	۸۴,۶۴	N	متعادل	SHHS-1 + SHHS-2
		۰,۸۴۶	۸۵,۰۷	۸۴,۲۱	۸۴,۹۴		O		

¹ pulse oximetry² Thoracic respiratory³ Abdominal respiratory⁴ Sleep Heart health Study

۲-۱-۲ طبقه بندی دو کلاسه آپنه انسدادی و آپنه مرکزی

در سال ۲۰۱۲ مطالعه‌ای انجام شد که در آن از یک الگوریتم جدید با استفاده از تجزیه و تحلیل بسته‌های موجک^۱ و ماشین بردار پشتیبان به عنوان طبقه بندی کننده برای طبقه بندی خودکار OSA و CSA استفاده شد. از ۲۹ مورد پلی سومونوگرافی شبانه، ۲۳ مورد در مرحله آموزش و ۶ مورد برای آزمون مورد استفاده قرار گرفتند. طبقه بندی بر روی بخش‌های ۵ ثانیه‌ای سیگنال ECG دوره^۲ به دوره انجام شد و رویدادها با ترکیب دوره‌های طبقه بندی شده شناسایی شدند. تجزیه و تحلیل بسته‌های موجک در روش پیشنهادی برای استخراج ویژگی استفاده شد. نتایج نشان دادند که الگوریتم پیشنهادی در طبقه‌بندی CSA و CSA با ویژگی‌های بسته موجک (دقت ۹۱ درصد، حساسیت ۸۸,۱۴ درصد و ویژگی ۹۱,۱۱ درصد) نسبت به ویژگی‌های سنتی مبتنی بر تجزیه موجک (دقت ۸۳,۷۹ درصد، حساسیت ۸۹,۱۸ درصد و ویژگی ۸۳,۵۹ درصد) عملکرد بهتری داشتند. استفاده از ویژگی‌های بسته موجک منجر به کاهش ۴۵٪ هشدار نادرست (تشخیص CSA به عنوان CSA) شد [۲۰].

مطالعه‌ای دیگر تحت عنوان تمایز آپنه انسدادی از آپنه مرکزی در ویدیوی مادون قرمز^۳ (IR) خواب با استفاده از یادگیری عمیق (۲۰۲۰) انجام شد که هدف این مطالعه ایجاد یک روش غیر تماسی برای تمایز بین این دو نوع آپنه بود. برای این مطالعه داده‌های خواب شبانه ۴۲ شرکت کننده جمع آوری شد. پلی سومونوگرافی کامل یک شبه برای تشخیص آپنه خواب در دو اتاق جداگانه ثبت شده بود و علاوه بر این، یک دوربین مادون قرمز در حدود ۱,۴ متر بالای تخت نصب شده بود. همزمان و همگام با PSG، ویدئوهای مادون قرمز از نمای بالای سر با ۳۰ فریم بر ثانیه ضبط شدند. رزولوشن 480×480 قسمت بالایی بدن (سر، سینه و شکم) را با جزئیات کافی به تصویر کشید. آپنه‌های انسدادی و مرکزی توسط ۳ فرد آموزش دیده بر اساس سیگنال پلتیسموگرافی القای تنفسی^۴ قفسه سینه، شکم، مجموع حرکت قفسه سینه و شکم، فشار بینی و اشباع اکسیژن، با پیروی از دستورالعمل آکادمی پزشکی خواب آمریکا حاشیه نویسی شدند. ویدئوهای مادون قرمز ثبت شده از ۳۰ هرتز به ۲ هرتز کاهش یافت تا هزینه محاسباتی کاهش یابد. از آنجایی که هر آپنه حداقل ۱۰ ثانیه طول می‌کشد، نرخ نمونه برداری ۲ فریم در ثانیه به حداقل ۲۰ فریم تصویر در هر رویداد تبدیل شد. پنج الگوریتم مختلف مبتنی بر بینایی کامپیوتر برای پردازش داده‌های ویدئویی مادون قرمز برای ردیابی و تجزیه و تحلیل حرکات بدن برای تمایز این دو نوع آپنه استفاده شدند. در دو روش اول، از طبقه بندی کننده‌های نظارت شده^۵ برای پردازش اطلاعات استفاده شد. در سه روش باقیمانده، یک شبکه عصبی کانولوشن برای استخراج ویژگی‌ها و تشخیص OA از CA طراحی شد. مدل با بهترین عملکرد، یک مدل CNN سه بعدی بود که برای تجزیه و تحلیل توالی

¹ wavelet packet

² epoch

³ infrared

⁴ respiratory inductance plethysmography

⁵ supervised classifiers

تصاویر جریان نوری در طول هر آپنه آموزش داده شد و به دقت ۹۵٪ و امتیاز F1 در تمایز OA در مقابل CA رسید [۲۱].

۲-۲ طبقه‌بندی سه کلاسه

در این قسمت، مقالات مربوط به طبقه‌بندی سه کلاس مورد بررسی قرار می‌گیرند که این طبقه‌بندی به طور کلی به سه حالت آپنه خفیف-آپنه شدید-نرمال، آپنه انسدادی-آپنه مرکزی-آپنه مختلط و نرمال-آپنه مرکزی-آپنه انسدادی تقسیم می‌شود.

۱-۲-۲ طبقه‌بندی سه کلاسه آپنه خفیف، آپنه شدید و نرمال

در سال ۲۰۱۷ مطالعه‌ای انجام شد که در آن یک سیستم خودکار از HRV و سیگنال‌های تنفسی مشتق شده از ECG برای تشخیص آپنه و از K نزدیک ترین همسایه^۱ (KNN) برای طبقه‌بندی آن استفاده کرد. ثبت‌های ECG مورد استفاده برای آموزش و آزمون از دو پایگاه داده جمع آوری شده بود که پایگاه داده اول شامل ۱۲ ثبت و پایگاه داده دوم شامل ۳۵ ثبت پلی سومنوگرافی تمام شب از افراد واقعی بودند. هر کدام از این پایگاه‌های داده به ترتیب برای آموزش و آزمون مدل مورد استفاده قرار گرفتند. در ابتدا ثبت‌های EDR به قسمت‌های یک دقیقه‌ای تقسیم و سپس پیک‌های R تشخیص داده شدند و بعد از آن HRV و محاسبه شدند. برای دستیابی به بهترین نتایج ممکن، از روش انتخاب ویژگی مبتنی بر بسته‌بندی^۲ استفاده شد که از دقت طبقه‌بندی کننده به عنوان یک معیار ارزیابی استفاده می‌کرد. همینطور پارامترهای بهینه برای طبقه‌بندی کننده‌ها قبل از فرآیند آموزش محاسبه شدند. در روند آموزش یک تکنیک اعتبارسنجی متقابل^۳ ۱۰ برابری استفاده شد و عملکرد طبقه‌بندی کننده‌های آموزش‌دیده با ارجاع به پایگاه داده دوم مورد ارزیابی قرار گرفت. ثبت‌ها به سه دسته به شرح زیر طبقه‌بندی شدند:

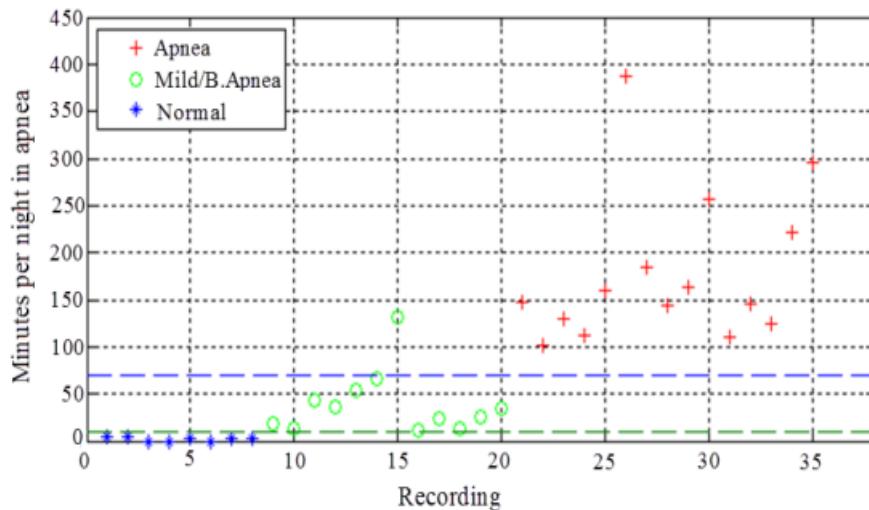
کلاس A (آپنه): ثبت با $AHI > 15$ که این کلاس شامل ۱۵ فرد بود، کلاس B (آپنه خفیف / مرزی): ثبت با $5 < AHI < 15$ که این کلاس شامل ۱۲ فرد بود و کلاس C (نرمال): ثبت با $AHI < 5$ که این کلاس شامل ۸ فرد بود. طبقه‌بندی در مجموعه داده آزمون، با به دست آوردن دقیقه‌های اختصاص داده شده به آپنه و اعمال

¹ k-nearest neighbor

² wrapper

³ cross-validation

آستانه های لازم انجام شد. تفکیک کلاس به دست آمده توسط طبقه بندی کننده KNN بر اساس دقیقه در شب در شکل ۱-۲ نشان داده شده است.



شکل ۱-۲. تفکیک کلاس بر اساس دقیقه در شب [۱۶].

طبقه بندی کننده KNN با جدا کردن موفقیت‌آمیز ۱۰۰ درصد ثبت های آپنه از ثبت های عادی، دقت، حساسیت و اختصاصیت بالاتری را در طبقه بندی به دست آورده بود. تازگی و اهمیت این مطالعه استفاده تنها از پارامترهای حوزه زمانی HRV و EDR به دست آمده از ثبت های ECG تک کanal از دو پایگاه داده آپنه متفاوت بود. سایر مدل ها عملکرد طبقه بندی ضعیف تری داشتند. برای مثال، جداسازی افراد نرمال از آپنه با دقت ۹۷,۱ درصد توسط پرسپترون چند لایه^۱ (MLP) و ماشین بردار پشتیبان^۲ (SVM) و ۸۶,۱ درصد توسط درخت تصمیم^۳ C4.5 به دست آمد. نتایج عملکردی طبقه بندی کننده ها در مجموعه داده های آزمون به ازای هر کلاس در جدول ۳-۲ نشان داده شده است.

با استفاده از آستانه ها برای خروجی مدل با KNN، دقت پیش‌بینی کلی ۹۷,۱۴ درصد برای ۳۴ از ۳۵ مورد از مجموعه داده آزمون به دست آمد. با توجه به نتایج به دست آمده، طبقه بندی کننده KNN انتخاب خوبی برای طبقه بندی آپنه مبتنی بر ECG تعیین شد [۱۶].

^۱ Multilayer perceptron

^۲ support vector machine

^۳ Decision tree

جدول ۳-۲ مقایسه عملکرد طبقه‌بندی کننده‌ها در مجموعه داده‌های آزمون در هر کلاس [۱۶].

کلاس	طبقه بندی کننده	دقت	حساسیت	اختصاصلیت
کلاس A	KNN	97.14	100	95
	MLP	94.29	100	90
	SVM	85.71	93.33	80
	C4.5 DT	82.86	66.67	95
	Average	90	90	90
کلاس B	KNN	97.14	91.67	100
	MLP	91.43	75	100
	SVM	82.86	66.67	91.30
	C4.5 DT	80	75	82.61
	Average	87.86	77.08	93.48
کلاس C	KNN	100	100	100
	MLP	100	97.14	88.89
	SVM	91.30	97.14	100
	C4.5 DT	82.61	86.11	77.78
	Average	93.48	95.10	91.67

۲-۲-۲ طبقه‌بندی سه کلاسه نرمال، آپنه انسدادی و آپنه مرکزی

در سال ۲۰۱۸ مطالعه‌ای به منظور تجزیه و تحلیل ویژگی‌های استخراج شده از دوره‌های EEG توسط تجزیه موجک گسسته و تبدیل هیلبرت^۱ (HT) برای تشخیص آپنه خواب انجام شد. علاوه بر این، ۳۰ ویژگی انتخاب شده در طبقه‌بندی خودکار تنفس نرمال و آپنه انسدادی و مرکزی توسط یک شبکه عصبی پیش‌خور^۲ با لایه پنهان استفاده شد. مراحل انجام شده در این تحقیق به منظور طبقه‌بندی خودکار آپنه خواب و هیپوپنه به ترتیب تهیه پایگاه داده، پیش‌پردازش سیگنال، استخراج و انتخاب ویژگی و طبقه‌بندی بودند. داده‌های موجود در پایگاه داده فیزیونت، که در کلینیک اختلالات خواب بیمارستان دانشگاه سنت وینسنت در دوبلین جمع‌آوری شده و شامل ثبت‌های پلی‌سومنوگرافی تمام شب و شامل سیگنال‌های EEG از دو کانال C4-A1 و C3-A2 از ۲۵ بیمار (۴ زن و ۲۱ مرد) بودند، در این کار استفاده شدند. پایگاه داده نهایی مورد استفاده در این اثر بالغ بر ۱۳۲۰ دوره بود که به طور تصادفی به مجموعه‌های آموزش (۹۲۴ ایپاک)، اعتبار سنجی و آزمون (۱۹۸ ایپاک) تقسیم شدند. تبدیل موجک گسسته^۳ (DWT) یک روش تجزیه و تحلیل زمان-فرکانس است که امکان تحلیل سیگنال‌های غیر ثابت را فراهم می‌کند و اغلب برای مطالعه EEG استفاده می‌شود. با در نظر گرفتن فرکانس نمونه برداری (۱۲۸ هرتز) و محدوده فرکانس امواج مغزی، در این مطالعه

¹ Hilbert transform

^۲ feedforward neural network

^۳ Discrete Wavelet Transform

از ۴ سطح تجزیه استفاده شد که منجر به زیر باندهای زیر شد: D1 (۳۲-۶۴ هرتز)، D2 (۱۶-۳۲ هرتز)، D3 (۸-۱۶ هرتز)، D4 (۴-۸ هرتز) و A4 (۰-۴ هرتز)، به ترتیب مشابه محدوده امواج گاما، بتا، آلفا، تتا و دلتا. بردار ویژگی^۱ (FV) هر یک از سیگنال‌های مغزی با محاسبه ۵ شاخص آماری (میانگین، انحراف معیار، چولگی، کشیدگی و میانه) مشخص شد. در پایان مجموعه بردارهای ویژگی (به طور جداگانه برای هر کلاس) به ۳ قسمت آموزش، اعتبارسنجی و آزمون تقسیم شدند و انتخاب ویژگی در مجموعه آموزش انجام شد. ابتدا، تجزیه و تحلیل واریانس^۲ (ANOVA) (روشی برای تعیین مشاهده تغییرپذیری در یک ویژگی مشخص ناشی از منابع مختلف) برای رد ویژگی‌هایی که بین هیچ یک از کلاس‌ها در سطح معنی‌داری ($p=0,05$) تفاوت قائل نمی‌شوند استفاده شد. سپس از تحلیل رگرسیون چند متغیره^۳ برای رد ویژگی‌هایی که تقریباً به طور خطی به یکدیگر وابسته بودند، استفاده شد. شبکه‌ی عصبی مصنوعی^۴ (ANN) به طور گسترده در مسائل طبقه‌بندی، همچنین هنگام تجزیه و تحلیل سیگنال EEG استفاده می‌شوند. ساختار کلی یک شبکه‌ی عصبی مصنوعی پیشخور^۵ (FFNN) از سه بخش اصلی تشکیل شده است: لایه ورودی، یک یا چند لایه پنهان و لایه خروجی. در نهایت از یک FFNN با یک لایه ورودی، دو لایه پنهان با نورون‌هایی که باتابع انتقال log-sigmoid مشخص می‌شوند و لایه خروجی با ۳ گره خطی (که نشان‌دهنده کلاس‌های موردنظر است) به عنوان طبقه‌بندی کننده استفاده شد. ماتریس درهم ریختگی^۶ مورد استفاده برای ارزیابی این طبقه‌بندی کننده در جدول ۴-۲ نشان داده شده است.

جدول ۴-۲ ماتریس درهم ریختگی برای مجموعه آزمون [۲۲].

پیش‌بینی (خرجی طبقه بند)				برچسب
صحت	آپنه مرکزی	آپنه انسدادی	تنفس نرمال	واقعی
۷۱,۲۱٪	۱۰	۹	۴۷	تنفس نرمال
۸۶,۳۶٪	۶	۵۷	۳	آپنه انسدادی
۷۴,۲۴٪	۴۹	۱۳	۴	آپنه مرکزی
۷۷,۲۷٪	صحت کلی			

ترکیب DWT و HT مورد استفاده برای استخراج ویژگی‌ها، امکان انتخاب نهایی ویژگی‌های متمایز و طبقه‌بندی OSA، CSA و تنفس نرمال را با دقیقت ۷۳,۹٪ برای مجموعه آموزش و ۷۷,۳٪ برای مجموعه آزمون فراهم کرد [۲۲].

^۱ feature vector

^۲ analysis of variance

^۳ multivariate regression

^۴ Artificial neural network

^۵ Feedforward Artificial neural network

^۶ feedforward neural network

مطالعه دیگری در سال ۲۰۲۱ برای تشخیص خودکار رویدادهای آپنه خواب با استفاده از ویژگی‌های سیگنال‌های EEG به منظور دسته‌بندی رویدادهای آپنه خواب انسدادی، رویدادهای آپنه خواب مرکزی و رویدادهای تنفس نرمال پیشنهاد شد. در این مطالعه، از داده‌های EEG ۳۰ فرد مختلف برای تشخیص و طبقه‌بندی آپنه خواب و همچنین تجزیه و تحلیل عملکرد طبقه‌بندی کننده استفاده شد. مجموعه داده شامل ۳۴۵۹ دوره بود که از این تعداد ۱۲۲۹ دوره رویدادهای آپنه انسدادی، ۸۱۲ دوره رویدادهای آپنه مرکزی و ۱۴۱۸ دوره رویدادهای تنفس نرمال بود. با استفاده از یک فیلتر باترورث^۱ میانگذر با پاسخ فرکانسی بینهایت، سیگنال‌های الکتروانسفالوگرام C3-A2 و C4-A1 به پنج زیرباند تقسیم شدند. سپس، آنتروپی نمونه^۲ و واریانس هر زیرباند استخراج شد. روش تجزیه و تحلیل ترکیب همسایه^۳ (NCA) برای انتخاب ویژگی استفاده شد و نتایج به عنوان ضرایب ورودی طبقه‌بندی کننده‌های جنگل تصادفی^۴، K نزدیک‌ترین همسایه و ماشین بردار پشتیبان استفاده شدند. پس از یک اعتبارسنجی متقابل ۱۰ برابری، مشخص شد که میانگین میزان دقت ۸۸,۹۹ و ۸۴,۸۵ و ۹۵,۲۴ درصد بود. جدول ۵-۲ عملکرد مربوط به هر دسته OSA، CSA و تنفس نرمال به ترتیب ۸۰,۴۳، ۸۸,۷۱ و ۹۵,۲۴ درصد بود. از جدول ۵-۲ مشاهده می‌شود که از بین سه طبقه‌بندی کننده، آپنه مرکزی و تنفس طبیعی نشان می‌دهد. جنگل تصادفی دارای بالاترین دقت طبقه‌بندی را دارد.

جدول ۵-۲ نتایج مربوط به هر طبقه‌بندی کننده [۲۳].

دقت				میانگین صحت	طبقه بند
تنفس نرمال	آپنه مرکزی	آپنه انسدادی			
۹۲,۲۴٪	۷۶,۹۲٪	۷۷,۲۱٪	۸۵,۵۱٪	KNN	
۸۸,۷۱٪	۵۵,۲۲٪	۵۹,۲۱٪	۶۸,۷٪	SVM	
۹۵,۲۴٪	۸۴,۸۵٪	۸۰,۴۳٪	۸۸,۹۹٪	RF	

با توجه به جدول ۶-۲ که عملکرد کلی هر طبقه‌بندی کننده را نشان می‌دهد، جنگل تصادفی بالاترین دقت طبقه‌بندی را داشت. هم چنین مشاهده شد که طبقه‌بندی کننده جنگل تصادفی نسبت به دو طبقه‌بندی کننده دیگر، معیار یادآوری، دقت، امتیاز f1 و ضریب کاپا^۵ بهتری دارد و بهترین عملکرد طبقه‌بندی را داشت [۲۳].

^۱ Butterworth^۲ sample entropy^۳ neighbor composition analysis^۴ Random forest^۵ kappa coefficient

جدول ۲-۶ نتایج سه طبقه بندی کننده شامل دقت، یادآوری، امتیاز F1 و ضریب کاپا [۲۳].

طبقه بند	یادآوری	دقت	امتیاز F1	کاپا
KNN	۰,۸۱	۰,۸۲	۰,۸۲	۰,۸۳
SVM	۰,۶۷	۰,۶۸	۰,۶۷	۰,۵۴
RF	۰,۸۶	۰,۸۹	۰,۸۷	۰,۸۵

۳-۲-۲ طبقه بندی سه کلاسه آپنه مرکزی-آپنه انسدادی-آپنه مختلط

در سال ۲۰۰۵ مطالعه‌ای تحت عنوان روشی جدید برای طبقه بندی آپنه خواب در سه کلاس آپنه انسدادی، آپنه مرکزی و آپنه مختلط با استفاده از موجک و شبکه‌های عصبی پیشخور انجام شد. ورودی‌های شبکه عصبی اولین ضرایب جزئیات سطح ۵ بودند که از تبدیل موجک گستته نمونه‌ها (که قبلاً به عنوان آپنه تشخیص داده شده بودند) در سیگنال تلاش قفسه سینه به دست آمده بودند. به منظور آموزش و آزمون سیستم‌ها، از ۱۲۰ رویداد مربوط به شش بیمار مختلف استفاده شد. سیگنال‌ها با فرکانس ۱۲,۵ هرتز نمونه برداری و آپنه‌های موجود در این ثبت‌ها توسط یک متخصص در این زمینه طبقه بندی شدند (۲۱۷ آپنه انسدادی، ۴۰ آپنه مرکزی و ۸۲ آپنه مختلط). برای به دست آوردن یک مجموعه آموزش متعادل، ۱۲۰ آپنه (۴۰ آپنه از هر کلاس)، انتخاب شدند. با توجه به حجم کم مجموعه آموزشی، به منظور تخمین میزان خطای واقعی طبقه‌بندی کننده، از اعتبارسنجی متقابل ۱۰ برابر استفاده شد. طرح کلی طبقه بندی کننده آپنه خودکار ارائه شده در این مقاله از سه مرحله تشکیل شده است. ابتدا یک ماژول تشخیص، سیگنال جریان‌ها را دریافت می‌کند و محل هر آپنه را مشخص می‌کند. متعاقباً، یک ماژول انتخابگر نمونه، نمونه‌های مربوط به آپنه‌ها را در سیگنال تلاش قفسه سینه انتخاب می‌کند. پس از آن، یک مرحله پیش پردازش، این نمونه‌های خام را دریافت می‌کند و ویژگی‌هایی را استخراج می‌کند که به عنوان ورودی به طبقه بندی کننده داده می‌شوند. یک تبدیل موجک گستته به عنوان مرحله پیش پردازش برای کاهش و تثبیت تعداد ورودی‌های طبقه بندی کننده استفاده شد. در نهایت، ماژول طبقه بندی، آپنه تشخیص داده شده را به عنوان مرکزی، انسدادی یا مختلط برچسب گذاری کرد. سیستم به کار گرفته شده برای ماژول طبقه بندی، یک شبکه عصبی مصنوعی پیشخور با یک لایه پنهان بود. نتایج ارائه شده در این کار با بیش از ۱۰۰ شبیه‌سازی مختلف به طور میانگین محاسبه شد و از روش مقایسه چندگانه برای انتخاب مدل استفاده شد. روش انتخاب شده در نهایت مبتنی بر یک شبکه عصبی پیشخور آموزش‌دیده با استفاده از چارچوب بیزین^۱ و یک تابع خطای آنتروپی متقابل بود. میانگین دقت طبقه بندی به دست آمده برای مجموعه آزمون $83,78 \pm 1,90$ درصد بود. ماتریس درهم ریختگی مربوطه در جدول ۲-۲ نشان داده شده است. همانطور که مشاهده می‌شود، اختلافات

^۱ Bayesian framework

اصلی بین کلاس انسدادی و مختلط و بین کلاس مرکزی و مختلط ظاهر می شود. این یک نتیجه منطقی است زیرا کلاس مختلط ترکیبی از دو کلاس دیگر است.

جدول ۷-۲ ماتریس درهم ریختگی [۲۴].

خروجی شبکه عصبی			برچسب
مرکزی	مختلط	انسدادی	واقعی
۱,۵۴	۶,۱	۳۲,۳۶	انسدادی
۴,۹	۳۲,۱۹	۲,۹۱	مختلط
۳۵,۹۸	۲,۶۲	۱,۴	مرکزی

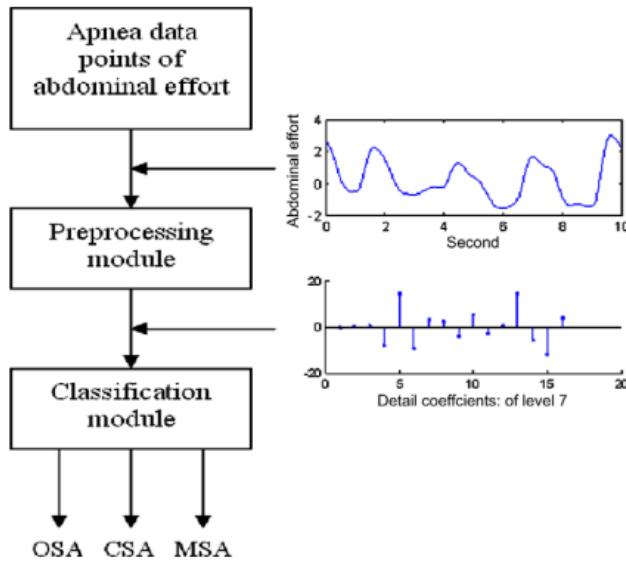
همچنین میانگین دقت و فاصله اطمینان به دست آمده برای هر یک از کلاس‌ها $80,90 \pm 2,53$ درصد (انسدادی)، $80,47 \pm 3,56$ درصد (مختلط) و $89,98 \pm 2,71$ درصد (مرکزی) بود [۲۴].

مطالعه دیگری در سال ۲۰۱۰، به منظور طبقه بندی آپنه خواب با استفاده از تبدیل موجک و شبکه‌های عصبی مصنوعی انجام شد که در این مطالعه سیگنال‌ها از ۲۱ بیمار مبتلا به آپنه خواب به دست آمده بودند. سیگنال‌ها در قسمت‌های ۸ ساعته در حالی که بیمار در طول شب خواب بود از طریق پلی سومنوگرافی ثبت شده بودند و سیگنال‌های شکمی با فرکانس ۱۲۸ هرتز نمونه برداری و همین طورآپنه‌های موجود در این ثبت‌ها توسط یک متخصص در این زمینه طبقه بندی شده بودند (۴۵۰ آپنه انسدادی، ۱۲۰ آپنه مرکزی و ۲۲۰ آپنه مختلط). برای به دست آوردن یک مجموعه آموزش/آزمون متعادل، ۳۶۰ آپنه (۱۲۰ از هر کلاس) انتخاب شد. با استفاده از تبدیل موجک، هر سیگنال تلاش شکمی به زیر باندهای خود جدا شد. یک موجک با عمق ۷ (سطح) طراحی شد. در این مطالعه ابتدا داده‌های شکمی به ضرایب موجک تقریب و جزیيات تقسیم و دوباره این ضرایب موجک به ضرایب موجک زیر تقریب و زیر جزیيات تقسیم شدند. این تقسیم‌بندی تا سطح ۷ ادامه یافت، به طوری که ضرایب جزئیات در سطح ۷ به عنوان ورودی شبکه عصبی داده شد. تبدیل موجک گستته به عنوان یک مرحله پیش پردازش برای کاهش و تثبیت تعداد ورودی‌های طبقه بندی کننده استفاده شد. در شکل ۲-۲ ساختار کلی روش طبقه بندی پیشنهادی نشان داده شده است.

مدل شبکه‌ی عصبی چند لایه^۱ که در این مطالعه استفاده شد دارای یک لایه ورودی با ۱۶ گره، یک لایه پنهان دارای ۱۵ گره و یک لایه خروجی با ۳ گره بود. شبکه آموزش دیده با سیگنال‌های تلاش شکمی برای هر سه کلاس مورد بررسی قرار گرفت. خروجی‌های شبکه مربوطه برای ضرایب مومنتوم^۲ متفاوت در جدول ۸-۲ نشان داده شده است.

¹ multilayer neural networks

² momentum coefficients



شکل ۲-۲ ساختار روش طبقه بندی پیشنهادی [۲۵].

جدول ۸-۲ عملکرد طبقه بندی شبکه عصبی مصنوعی برای (الف) ضریب مومنتوم ۰,۹۵، (ب) ضریب مومنتوم ۰,۷۵ و (ج) ضریب مومنتوم ۰,۵۰ [۲۵].

خروجی شبکه عصبی			واقعی
آپنه خواب انسدادی	آپنه خواب مرکزی	آپنه خواب مختلط	
(الف)			
%۶,۵۰	%۲,۴۶	%۷۴,۹۹	آپنه خواب انسدادی
%۲۲,۶۴	%۹۴,۷	%۷,۰۱	آپنه خواب مرکزی
%۶۶,۸۷	%۱۸,۳۲	%۱۵,۱۲	آپنه خواب مختلط
(ب)			
%۱۲,۴۱	%۲,۳۲	%۷۳,۶۷	آپنه خواب انسدادی
%۲۴,۶۷	%۹۴,۴۳	%۹,۳۰	آپنه خواب مرکزی
%۶۶,۰۰	%۱۶,۴۲	%۱۹,۲۴	آپنه خواب مختلط
(ج)			
%۹,۴۷	%۰,۵۲	%۷۱,۶۱	آپنه خواب انسدادی
%۲۵,۲۱	%۹۳,۵۷	%۱۵,۳۰	آپنه خواب مرکزی
%۶۵,۶۰	%۱۳,۵۹	%۲۱,۴۴	آپنه خواب مختلط

دقت کلی به دست آمده برای ضرایب تکانه^۱ ۰,۹۵، ۰,۷۵ و ۰,۵۰ به ترتیب ۷۸,۰۳، ۷۸,۸۵ و ۷۶,۹۳ درصد بود. همچنین میانگین دقت و فاصله اطمینان به دست آمده برای آپنه انسدادی ۷۳/۴۲ درصد، آپنه مرکزی ۹۴/۲۳ درصد و آپنه مختلط ۶۶/۱۶ درصد گزارش شد [۲۵].

^۱ momentum

مدلی دیگر نیز برای طبقه بندی آپنه خواب به یکی از سه نوع انسدادی، مرکزی و مختلط در مطالعه ای در سال ۲۰۱۲ ارائه شد. این مدل توسط ترکیبی از شبکه های عصبی مصنوعی شکل می گرفت که ورودی های آنها ضرایب به دست آمده از تجزیه موجک گستته اعمال شده بر روی نمونه های خام آپنه در سیگنال تلاش قفسه سینه بودند. سیگنال جریان هوای بینی با استفاده از ترمیستور و سیگنال تلاش قفسه سینه با استفاده از نوارهای سینه ای-شکمی اندازه گیری و هر دو سیگنال با فرکانس ۱۲,۵ هرتز نمونه برداری شدند. سپس، توسط یک متخصص هر رویداد آپنه در یکی از سه کلاس برچسب گذاری و تجزیه و تحلیل شد. در مجموع ۳۳۹ آپنه وجود داشت که ۲۱۷ مورد انسدادی، ۴۰ آپنه مرکزی و ۸۲ مورد مختلط بودند. برای به دست آوردن یک مجموعه آموزش متعادل، ۱۲۰ آپنه (۴۰ آپنه از هر کلاس) انتخاب شد. موجک گستته روی نمونه های خام بخش های سیگنال تلاش قفسه سینه که در آن محل آپنه ها مشخص شده بودند، اعمال شد. در این روش، استفاده از موجک به عنوان یک تکنیک پیش پردازش منجر به یک سیستم ساده تر، کاهش و ثبیت تعداد ورودی های طبقه بندی کننده می شد. حذف ویژگی بازگشتی ماشین بردار پشتیبان^۱ (SVM) که یک تکنیک رتبه بندی ویژگی بود که از وزن چندین طبقه بندی کننده SVM، برای ایجاد رتبه بندی ویژگی ها استفاده می کرد، به کار گرفته شد. ضرایب ورودی بدست آمده برای هر شبکه با روش انتخاب ویژگی (حذف ویژگی بازگشتی ماشین بردار پشتیبان) تعیین شد. میزان خطای واقعی با استفاده از اعتبارسنجی متقابل ۱۰ برابری برآورد شد. میانگین دقت آزمون بدست آمده 0.79 ± 0.27 درصد و دقت تشخیص آپنه برای هر کلاس ۹۴/۶۲ درصد (انسدادی)، ۹۵/۴۷ درصد (مرکزی) و ۹۰/۴۵ درصد (مختلط) بود.^[۲۶]

در سال ۲۰۱۳ مطالعه ای برای طبقه بندی آپنه خواب با استفاده از تبدیل موجک متقطع انجام شد. روش توسعه یافته سیگنال های جریان هوای تلاش قفسه سینه را به عنوان ورودی گرفته، سپس به زمان-فرکانس و فاز تبدیل کرده تا اطلاعات همبستگی بین دو سیگنال را در شرایط آپنه مختلف استخراج کند. یک گروه ۲۰ نفری (۱۵ مرد و ۵ زن) مشکوک به آپنه خواب در این مطالعه وارد شدند. به دلیل وجود آرتیفیکت های ناشی از حرکات بیمار یا حسگر سیگنال های خام جمع آوری شده از PSG، سیگنال های تنفسی با فیلتر پایین گذر با ترورث مرتبه ۱۰ با فرکانس قطع ۸,۰ هرتز برای حذف آرتیفیکت های حرکتی حسگر/ بیمار فیلتر شدند. دامنه تمامی سیگنال ها در بازه ۰ تا ۱ بر اساس حداکثر دامنه تنفس سوژه نرمال سازی شدند. فرآیند تشخیص آپنه به دو مرحله تشخیص رویداد و طبقه بندی نوع آپنه تقسیم می شد. از این رو، برای تشخیص حوادث آپنه، یک پنجه متحرک بدون همپوشانی به عرض ۱۰ ثانیه در نظر گرفته شد. وضوح تشخیص برابر طول پنجه یعنی ۱,۰ هرتز تعیین شد. به دلیل اینکه موجک متقابل^۲ ضرایب زیادی را در اندازه و فاز برمی گرداند، ممکن است مدیریت این تعداد زیاد ضرایب توسط برخی از سیستم های خودکار قابل حمل دشوار باشد، بنابراین برای کاهش محاسبات و پیچیدگی، تکنیک کاهش ابعاد مبتنی بر تجزیه و تحلیل مؤلفه اصلی هسته

¹ recursive feature elimination

² cross-wavelet

استفاده شد. میانگین صحت طبقه‌بندی به دست آمده با استفاده از تکنیک آستانه گذاری ساده (KPCA)^۱ درصد و این مقدار برای کلاس انسدادی $85/2$ درصد، مرکزی $86/4$ درصد و مختلط $83/6$ درصد بود. نتایج مربوط به این مطالعه نشان داد که موحک متقابل پرای تشخیص آینه مفید است [۲۷].

به منظور طبقه بندی انواع آپنه و شدت آن در سال ۲۰۲۱ مطالعه ای انجام شد که از سیگنال های EEG برچسب گذاری شده از ۲۵ بیمار آپنه استفاده شد و دو طبقه بندی کننده مجزا با استفاده از دامنه فرکانس EEG و ویژگی های غیر خطی برای طبقه بندی باینری شدت آپنه و طبقه بندی چند کلاسه ای انواع آپنه و هیپوپنه که شامل شش کلاس آپنه انسدادی، آپنه مرکزی، آپنه مختلط، هیپوپنه انسدادی، هیپوپنه مرکزی و هیپوپنه مختلط بود، ساخته شد. در هر دو مسئله طبقه بندی، سه مدل یعنی ماشین بردار پشتیبان، تحلیل تشخیصی خطی^۲ (LDA) و بیز ساده^۳ (NB) ارزیابی و مقایسه شدند. نتایج نشان داد که مدل SVM، در هر دو مسئله طبقه بندی بهترین عملکرد را داشت و به دقت بالاتر از سطح پایه رسید. مطابق جدول ۹-۲، عملکرد SVM در طبقه بندی باینری شدت آپنه قابل قبول بود (۷۶٪ دقت متوسط) اما مطابق جدول ۱۰-۲، در مورد طبقه بندی چند کلاسه انواع آپنه، طبقه بندی کننده SVM به عملکرد قابل قبولی برای همه انواع آپنه نرسید (۴۸٪ دقت متوسط) [۲۸].

جدول ۹-۲ نتایج عملکرد طبقه‌بندی پاینری شدت آپنه با سه مدل طبقه‌بندی کننده [۲۸].

جدول ۱۰-۲ نتایج عملکرد طیقه بندی انواع مختلف آینه خواب با سه مدل طیقه بندی کننده [۲۸].

ماشین بردار پشتیبان	تجزیه و تحلیل تفکیک خطی	بیز ساده	طبقه بندی چند کلاسه انواع آپنه
---------------------	-------------------------	----------	--------------------------------

¹ kernel principal component analysis

Linear Discriminant analysis

³ Naive Bayes

آپنه مرکزی	آپنه مختلط	آپنه انسدادی	صحت
امتیاز F1	امتیاز F1	امتیاز F1	
یدآوری	یدآوری	یدآوری	دقت
دقت	دقت	دقت	امتیاز
F1	F1	F1	یدآوری
۰,۰۹۷۶	۰,۳۳۳۳	۰,۱۱۵۰۹	۰,۳۹۰۲
۰,۶۸۲۹	۰,۳۵۹۰	۰,۴۷۰۶	۰,۴۶۳۴
۰,۱۳۴۶	۰,۳۶۸۴	۰,۱۹۷۲	۰,۲۱۱۵
٪۳۸,۴۳	٪۴۳,۱۴	٪۴۸,۲۴	

فصل ۳ - روش تحقیق

۱-۳ مقدمه

در این فصل، ابتدا به معرفی و توضیح هر یک از پایگاه داده های استفاده شده در این پژوهش پرداخته شده و سپس مراحل پیش پردازش داده ها شرح داده می شود. سپس ویژگی های استخراج شده معرفی و روش کاهش ابعاد ویژگی بررسی می شود. در ادامه به چگونگی تقسیم مجموعه داده ها و ساختار شبکه عصبی پیشنهادی پرداخته شده و در انتها، هر یک از معیار های ارزیابی مورد استفاده در این پژوهش توضیح داده می شوند.

۲-۳ پایگاه داده

در این تحقیق از سه پایگاه داده ^۱ MIT-BIH polysomnographic، بانک داده خواب کشوری بیمارستان کودکان ^۲ (NCHSDB) و مطالعه خانواده کلیولند ^۳ (CFS) استفاده شده است که در ادامه به تشریح هر کدام پرداخته می شود.

۲-۱-۳ پایگاه داده ^۱ MIT-BIH polysomnographic

این پایگاه داده، شامل بیش از ۸۰ ساعت ثبت سیگنال های فیزیولوژیکی متعدد در طول خواب است که افراد در آزمایشگاه خواب بیمارستان بث اسرائیل بوستون ^۳ برای ارزیابی سندروم آپنه انسدادی مزمن خواب، و برای آزمون اثرات فشار هوایی مثبت مداوم، تحت نظر قرار گرفتند [۲۹].

در این پایگاه داده، همه ۱۶ نفر مرد بودند که محدوده سنی ۳۲ تا ۵۶ سال (میانگین سنی ۴۳ سال)، و وزن های ۸۹ تا ۱۵۲ کیلوگرم (میانگین وزن ۱۱۹ کیلوگرم) را داشتند. ثبت های slp01a و slp01b بخش هایی از پلی سومنوگرام یک فرد هستند که با فاصله ی حدود یک ساعت از هم جدا شده اند. ثبت های slpo2a و slp02b بخش هایی از پلی سومنوگرام فردی دیگر هستند که با فاصله ده دقیقه ای از هم جدا شده اند. ۱۴ ثبت دیگر همگی از افراد مختلف هستند؛ به عبارتی این مجموعه داده در مجموع ۱۸ ثبت از ۱۶ سوژه مختلف را در خود جای داده است که از دوفرد دوبار ثبت انجام شده است که دارای یک نام هستند اما در یک

¹ Nationwide Children's Hospital Sleep DataBank

² Cleveland Family Study

³ Boston's Beth Israel Hospital Sleep Laboratory

پسوند a و b تفاوت دارند. ثبت ها شامل سیگنال ECG، سیگنال فشار خون تهاجمی، سیگنال EEG، سیگنال تنفسی، سیگنال EOG و سیگنال EMG از چانه هستند. جدول ۱-۳ طول سیگنال و مقدار AHI هر ثبت را نشان می دهد.

هر ثبت شامل دو فایل برچسب گذاری^۱ است: فایل های .ecg. حاوی برچسب گذاری ضربان قلب و فایل های .st. حاوی برچسب گذاری مراحل خواب و آپنه هستند. برچسب های مربوط به هر رویداد در جدول ۲-۳ آورده شده است [۲۹].

جدول ۱-۳ اطلاعات ثبت های پایگاه داده MITBIH [۲۹]

AHI	طول (ساعت)	ثبت
۱۷	۲:۰۰	slp01a
۲۲,۳	۳:۰۰	slp01b
۳۴	۳:۰۰	slp02a
۲۲,۲	۲:۱۵	slp02b
۴۳	۶:۰۰	slp03
۵۹,۸	۶:۰۰	slp04
۳۰,۷	۶:۰۰	slp14
۵۳,۱	۶:۰۰	slp16
۲۲,۱	۵:۲۰	slp32
۱۰۰,۸	۵:۵۰	slp37
۶۰	۶:۳۰	slp41
۵	۶:۲۰	slp45
۴۶,۸	۶:۲۰	slp48
۵۵,۳	۴:۰۰	slp59
۵۹,۲	۵:۵۵	slp60
۴۱,۲	۶:۱۰	slp61
۶۵,۵	۳:۴۰	slp66
۰,۷	۱:۱۷	slp67x

¹ annotation

جدول ۲-۳ برچسب های رویدادها.

معنی	برچسب	معنی	برچسب
آپنه انسدادی	OA	بیداری	W
آپنه انسدادی با برانگیختگی	X	مرحله ۱ خواب	۱
آپنه مرکزی	CA	مرحله ۲ خواب	۲
آپنه مرکزی با برانگیختگی	CAA	مرحله ۳ خواب	۳
حرکت پا	L	مرحله ۴ خواب	۴
حرکت پا با برانگیختگی	LA	خواب REM	R
برانگیختگی نامشخص	A	هیپوپنه	H
زمان حرکت	MT	هیپوپنه با برانگیختگی	HA

نرخ نمونه برداری سیگنال ۲۵۰ هرتز می باشد و برچسب گذاری در هر ۳۰ ثانیه انجام شده است؛ بنابراین در هر ۳۰ ثانیه ۷۵۰۰ نمونه وجود دارد. این پایگاه داده به جای برچسب گذاری یک ایپاک به عنوان آپنه یا غیر آپنه، دارای چندین کلاس برای تعیین آپنه یا هیپوپنه بودن و همچنین انسدادی یا مرکزی بودن می باشد.

جدول ۳-۳ تعداد کل رویداد های آپنه مختلف مربوط به این مطالعه را نشان می دهد.

جدول ۳-۳ تعداد کل رویداد های آپنه پایگاه داده MITBIH.

نوع آپنه	انسدادی	مرکزی
تعداد	۳۹۹۴	۴۸۳

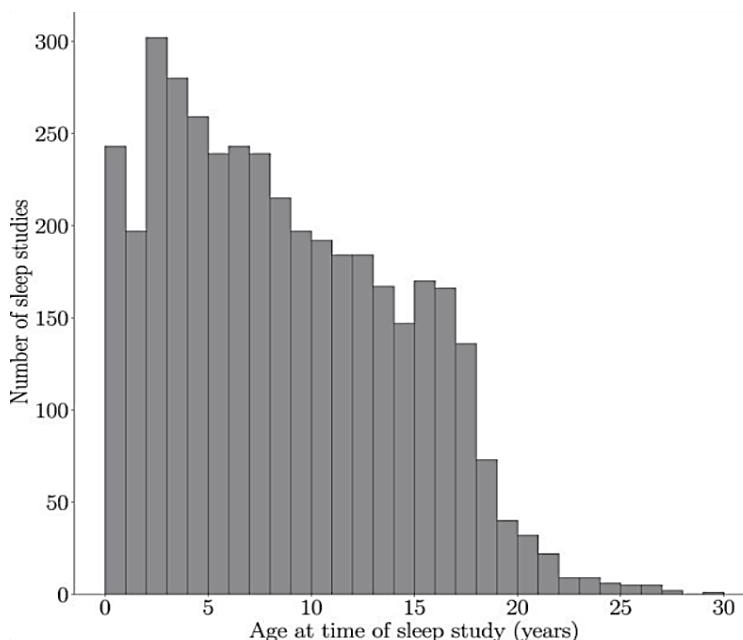
۲-۲-۳ بانک داده خواب کشوری بیمارستان کودکان (NCHSDB)

به منظور تسريع تحقیقات در مورد خواب کودکان و ارتباط آن با سلامتی، بانک داده خواب کشوری بیمارستان کودکان ایجاد شد که شامل ۳۹۸۴ مطالعه خواب می باشد که بر روی ۳۶۷۳ بیمار منحصر به فرد بین سال های ۲۰۱۷ و ۲۰۱۹ انجام شده است. از این تعداد، ۳۴۰۰ بیمار یک مطالعه خواب، ۲۳۸ بیمار دو مطالعه، و ۳۵ بیمار بیش از دو مطالعه (با حداقل ۵ مطالعه خواب برای یک بیمار) دارند. از نظر توزیع جنسیتی، ۲۰۶۸ نفر مرد و ۱۶۰۴ نفر زن بودند و جنسیت یک فرد مشخص نبود. جدول ۴-۳ توزیع نژادهای منحصر به فرد بیماران را نشان می دهد.

جدول ۴-۳ توزیع نژادی مربوط به ۳۶۷۳ فرد [۳۰].

درصد	تعداد	نژاد
۶۶,۲۴٪	۲۴۳۳	سفید پوست
۲۰,۰۹٪	۷۳۸	سیاه پوست یا آفریقایی
۷,۵۴٪	۲۷۷	چند نژادی
۲,۵۳٪	۹۳	آسیایی
۳,۵۹٪	۱۳۲	سایر و ناشناخته
۱۰۰٪	۳۶۷۳	کل

همانطور که در شکل ۱-۳ مشاهده می شود اکثر بیماران (۲۴۱۲) در مجموعه داده در زمان مطالعه خواب کمتر از ۱۰ سال سن داشتند.



شکل ۱-۳ توزیع سنی افراد شرکت کننده در زمان مطالعه خواب [۳۰].

داده های فیزیولوژیکی جمع آوری شده در طی یک مطالعه خواب شبانه شامل EEG برای شناسایی مراحل خواب، EMG فعالیت چانه برای کمک به شناسایی کاهش تون که در طول خواب حرکت چشم تند^۱ (REM) مشاهده می شود، EMG پا برای اندازه گیری حرکات پا، EOG برای شناسایی حرکات مشخصه چشم که در خواب REM مشاهده می شود، ECG برای نظارت بر ضربان و ریتم قلب، سنسورهای بینی و دهان برای اندازه گیری جریان هوا، کمربند قفسه سینه و شکم برای اندازه گیری حرکات قفسه سینه و شکم در طول تنفس که برای نشان دادن افزایش یا کاهش تلاش تنفسی مفید است، پالس اکسیمتری برای اندازه گیری اشباع اکسیژن خون و اندازه گیری دی اکسید کربن (CO₂) هوای بازدمی برای ارزیابی هیپوventیلاسیون^۲ می باشند.

¹ Rapid eye movement sleep² Hypoventilation

مطالعات خواب به صورت زمان واقعی^۱ توسط تکنسین ها در زمان مطالعه برچسب گذاری و پس از اتمام مطالعه توسط تکنسینی دیگر مرحله بندی و امتیازدهی شدند. برچسب گذاری های استفاده شده در این پایگاه داده شامل هر سه حالت مختلف آپنه انسدادی، مرکزی و مختلط بود. طول کل ثبت در این پایگاه داده به ۴۰۸۸۴ ساعت می رسد که حداقل طول مطالعه ۳ دقیقه، حداکثر ۱۶,۵ ساعت و میانگین آن ۱۰,۳ ساعت است. اکثر موارد ثبت شده (۳۲۰۴) با فرکانس نمونه برداری ۲۵۶ هرتز، ۵۸۱ مطالعه در ۴۰۰ هرتز و بقیه (۱۹۹) در ۵۱۲ هرتز نمونه برداری شده است [۳۰]. جدول ۵-۳ تعداد کل رویداد های آپنه مختلف مربوط به این مطالعه را نشان می دهد.

جدول ۵-۳ تعداد کل رویداد های آپنه پایگاه داده NCHSDB

نوع آپنه	انسدادی	مرکزی	مختلط
تعداد	۱۲۷۸۵	۶۱۰۴	۲۲۵۳

۳-۲-۳ مطالعه خانواده کلیولند (CFS)

مطالعه خانواده کلیولند بزرگترین مطالعه مبتنی بر خانواده در مورد آپنه خواب در سراسر جهان است که شامل ۲۲۸۴ فرد (۴۶٪ آفریقایی آمریکایی) از ۳۶۱ خانواده در یک دوره ۱۶ ساله است. این مطالعه در سال ۱۹۹۰ با هدف اولیه تعیین کمیت تجمع خانوادگی آپنه خواب آغاز شد. تمامی افراد که مبتلا به آپنه خواب تشخیص داده شده بودند، بستگان درجه یک، همسر و بستگان درجه دو در دسترس مورد مطالعه قرار گرفتند. هر بررسی، که در فواصل زمانی تقریباً ۴ ساله برگزار شد، شامل افراد جدید و همچنین بررسی های بعدی برای افرادی بود که قبل اثبات نام کرده بودند. برای سه بررسی اول، داده ها در خانه های شرکت کنندگان جمع آوری شد در حالی که آخرین بازدید در یک مرکز تحقیقات بالینی عمومی^۲ (GCRC) انجام شد. افراد در طول یک شب بررسی حداقل به مدت ۶ ساعت با ثبت حرارت بینی/دهانی^۳، امپدنس دیواره قفسه سینه، پالس اکسیمتری انگشت و ECG تحت نظر قرار گرفتند. وقایع تنفسی (آپنه یا هیپوپنه) به عنوان توقف یا کاهش جریان هوا یا امپدنس دیواره قفسه سینه به مدت ۱۰ ثانیه همراه با کاهش ۲,۵ درصدی اشباع اکسیژن از مقادیر پایه تعریف شد. پس از هر ثبت، رویداد ها توسط یک فرد متخصص برچسب گذاری شدند که برچسب های مربوط به آپنه خواب شامل تنفس طبیعی، آپنه انسدادی، آپنه مرکزی و آپنه مختلط بودند. شکل ۳ نمودار توزیع سنی شرکت کنندگان در زمان شروع مطالعه را نشان می دهد. جدول ۶-۳ نیز تعداد کل رویداد های آپنه مختلف مربوط به این مطالعه را نشان می دهد.

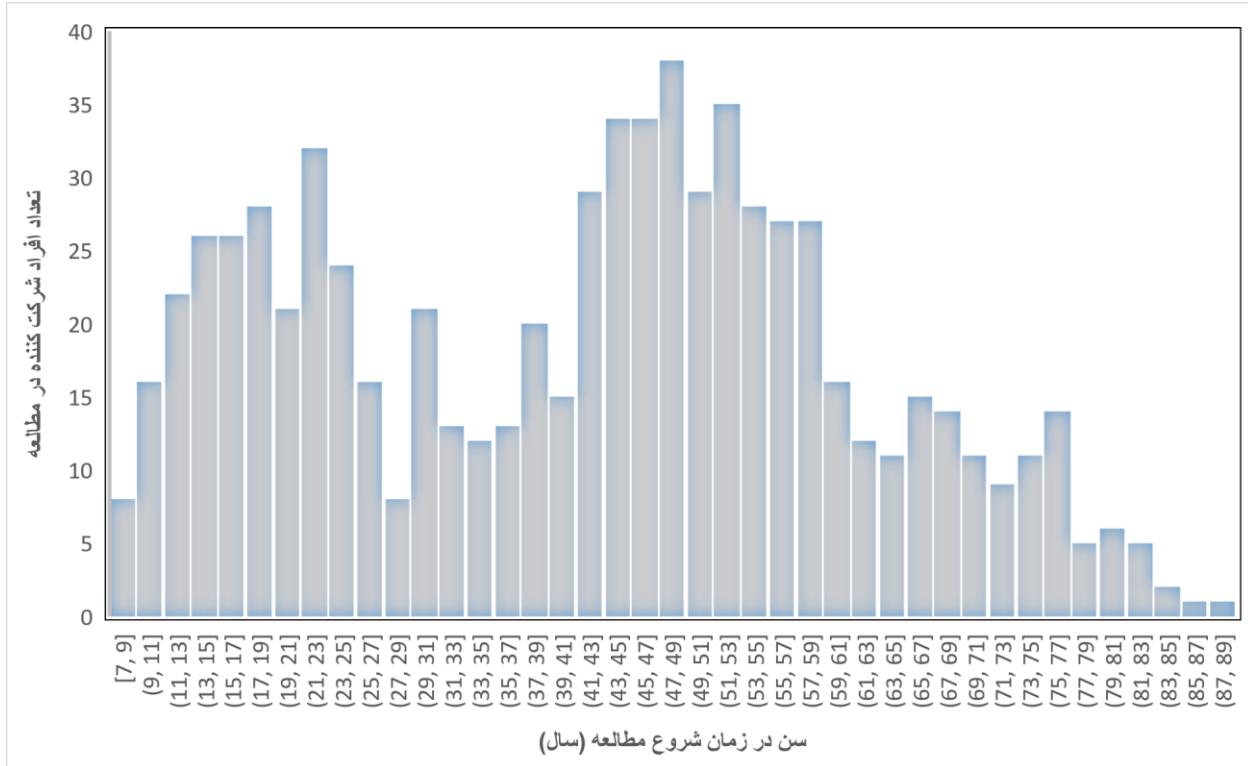
¹ Real time

² General clinical research center

³ Nasal/oral thermistry

جدول ۶-۳ تعداد کل رویداد های آپنه پایگاه داده CFS

مختلط	مرکزی	انسدادی	نوع آپنه
تعداد	۴۷۶۰	۳۲۴۱۰	تعداد



شکل ۳-۲ نمودار توزیع سنی افراد شرکت کننده در زمان شروع مطالعه.

۳-۳ پیش پردازش داده

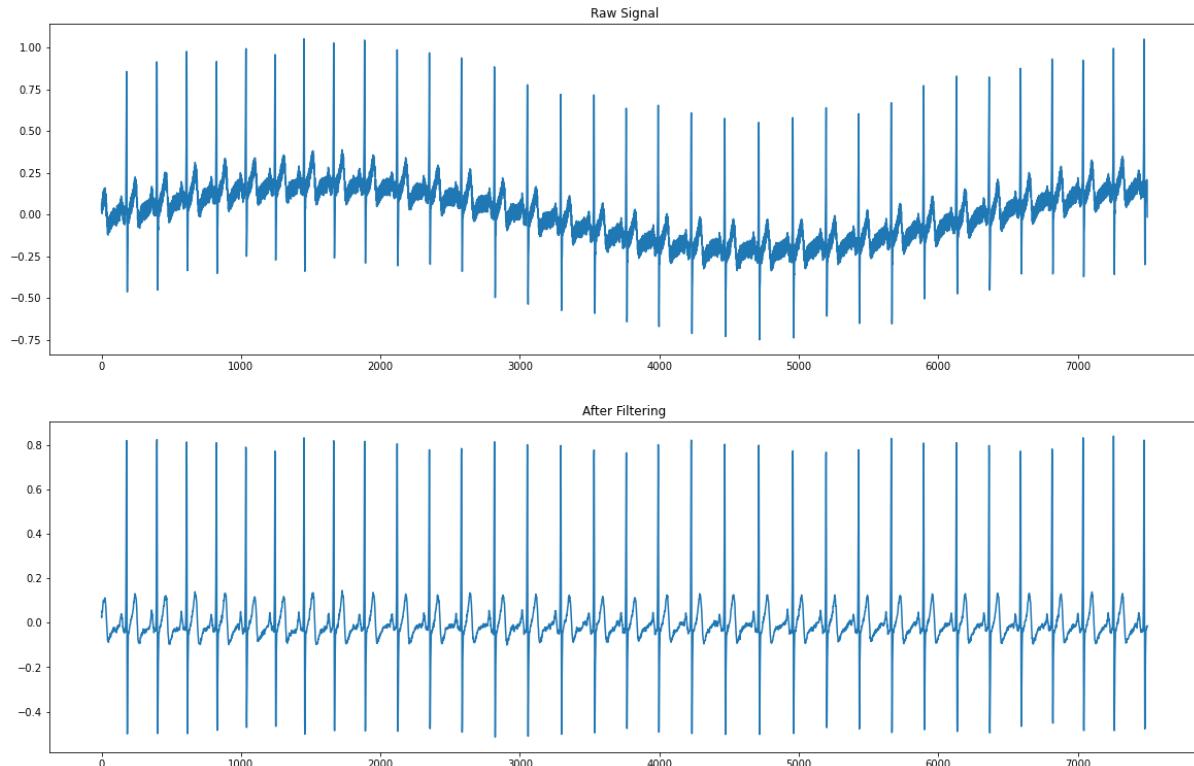
۳-۳-۱ فیلتر کردن داده ها

تداخل خط برق^۱ (PLI) و تغییر خط مبنا^۲ (BW) عناصر اصلی نویز هستند که در سیگنال های الکتروکاردیوگرام وجود دارند. تغییر خط مبنا یک آرتیفیکت با فرکانس پایین است که ناشی از تغییر امپدانس الکترود – پوست، حرکات و تنفس بیمار می باشد [۳۲]. اکثر تکنیک های حذف تغییرخط مبنا براساس حذف اجزای فرکانس پایین سیگنال ECG می باشد [۳۲]. PLI به دلیل تداخل الکترومغناطیسی منبع متناوب معرفی شده است و بسته به منبع تغذیه، فرکانس آن ۵۰ هرتز یا ۶۰ هرتز است [۳۳]. به منظور حذف این دو نویز، داده های مورد نظر در محیط پایتون با استفاده از جعبه ابزار neurokit2 فیلتر شدند. فیلتری که بهترین نتیجه

¹ Power-line interference

² baseline wander

را داشت فیلتر میان گذر با ترورث درجه چهارم بود [۳۴]. طیف سیگنال ECG انسان محدوده فرکانسی ۵-۱۰۰ هرتز را پوشش می دهد، که بخش اصلی مجموعه QRS در محدوده ۴۵-۵۰ هرتز قرار دارد [۳۵]. بنابراین به منظور فیلتر کردن داده ها، یک فیلتر با ترورث^۱ میان گذر مرتبه ۴ با بازه فرکانسی ۵-۵۰ هرتز مورد استفاده قرار گرفت. در شکل ۳-۳ نمونه ای از سیگنال ECG فیلتر شده نمایش داده شده است.



شکل ۳-۳ نمونه ای از سیگنال ECG بعد از اعمال فیلتر.

۲-۳-۳ استاندارد سازی داده ها

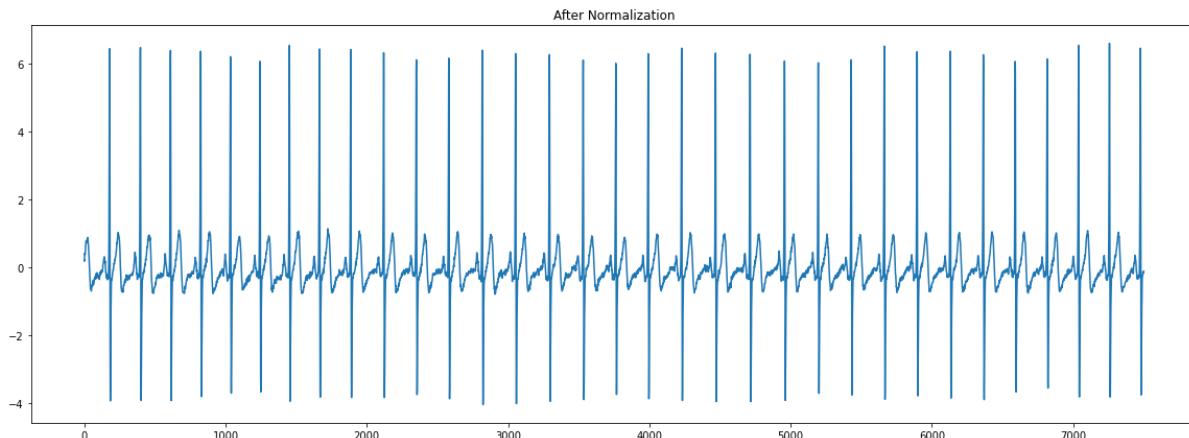
به منظور استاندارد سازی سیگنال ها، یک عملیات امتیاز Z^۲، که توسط فرمول ۳-۱ تعریف شده است، روی داده های فیلتر شده اعمال شد [۳۶].

$$Z = \frac{x - \mu}{\sigma} \quad (1-3)$$

که در آن x سیگنال مورد نظر، μ مقدار متوسط سیگنال و σ انحراف معیار آن می باشد. استاندارد سازی باعث می شود که مقادیر داده ها دارای میانگین صفر و واریانس یک باشند. شکل ۴-۳ یک نمونه از سیگنال را بعد از استاندارد سازی نشان می دهد.

¹ Butterworth

² Z-score



شکل ۴-۳ نمونه ای از سیگنال استاندارد شده.

۳-۳-۳ بخش بندی سیگنال

برای بخش بندی سیگنال های ECG پایگاه داده‌ی MIT-BIH polysomnography، با توجه به اینکه برچسب های موجود، مربوط به بخش های ۳۰ ثانیه‌ای هستند از زمان شروع ثبت، سیگنال‌ها به بخش های ۳۰ ثانیه‌ای تقسیم شدند.

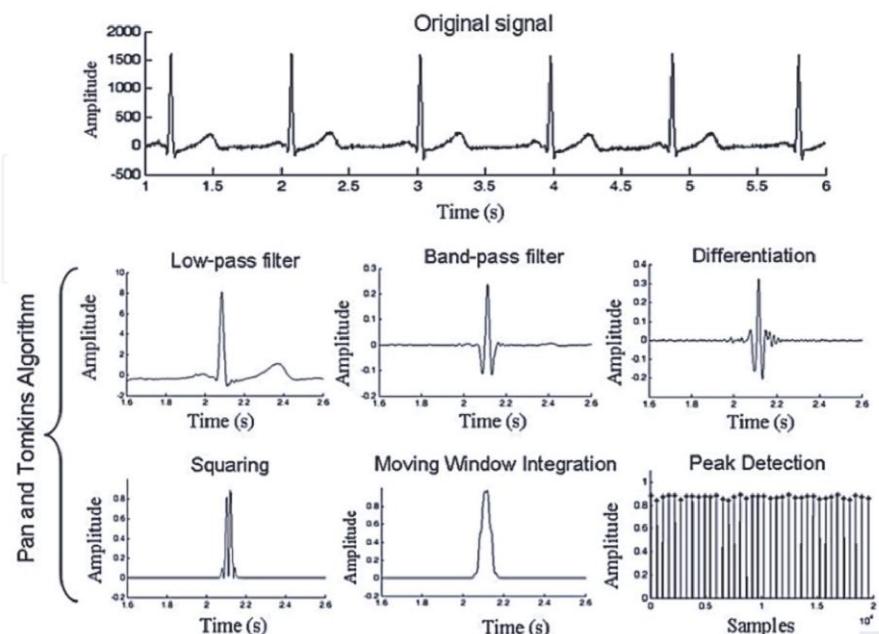
برای پایگاه داده‌ی CFS و NCHSDB به دلیل وجود فرکانس‌های نمونه برداری مختلف برای هر ثبت، ابتدا فرکانس نمونه برداری تمام ثبت‌ها را به ۲۵۰ هرتز (فرکانس نمونه برداری استفاده شده در پایگاه داده-MIT-BIH) تغییر داده شد. سپس با توجه به اینکه میانگین مدت زمان رویداد‌های آپنه در این دو پایگاه داده بین ۱۵ تا ۲۰ ثانیه بود، برای جداسازی بخش‌های آپنه موجود در این ثبت‌ها از ۵ ثانیه قبل از وقوع هر رویداد آپنه تا ۲۵ ثانیه بعد از رویداد آپنه را یک بخش با برچسب آپنه مربوطه در نظر می‌گیریم.

۴-۳ استخراج ویژگی

در این مطالعه به منظور کاهش هزینه محاسباتی و تسريع آموزش مدل عصبی عمیق به جای استفاده مستقیم از سیگنال خام ECG، از ویژگی‌های HRV و EDR استخراج شده از ECG استفاده شد که در ادامه به توضیح هر یک پرداخته می‌شود.

۱-۴-۳ تغییر پذیری ضربان قلب

تغییر پذیری ضربان قلب نوسان در فواصل زمانی بین ضربان های متوالی است [۳۷]. به دلیل اینکه HRV ارتباط مستقیمی با سیستم عصبی خودنمختار^۱ (ANS) دارد هر تغییری که در بدن انسان رخ دهد می تواند مستقیماً توسط HRV شناسایی شود. برای استخراج سیگنال HRV، الگوریتم های QRS مناسب برای شناسایی پیکها و موج R آن، برای به دست آوردن فاصله RR، باید اعمال شوند [۳۸]. بنابراین ابتدا پیک R سیگنال ECG با استفاده از الگوریتم پن تامپکینز^۲ تشخیص داده شده و سپس فواصل R-R محاسبه می شود [۳۹]. در الگوریتم پن تامپکینز ابتدا یک فیلتر پایین گذر به منظور حذف نویز های فرکانس بالا و سپس یک فیلتر میان گذر برای حذف تغییر خط مبنا انتخاب و حفظ اطلاعات فرکانسی مربوط به مجموعه QRS استفاده می شود. سپس برای محاسبه اطلاعات شبیه، مشتق سیگنال را محاسبه کرده و برای تاکید بیشتر بر روی اجزای فرکانس بالا و تضعیف اجزای فرکانس پایین، مربع سیگنال محاسبه می شود. در انتهای سیگنال به دست آمده با استفاده از یک فیلتر میانگین متحرک^۳ با طول پنجره ۸۰ میلی ثانیه نرم شده و نقاط R بعد از اعمال آستانه گذاری و فقی^۴ مشخص می شوند [۴۰]. این الگوریتم به طور خلاصه در شکل ۵-۳ نشان داده شده است.



شکل ۵-۳ الگوریتم پن تامپکینز [۴۰].

^۱ Autonomic nervous system

^۲ Pan-Tompkins algorithm

^۳ Moving average

^۴ Adaptive thresholding

در ادامه سیگنال HRV با محاسبه ی فواصل R-R و اختلاف بین این فواصل به دست می آید. به طور کلی ویژگی های قابل استخراج از HRV به سه دسته ی ویژگی های حوزه زمان، حوزه فرکانس و غیرخطی تقسیم می شوند.

۱-۱-۴-۳ ویژگی های حوزه ی زمان

در این پژوهش ویژگی های حوزه زمان استخراج شده از HRV شامل میانگین فواصل RR^۱، انحراف استاندارد فواصل RR^۲ (SDNN)، ریشه میانگین مربع اختلافات موفق^۳ (RMSSD)، انحراف استاندارد اختلافات موفق بین فواصل^۴ (SDSD) RR، میانه، میانه ی مشتق مطلق^۵ (MadNN)، بازه ی درون چارکی^۶ (IQRNN)، صدک بیستم^۷ (Prc80NN)، صدک هشتادم (Prc20NN)، نسبت فواصل RR بزرگ تر از ۵۰ میلی ثانیه (pNN50)، نسبت فواصل RR بزرگ تر از ۲۰ میلی ثانیه (pNN20)، حداقل فواصل (MinNN) و حداکثر فواصل (MaxNN) می باشند.

۲-۱-۴-۳ ویژگی های حوزه ی فرکانس

ویژگی های حوزه ی فرکانس استفاده شده در این پژوهش شامل طیف توان فرکانس بالا^۸ (HF^۹) (۰,۱۵-۰,۴ هرتز)، طیف توان فرکانس خیلی بالا^{۱۰} (VHF^{۱۱}) (۰,۴-۰,۵ هرتز)، توان فرکانس بالای نرمال شده (HFn) و تبدیل لگاریتم طیف توان فرکانس بالا (LnHF) می باشند.

۳-۱-۴-۳ ویژگی های غیر خطی

ویژگی های غیر خطی استخراج شده از سیگنال HRV که در این پژوهش مورد استفاده قرار گرفته اند شامل شاخص های پایه منحنی پوانکاره^{۱۲}، انحراف معیار عمود بر خط هویت^{۱۳} (SD1)، انحراف استاندارد در راستای خط هویت (SD2)، نسبت SD1 به SD2، مساحت زیر بیضی تشکیل شده از SD1 و SD2 (S)، شاخص سمتپانیک قلبی (CSI) و شاخص واگ قلبی (CVI))، شاخص های عدم تقارن ضربان قلب (شاخص گوزیک)، شاخص شیب (SI)، شاخص مساحت (AI)، شاخص پورتا (PI)، سهم کاهش و شتاب ضربان قلب در

^۱ MeanNN

^۲ RR interval standard deviation

^۳ square root of the mean of the squared successive differences

^۴ standard deviation of the successive differences

^۵ median absolute deviation

^۶ interquartile range

^۷ The 20th percentile

^۸ high frequency

^۹ very high frequency

^{۱۰} Poincaré plot

^{۱۱} line of identity

کوتاه مدت، شاخص کاهش و شتاب ضربان قلب در HRV بلند مدت و سهم کلی کاهش و شتاب ضربان قلب در HRV)، شاخص های تقسیم ضربان قلب^۱ (درصد نقاط عطف فواصل RR (PIP)، معکوس طول متوسط بخش های شتاب/کاهش سرعت (IALS) و شاخص های پیچیدگی (آنتروپی شنون (ShannonEn)، بعد همبستگی (CD)، بعد فراکتال هیگوچی^۲ (HFD) و بعد فراکتال کاتز^۳ (KFD)) بودند.

نمودار پوانکاره یک نمایش گرافیکی رایج از همبستگی بین فواصل RR متوالی، برای مثال نمودار_{j+1} RR_{j+1} در مقابل R_j است. یک رویکرد پرکاربرد برای تجزیه و تحلیل نمودار پوانکاره سری RR شامل برآش یک بیضی جهت یافته با توجه به خط هویت و محاسبه انحراف استاندارد نقاط عمود و در امتداد خط هویت به ترتیب تحت عنوان SD1 و SD2 است [۴۶]. شاخص سمپاتیک قلبی معیاری برای عملکرد سمپاتیک قلب مستقل از فعالیت واگ است که با تقسیم تغییرپذیری طولی نمودار پوانکاره (SD2) بر متغیر عرضی آن (SD1) محاسبه می‌شود. شاخص واگ قلبی شاخصی از عملکرد پاراسمپاتیک قلبی است با محاسبه لگاریتم حاصل ضرب تغییرپذیری طولی نمودار پوانکاره (SD2) در متغیر عرضی آن (SD1) بیان می‌شود [۴۷]. شاخص پورتا، به عنوان تعداد نقاط زیر خط هویت تقسیم بر تعداد کل نقاط در نمودار پوانکاره به جز نقاطی که روی خط هویت قرار دارند، تعریف می‌شود. بعد همبستگی اطلاعاتی در مورد تعداد اجزای عملکردی مستقل لازم برای توصیف سیستم مورد نظر و درجه جفت شدگی غیرخطی بین این اجزا می‌دهد. با توجه به اینکه بعد همبستگی امکان ارزیابی سری های زمانی کوتاه و همچنین غیر ثابت را فراهم می‌کند، معیاری است که می‌تواند به محدودیت نیاز به سری های زمانی بزرگ غلبه کند [۴۸]. آنتروپی شنون به طور معمول با استفاده از تبدیل مجموعه داده به چند دسته یا یک توالی نمادین تخمین زده می‌شود. با شمارش فرکانس نسبی هر دسته یا نماد، آنتروپی شنون برابر مجموع فرکانس های نسبی می‌شود [۴۹]. بعد فراکتال معیاری است که میزان پیچیدگی یک شکل خود-مشابه (مانند برف دانه گُخ) را نشان می‌دهد. بعد فراکتال هیگوچی و بعد فراکتال کاتز نیز جزئی از شناخته شده ترین روش های محاسبه معیار بعد فراکتال هستند.

تمامی ویژگی های استفاده شده در این پژوهش به اختصار در جدول ۷-۳ آورده شده است.

جدول ۷-۳ ویژگی های مورد استفاده استخراج شده از سیگنال ECG.

MeanNN, SDNN, RMSSD, SDSD, MedianNN, MadNN, IQRNN, Prc20NN, Prc80NN, pNN50, pNN20, MaxNN, MinNN	حوزه زمان	HRV
HF, VHF, HF _n , LnHF	حوزه فرکانس	
SD1, SD2, SD1/SD2, S, CSI, CVI, GI, SI, AI, PI, PIP, IALS, ShannonEn, CD, HFD, KFD	غیر خطی	
سیگنال تنفس مشتق شده از ECG		EDR

^۱ Heart Rate Fragmentation

^۲ Higuchi's Fractal Dimension

^۳ Katz's Fractal Dimension

۲-۴-۳ سیگنال تنفس مشتق شده از ECG

اندازه گیری و نظارت بر تنفس یک پارامتر بسیار مهم در زمینه بالینی و تشخیصی است. نرخ غیر طبیعی تنفس شاخصی از بی ثباتی فیزیولوژیکی می باشد. نرخ تنفس^۱ می تواند برای تشخیص زودهنگام بیماری های مزمن مانند بیماری مزمن انسدادی ریه، نارسایی احتقانی قلب^۲ (CHF) و اختلالات تنفسی مانند آپنه خواب استفاده شود. مشاهده شده است که ECG می تواند به عنوان یک سیگنال حامل اطلاعات تنفسی در نظر گرفته شود که دلیل آن تأثیر غالب تنفس بر چرخه قلبی است که به طور کلی به عنوان آریتمی سینوسی تنفسی^۳ (RSA) شناخته می شود. در سال های اخیر، ضرورت استفاده از نظارت تنفسی غیرتهاجمی شاهد رشد سریعی بوده است. به این منظور روش های مختلفی مانند پلتیسموگرافی القابی تنفسی، نرخ تنفس مشتق از شتاب سه بعدی^۴ و تنفس مشتق شده از ECG معرفی شده اند. روش تنفس مشتق شده از ECG بسیار مفید است زیرا هم تنفس و هم سیگنال ECG را می توان به طور همزمان نظارت کرد. ضربان قلب در طول دم افزایش می یابد (فاصله R-R کوتاه تر) و در طول بازدم (فاصله R-R طولانی تر) کاهش می یابد. بنابراین فاصله R-R می تواند به عنوان جایگزین سیگنال تنفسی استفاده شود. بر این اساس، EDR با استفاده از هر دو روش HRV و روش تغییرات دامنه اوج^۵ (PAV) به دست می آید. برای محاسبه تنفس مشتق شده با استفاده از HRV ابتدا پیک های R شناسایی می شوند و مقدار فاصله R-R برای هر یک از دو چرخه متوالی محاسبه می شود. سپس نرخ ضربان قلب^۶ (HR) برای هر بازه R-R با استفاده از فرمول ۲-۳ محاسبه می شود.

$$\text{نرخ ضربان قلب} = \frac{60}{\text{فاصله R-R}} \quad (2-3)$$

سپس مقادیر ضربان قلب به دست آمده با استفاده از درون یابی چند جمله ای مکعبی^۷ برای به دست آوردن شکل موج EDR از HRV درون یابی می شود. در روش محاسبه ای EDR از PAV دامنه پیک های R شناسایی شده با استفاده از درون یابی اسپلاین مکعبی بازسازی می شود [۴۱]. با توجه به این که محاسبه ای EDR با استفاده از HRV نتایج بهتری را نشان داده است، در این پژوهش نیز این روش برای محاسبه EDR استفاده شد.

¹ respiratory rate

² Congestive Heart Failure

³ Respiratory Sinus Arrhythmia

⁴ 3D-accelaration derived respiration rate

⁵ Peak Amplitude Variation

⁶ Heart Rate

⁷ cubic spline interpolation

۵-۳ کاهش ابعاد ویژگی

تجزیه و تحلیل مؤلفه اصلی^۱ (PCA) یک روش آماری است که اغلب به عنوان تکنیکی برای کاهش فشرده سازی داده ها بدون از دست دادن اطلاعات استفاده می شود. در این تحقیق از PCA برای فشرده سازی ابعاد ویژگی های استخراج شده استفاده شده است. این روش از تجزیه مقادیر ویژه ماتریس کوواریانس استفاده می کند و داده ها را براساس بردارهای ویژه تعریف می کند. تنها تعداد کمی از مقادیر ویژه به طور قابل توجه دارای مقدار بزرگی خواهند بود و سایرین مقدار بسیار کوچکی خواهند داشت و به نمایش تغییرات داده ها کمکی نمی کنند. بنابراین ۵ مقدار ویژه مهم برای طبقه بندی چهار کلاس موجود در این پژوهش انتخاب شده است [۴۲]. واریانس مربوط به هر کدام از مؤلفه های اصلی استخراج شده از ویژگی ها در جدول ۸-۳ نمایش داده شده است.

جدول ۸-۳ واریانس مربوط به هر مؤلفه

مؤلفه های اصلی	مؤلفه اول	مؤلفه دوم	مؤلفه سوم	مؤلفه چهارم	مؤلفه پنجم
واریانس	۹.۹۹۹۹x10 ^{-۱}	3.364x10 ^{-۶}	6.4059x10 ^{-۷}	1.6946x10 ^{-۷}	5.6519x10 ^{-۸}

با توجه به واریانس مؤلفه های انتخاب شده، مؤلفه اول با داشتن بیشترین واریانس بهترین مؤلفه برای نمایش تغییرات داده های موجود است.

۶-۳ تقسیم مجموعه داده به مجموعه آموزش و آزمون

تفکیک مجموعه داده بخشی ضروری برای ارزیابی بی طرفانه عملکرد الگوریتم های یادگیری ماشین است. این عملیات اغلب داده ها را به سه مجموعه آموزش، آزمون و اعتبارسنجی تقسیم می کند. در این پژوهش ابتدا ۹۰٪ از کل داده ها برای آموزش و اعتبارسنجی و ۱۰٪ باقی مانده برای آزمون به طور تصادفی تفکیک شدند. برای غلبه بر مشکل نامتعادل بودن داده های مربوط به هر کلاس و تجزیه و تحلیل قابل اعتماد و دقیق از اعتبار سنجی متقابل ده برابری طبقه ای^۲ استفاده شد که روشی مؤثر برای متعادل کردن مجموعه داده های نامتعادل است. در روش اعتبارسنجی متقابل معمولی (n برابر)، یک مجموعه داده S ابتدا به طور تصادفی به n زیرمجموعه (فولد) s_1, s_2, \dots, s_n با اندازه مساوی تقسیم می شود. سپس هر یک از n فولد به نوبه خود به عنوان مجموعه اعتبارسنجی استفاده می شود. در حالی که فولد های باقی مانده ($n-1$) به عنوان مجموعه آموزشی استفاده می شوند سپس یک طبقه بند از مجموعه آموزشی ساخته می شود و دقت آن در مجموعه اعتبارسنجی ارزیابی می شود. این فرآیند n بار تکرار می شود و هر بار از یک فولد متفاوت به عنوان مجموعه اعتبارسنجی استفاده می شود. ویژگی اعتبارسنجی متقابل این است که تمام n مجموعه اعتبارسنجی مستقل هستند و

¹ Principal component analysis

² Stratified K Fold Cross Validation

بنابراین هر مورد در مجموعه آموزشی اصلی تنها یک بار اعتبارسنجی می‌شود. در مقابل، هنگام استفاده از روش‌های استاندارد آموزش-آزمون یا بوت استرپ^۱، برخی از موارد ممکن است چندین بار اعتبارسنجی شوند در حالی که برخی دیگر ممکن است اصلاً اعتبارسنجی نشوند. شاخه‌ای از اعتبار سنجی متقابل، اعتبار سنجی متقابل طبقه‌ای می‌باشد که در آن یک مجموعه داده S به n فولد تقسیم می‌شود به طوری که هر کلاس به طور یکنواخت بین n فولد توزیع می‌شود. نتیجه این است که توزیع کلاس در هر فولد شبیه به مجموعه داده اصل S است در مقابل، اعتبارسنجی متقابل معمولی به طور تصادفی S را بدون در نظر گرفتن توزیع کلاس به n فولد تقسیم می‌کند. در اعتبارسنجی متقابل معمولی یک کلاس خاص می‌تواند به طور ناموزون توزیع شود به این معنی که برخی از فولد‌ها حاوی موارد بیشتری از کلاس نسبت به سایرین باشند. این اعوجاج در توزیع کلاس‌ها می‌تواند دقیق تخمین را کاهش دهد. همچنین در مطالعه‌ای توسط کوهاوی (۱۹۹۵) گزارش شده است که اعتبار سنجی متقابل طبقه‌ای نسبت به اعتبارسنجی متقابل معمولی بهتر عمل می‌کند (بایاس و واریانس کمتری دارد) [۴۳].

۷-۳ ساختار شبکه عصبی

اخیراً روش‌های یادگیری عمیق برای شناسایی آپنه پیشنهاد و استفاده شده‌اند. بسیاری از مطالعات از یادگیری عمیق در قالب شبکه‌های عصبی کانولوشن استفاده کردند که عملکرد بالایی را نشان داده‌اند. با این وجود، CNN‌ها اساساً برای تشخیص تصویر طراحی شده‌اند و معمولاً به قدرت محاسباتی بالایی نیاز دارند. شبکه‌های عصبی بازگشتی^۲ (RNN) زیر شاخه‌ای از شبکه‌های عصبی پیشخور کلاسیک هستند که به طور موثر توالی‌های با طول متغیر و داده‌های سری زمانی را مدیریت می‌کنند. به طور خاص، وقوع مکرر زمانی اختلالات تنفسی در خواب می‌تواند به طور بالقوه RNN‌ها را مفیدتر و مناسب‌تر از روش‌های یادگیری ماشینی معمولی و یا روش‌های مبتنی بر CNN کند. شبکه عصبی بازگشتی معمولاً روی سیگنالی اعمال می‌شود که بین مقادیر آن در طول زمان همبستگی وجود دارد. یک RNN به طور ایده‌آل برای اطلاعات متوالی و داده‌های سری زمانی عالی است زیرا دارای حافظه نیز می‌باشد. مزیت اصلی RNN در نظر گرفتن وابستگی‌های زمانی و استخراج ویژگی‌های زمانی است. از طرف دیگر، دو مشکل ناپدید شدن^۳ و انفجار^۴ گرادیان در شبکه‌های عصبی بازگشتی یادگیری وابستگی‌های طولانی مدت را برای RNN‌ها بسیار دشوار می‌کنند. برای رفع این نقص، می‌توان از حافظه طولانی کوتاه مدت^۵ (LSTM) استفاده کرد. شبکه‌های LSTM از حافظه بلند مدت و کوتاه مدت برای پیگیری تغییرات سیگنال استفاده می‌کنند. همانطور که در شکل ۳-۶

¹ bootstrap

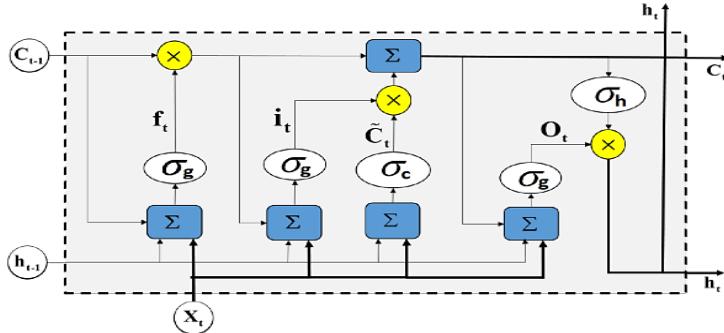
² Recurrent neural network

³ vanish

⁴ explode

⁵ Long Short-Term Memory

نشان داده شده است، هر سلول پایه LSTM مجهر به سه دروازه ورودی، یک دروازه خروجی و یک دروازه فراموشی.



شکل ۶-۳ معماری معمولی LSTM. یک بلوک LSTM معمولاً دارای یک سلول حافظه، دروازه ورودی (i_t)، دروازه خروجی (O_t) و یک دروازه فراموشی (f_t) است.

از نظر ریاضی، ساختار LSTM را می‌توان به صورت زیر فرموله کرد:

$$f_t = \sigma_g(W_f x_t + U_f h_{t-1} + b_f) \quad (3-3) \text{ دروازه فراموشی}$$

$$i_t = \sigma_g(W_i x_t + U_i h_{t-1} + b_i) \quad (4-3) \text{ دروازه ورودی}$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \sigma_c(W_c x_t + U_c h_{t-1} + b_c) \quad (5-3) \text{ برروز رسانی وضعیت سلول}$$

$$O_t = \sigma_g(W_o x_t + U_o h_{t-1} + b_o) \quad (6-3) \text{ دروازه خروجی}$$

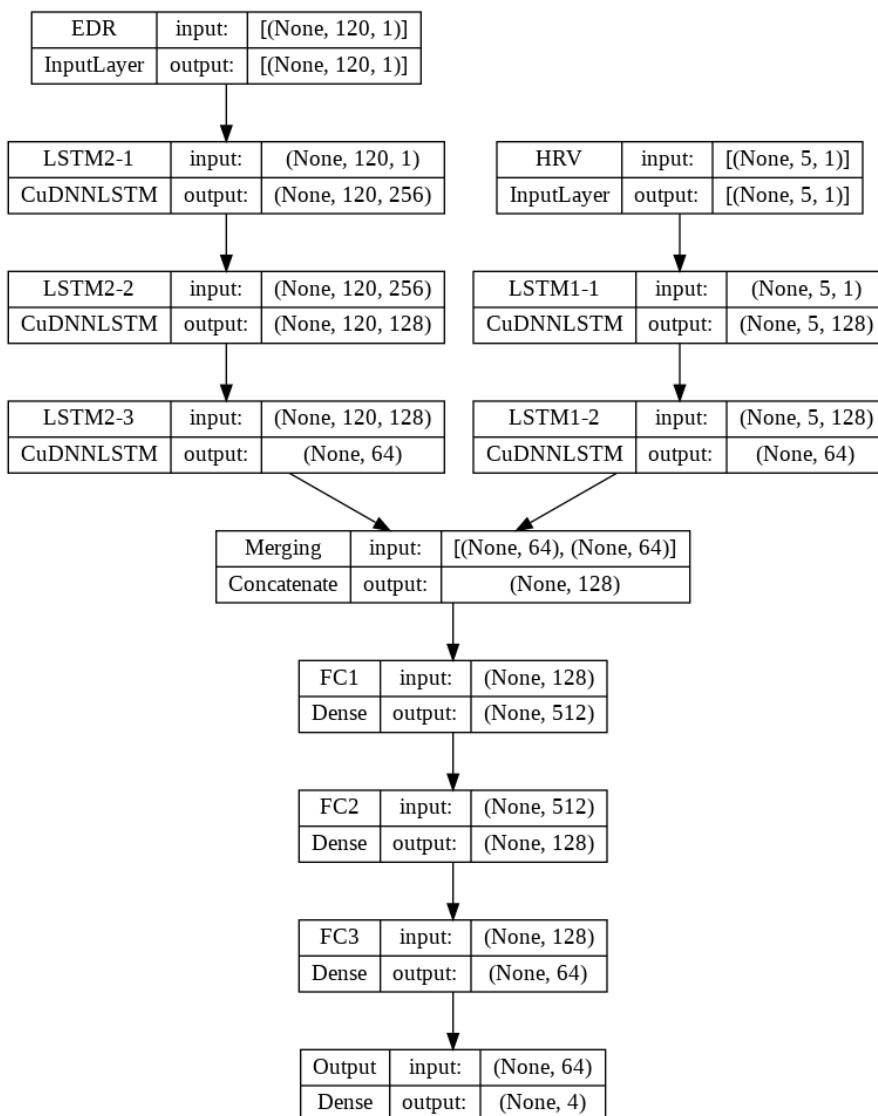
$$h_t = O_t \odot \sigma_h(C_t) \quad (7-3) \text{ خروجی}$$

که در آن h_{t-1} و c_{t-1} به ترتیب خروجی و وضعیت سلول قبلی LSTM هستند. x_t بردار ورودی می‌باشد. W ، U و b بترتیب ماتریس وزن ورودی، ماتریس وزن تکرار شونده و عبارت بایاس برای دروازه هستند. این پارامترها در طول فرآیند آموزش شبکه یادگرفته می‌شوند. σ_g تابع فعال‌سازی سیگموئیدی است در حالی که σ_c و σ_h تابع فعال‌سازی تانژانت هذلولی هستند. سلول LSTM می‌تواند وزن‌ها را براساس حالت قبلی (C_{t-1}) و دروازه ورودی (i_t) به روز کند. قابلیت اندازه‌گیری وابستگی فواصل طولانی سیگنال ورودی به دلیل مکانیزم دروازه‌ای است که مشخصه اصلی سلول LSTM است.

بدلیل ماهیت وابسته به زمان و متناوب سیگنال‌های ECG، در این پژوهش از شبکه عصبی بازگشتی LSTM استفاده شده است. ساختار کلی شبکه در شکل ۷-۳ نشان داده شده است. شبکه استفاده شده دارای دو ورودی است که هر کدام از ویژگی‌های HRV و سیگنال EDR استخراج شده بطور مجزا و همزمان به شبکه داده می‌شوند. در شاخه مربوط به HRV دو سلول LSTM بترتیب با تعداد واحد‌های ۱۲۸ و ۶۴ قرار گرفته اند. در شاخه EDR از سه سلول LSTM بترتیب با تعداد واحد‌های ۲۵۶، ۱۲۸، و ۶۴ استفاده شده است. خروجی هر شاخه در نهایت با هم ادغام شده و به سه لایه کاملاً متصل، برای شناسایی و استخراج روابط موجود در داده‌ها، داده می‌شود. به منظور طبقه‌بندی داده‌ها خروجی آخرین لایه کاملاً متصل در انتهای به

یک لایه با ۴ نورون داده می شود. همچنین به منظور کاهش احتمال بیش برآزش^۱ بعد از هر لایه LSTM و بعد از هر لایه کاملاً متصل از لایه دراپ اوت با درصد ۵۰ استفاده شد.

در آموزش شبکه، اندازه هر دسته، ۲۰۴۸ در نظر گرفته شده و تعداد تکرار برابر ۱۵۰ قرار داده شده است (تعداد تکرار، تعداد دفعاتی است که کل مجموعه داده آموزشی به شبکه داده می شود). همچنین به منظور جلوگیری از بیش برآزش و ذخیره مدل با عملکرد مطلوب در هنگام آموزش شبکه، بر روی میزان خطای اعتبار سنجی مجموعه داده نظارت انجام می گیرد. بدین صورت که در هر تکرار آموزش شبکه، خطای با استفاده از داده اعتبار سنجی محاسبه شده و اگر خطای محاسبه شده نسبت به خطای در تکرارهای قبلی بهتر شده باشد، آن مدل ذخیره می شود و در ادامه تکرارها نیز همین شیوه در نظر گرفته می شود. در انتها شبکه با کمترین خطای بر روی داده های اعتبار سنجی به عنوان شبکه آموزش دیده نهایی انتخاب می شود.



شکل ۳-۷ نمای کلی ساختار شبکه پیشنهادی.

¹ Overfitting

توابع فعال سازی استفاده شده برای هر یک از لایه های LSTM، کاملاً متصل و لایه نهایی به ترتیب تانژانت هایپربولیک، ReLU و Softmax بودند.

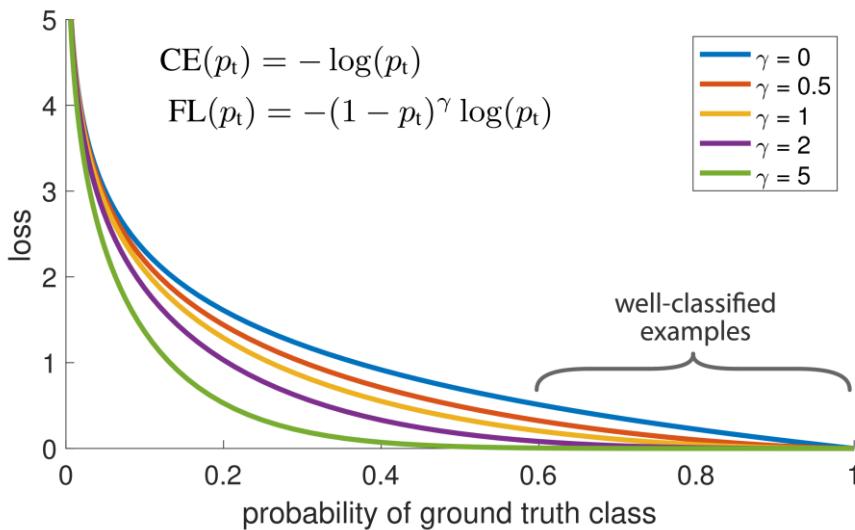
۱-۷-۳ تابع هزینه

در این مطالعه به دلیل نامتعادل بودن داده ها، از تابع هزینه کانونی^۱ استفاده شد. تابع هزینه کانونی به موضوع عدم تعادل بین کلاس ها در طول آموزش می پردازد. تابع هزینه کانونی یک عبارت تعديل کننده را بر روی تابع هزینه آنتروپی متقابل اعمال می کند تا تمرکز یادگیری بر روی نمونه ها با طبقه بندی اشتباه قرار گیرد. در این صورت تابع هزینه آنتروپی متقابل به صورت پویا مقیاس بندی می شود که در آن ضریب مقیاس با افزایش ضریب اعتماد کلاس صحیح، به صفر متمایل می شود. این ضریب مقیاس می تواند به طور خودکار سهم نمونه های ساده را در طول آموزش کاهش داده و به سرعت مدل را بر روی نمونه های سخت متمرکز کند. به طور رسمی، تابع هزینه کانونی یک ضریب γ (۰ - ۱) را به معیار استاندارد آنتروپی متقابل اضافه می کند. تنظیم γ باعث کاهش هزینه نسبی نمونه های به درستی طبقه بندی شده می شود و تمرکز بیشتری را بر نمونه های سخت و با طبقه بندی نادرست می گذارد. معادله کلی تابع هزینه کانونی در زیر آورده شده است:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (8-3)$$

که در آن γ ضریب مقیاس، α_t ضریب تعادل تعداد داده و p_t احتمال کلاس صحیح می باشد. در واقع ضریب α_t برای برطرف کردن عدم تعادل بین تعداد داده های کلاس ها و به تعادل رساندن اهمیت هر یک از کلاس ها در نظر گرفته می شود. اما با توجه به اینکه این ضریب به تنهایی نمی تواند بین کلاس های سخت و آسان تفاوت قائل شود، در نتیجه، لازم است عامل دیگری یعنی ضریب مقیاس γ تعریف شود تا بتواند وزن نمونه های آسان را کمتر کرده و بیشتر بر روی داده های سخت تمرکز کند. نمودار مربوط به تغییرات تابع هزینه کانونی به ازای مقادیر مختلف ضریب مقیاس در شکل ۸-۳ نشان داده شده است [۴۴].

¹ Focal Loss



شکل ۸-۳ نمودار تغییرات تابع هزینه کانونی بر حسب احتمال کلاس صحیح به ازای مقادیر مقیاس ۰ تا ۵ [۴۴].

۲-۷-۳ تابع بهینه ساز آدام

بهینه ساز آدام، میزان نرخ یادگیری را با توجه به بهینه کردن مدل و با استفاده از یک ترم حرکتی تطبیق می دهد [۴۵]. این ترم حرکتی، بروز رسانی پارامترها را کنترل می کند. اگر گرادیان برای چندین تکرار مشابه باشد، در نتیجه بروز رسانی، نرخ یادگیری بزرگتر می شود و اگر گرادیان تغییرات بزرگی داشته باشد (به عنوان مثال نویز)، در نتیجه، بروز رسانی با نرخ یادگیری کوچکتری انجام می شود.

۸-۳ معیارهای ارزیابی

در این پژوهش از چهار معیار صحت، یادآوری، امتیاز F1 و ناحیه زیر منحنی ROC^۱ (AUC) برای ارزیابی عملکرد شبکه استفاده شده است.

۱-۸-۳ ماتریس درهم‌ریختگی

به ماتریسی گفته می شود که در آن عملکرد الگوریتم نشان داده می شود. معمولاً چنین نمایشی برای الگوریتم های یادگیری نظارت شده استفاده می شود. این ماتریس در شکل ۹-۳ آورده شده است. سطرهای این ماتریس، کلاس های پیش‌بینی شده و ستون های این ماتریس، کلاس های درست هستند. این ماتریس دارای چهار درایه به نام های TP، FP، FN و TN است.

^۱ Area Under the ROC Curve

TP: نشان‌دهنده تعداد کلاس‌های مثبتی است که به درستی توسط الگوریتم به عنوان کلاس مثبت پیش‌بینی شده‌اند.

TN: نشان‌دهنده تعداد کلاس‌های منفی است که به درستی توسط الگوریتم به عنوان کلاس منفی پیش‌بینی شده‌اند.

FP: نشان‌دهنده تعداد کلاس‌های منفی است که به غلط توسط الگوریتم به عنوان کلاس مثبت پیش‌بینی شده‌اند.

FN: نشان‌دهنده تعداد کلاس‌های مثبتی است که به غلط توسط الگوریتم به عنوان کلاس منفی پیش‌بینی شده‌اند.

Estimate			
	$C_0 \dots C_{k-1}$	C_k	$C_{k+1} \dots C_n$
$C_{k+1} \dots C_n$	TN	FP	TN
C_k	FN	TP	FN
$C_{k-1} \dots C_0$	TN	FP	TN

TN	true negative
TP	true positive
FN	false negative
FP	false positive

شکل ۹-۳ ماتریس درهم‌ریختگی.

۲-۸-۳ معیار دقت

دقت معیاری است که با تقسیم مثبت‌های واقعی بر روی هر چیزی که به عنوان مثبت پیش‌بینی شده باشد محاسبه می‌شود. این معیار تلاش می‌کند به این سؤال پاسخ دهد: چه نسبتی از شناسایی‌های مثبت واقعاً درست بوده است؟ معیار دقت طبق رابطه ۸-۳ محاسبه می‌شود.

$$\text{precision} = \frac{TP}{TP+FP} \quad (9-3)$$

که در آن TP حالتی است که برخی اشخاص بیمار باشند و الگوریتم هم به درستی بیماری را تشخیص داده باشد و FP حالتی است که برخی اشخاص بیمار نباشند ولی الگوریتم به اشتباه بگوید که این افراد بیمار هستند.

۳-۸-۳ معیار یادآوری

یادآوری (یا نرخ مثبت واقعی) با تقسیم مثبت های واقعی بر هر چیزی که باید مثبت پیش بینی می شد محاسبه می شود. این معیار به این سوال پاسخ می دهد که چه نسبتی از موارد مثبت واقعی به درستی شناسایی شده اند. معیار یادآوری طبق رابطه ۹-۳ محاسبه می شود.

$$recall = \frac{TP}{TP+FN} \quad (10-3)$$

که در آن FN حالتی است که برخی اشخاص بیمار باشند ولی الگوریتم به اشتباه بگویند که این افراد بیمار نیستند.

۴-۸-۳ F1 امتیاز

دقت و یادآوری دو عنصر سازنده امتیاز F1 هستند و هدف امتیاز F1 ترکیب این دو معیار در یک معیار می باشد. در عین حال، امتیاز F1 طوری طراحی شده است که روی داده های نامتعادل به خوبی کار کند. رابطه امتیاز F1 به شرح زیر است:

$$F1 = 2 * \frac{precision*recall}{precision+recall} \quad (11-3)$$

۵-۸-۳ منحنی ROC و ناحیه زیر آن

منحنی ROC یک روش عالی برای تجسم عملکرد یک مدل طبقه بندی است. این منحنی توسط ترسیم نسبت نرخ مثبت صحیح^۱ (TPR) بر حسب نرخ مثبت کاذب^۲ (FPR) ایجاد می شود. TPR مشخص می کند که به چه نسبتی پیش بینی صحیح صورت گرفته است. یعنی تعداد پیش بینی های صحیح بر تعداد نتایج مثبت واقعی تقسیم شده و نرخ پیش بینی صحیح مثبت محاسبه می شود. از طرف دیگر FPR نشانگر تعداد شناسایی های مثبت از میان مشاهدات منفی است. سطح زیر این منحنی (AUC) یک معیار بسیار رایج است که برای مقایسه مدل های مختلف یادگیری ماشین استفاده می شود. مقدار عددی AUC به وضوح عددی بین صفر تا یک است و نشان می دهد قدرت تشخیص یک تست چقدر است. اگر این عدد به یک نزدیک باشد به معنای آن است که داده ها عموماً در بالای خط نیمساز قرار گرفته اند و میزان نرخ مثبت صحیح بالا است. اعداد AUC نزدیک به ۰,۵ همان برابری نرخ مثبت صحیح و نرخ مثبت کاذب را نشان می دهد و اعداد کمتر از ۰,۵ بیانگر بالاتر بودن نرخ مثبت کاذب در مقایسه با نرخ مثبت صحیح است.

¹ True positive rate

² False Positive Rate

۹-۳ نرم افزار و سخت افزار مورد استفاده

به منظور پیاده سازی شبکه تعریف شده و همچنین آموزش آن، از محیط Python و از کتابخانه Keras^۱ و پس زمینه^۲ Tensorflow^۳، که یکی از رایج ترین و پر کاربرد ترین کتابخانه های مورد استفاده در شبکه های عصبی هستند، استفاده شده است.

سرعت پردازش بر روی GPU به خصوص برای کاربرد های یادگیری عمیق به طور معمول ۱۰ تا ۳۰ برابر سریع تر از حالتی است که از CPU استفاده شود اما به دلیل محدودیت در دسترسی به ظرفیت بالای GPU، Google محیطی را برای برنامه نویسان به نام Google Colaboratory فراهم کرده که GPU مدل Tesla K80 12GB و همچنین ۶۸ گیگا بایت حافظه دیسک در اختیار آنان قرار می دهد و می توان از آن به مدت ۱۲ ساعت در روز به طور مداوم استفاده کرد. در این پژوهش به منظور اجرای کدها و آموزش سریع تر شبکه، از محیط Google Colab استفاده شده است. به دلیل حجم بسیار بالای پایگاه های داده استفاده شده در این مطالعه (حجم کلی بیش از ۴ ترابایت) دانلود، بارگذاری و پیش پردازش داده ها در محیط Google Colab بیش از ۲ ماه بطول انجامید. همچین مدت زمان استخراج ویژگی از سیگنال ECG و آموزش شبکه پیشنهادی با اعمال اعتبار سنجی متقابل ۱۰ برابری در محیط Google Colab بترتیب ۵ و ۱۱ ساعت بود.

^۱ Keras

^۲ Backend

^۳ Tensorflow

فصل ۴ - نتایج

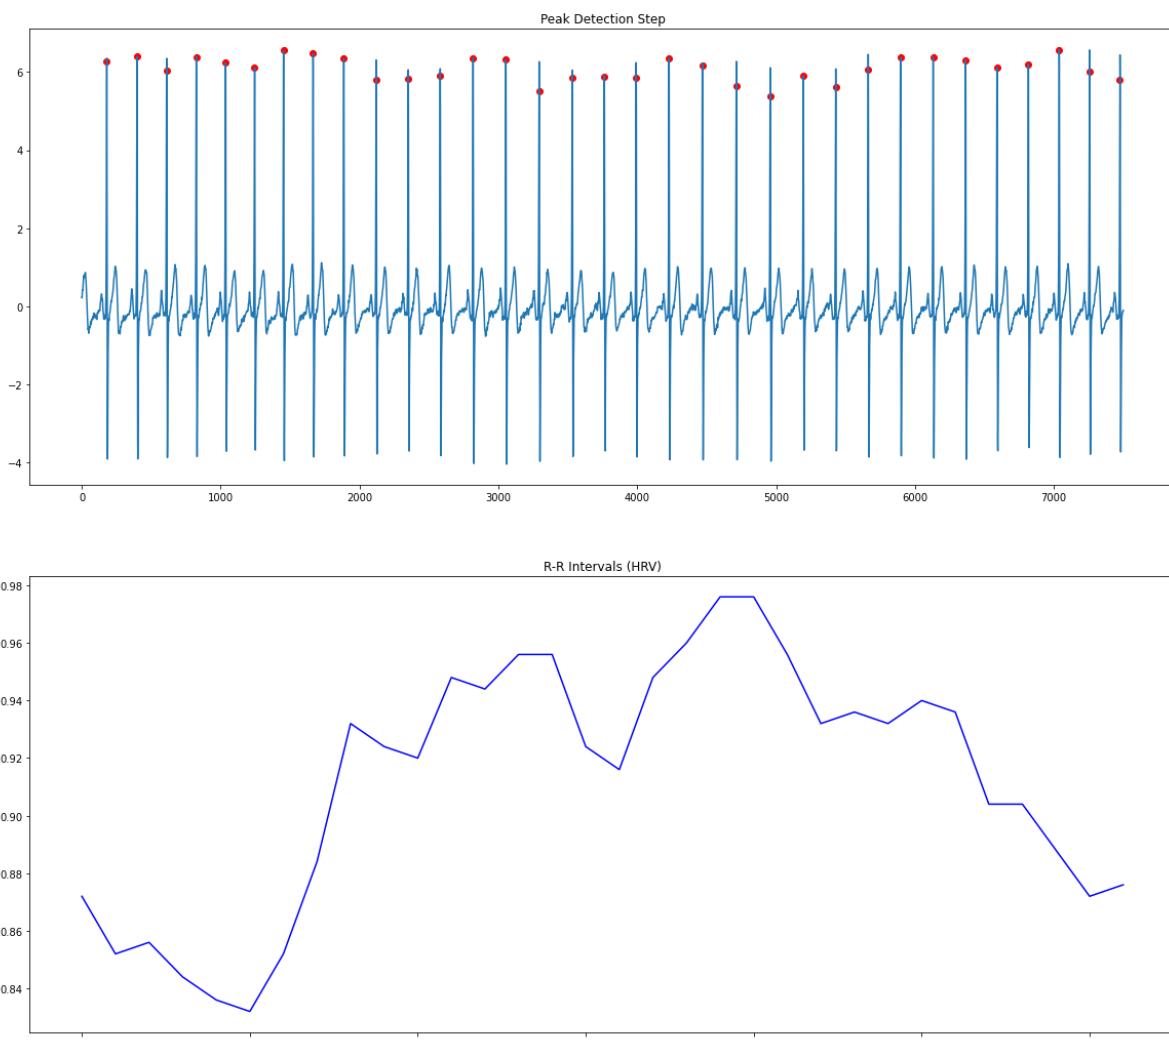
۱-۴ مقدمه

در این فصل به بررسی و تحلیل نتایج مربوط به مرحله استخراج ویژگی، تقسیم مجموعه داده، آموزش شبکه عصبی و آزمون شبکه عصبی پرداخته خواهد شد.

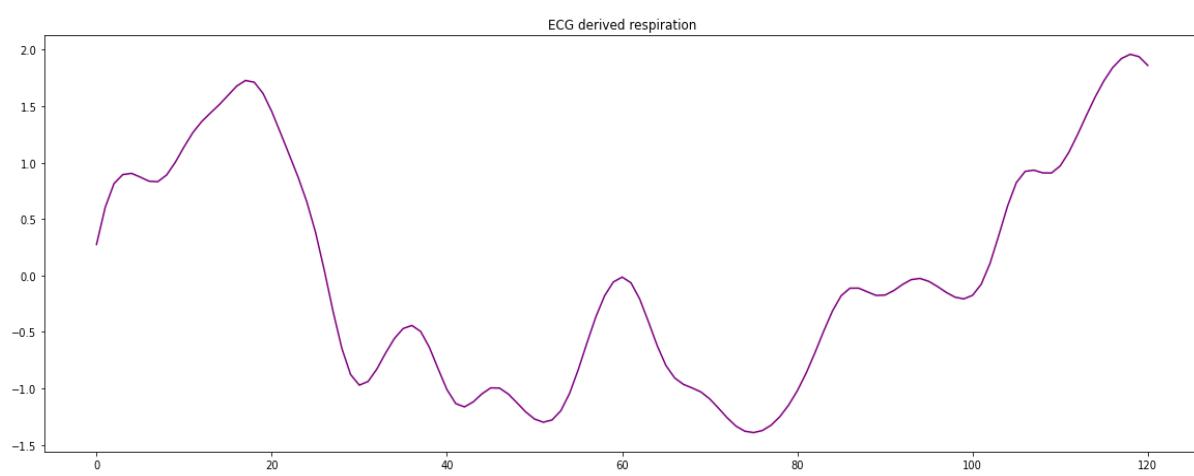
۲-۴ مرحله استخراج ویژگی

همانطور که در فصل پیشین گفته شد، در ابتدا به منظور حذف نویز، سیگنال ECG با استفاده از یک فیلتر میان گذر فیلتر شده و استاندارد سازی شده و سپس به بخش های ۳۰ ثانیه تقسیم می شود. در ادامه، همانطور که در فصل قبل توضیح داده شد، برای محاسبه ویژگی های مبتنی بر تغییرپذیری ضربان قلب ابتدا قله های R هر یک از بخش ها با استفاده از الگوریتم پن تامپکینس تشخیص داده شده و تغییرات فواصل بین این قله ها بدست آمده و در نهایت ویژگی های حوزه زمان، فرکانس و ویژگی های غیر خطی معرفی شده معرفی شده با توجه به سیگنال تغییرات فواصل بین قله ها محاسبه می شوند. شکل ۱-۴ قله های R تشخیص داده شده و سیگنال تغییرات فواصل بین قله ها مربوط به یک بخش را نشان می دهد.

سیگنال تنفس مشتق شده از ECG نیز با توجه به الگوریتم معرفی شده در فصل قبل برای هر بخش ۳۰ ثانیه ای محاسبه می شود. شکل ۲-۴ سیگنال تنفس مشتق شده از ECG را نشان می دهد.



شکل ۱-۴ قسمت اول قله های R تشخیص داده شده، قسمت دوم نمودار فواصل R-R مربوط به یک بخش ۳۰ ثانیه ای را نشان می دهدند.



شکل ۲-۴ سیگنال تنفس مشتق شده از ECG مربوط به یک بخش ۳۰ ثانیه ای از سیگنال.

۳-۳ مرحله تقسیم مجموعه داده

بعد از استخراج ویژگی های مربوط به HRV و کاهش ابعاد این ویژگی ها و همچنین محاسبه سیگنال تنفس مشتق شده از ECG، همانطور که در فصل قبل بیان شد، مجموعه داده به سه مجموعه داده آموزش، اعتبار سنジ و آزمون تقسیم می شود. تعداد داده های موجود در هر مجموعه داده به تفکیک کلاس در جدول ۱-۴ آورده شده است.

جدول ۱-۴ تعداد های موجود در هر مجموعه داده به تفکیک کلاس.

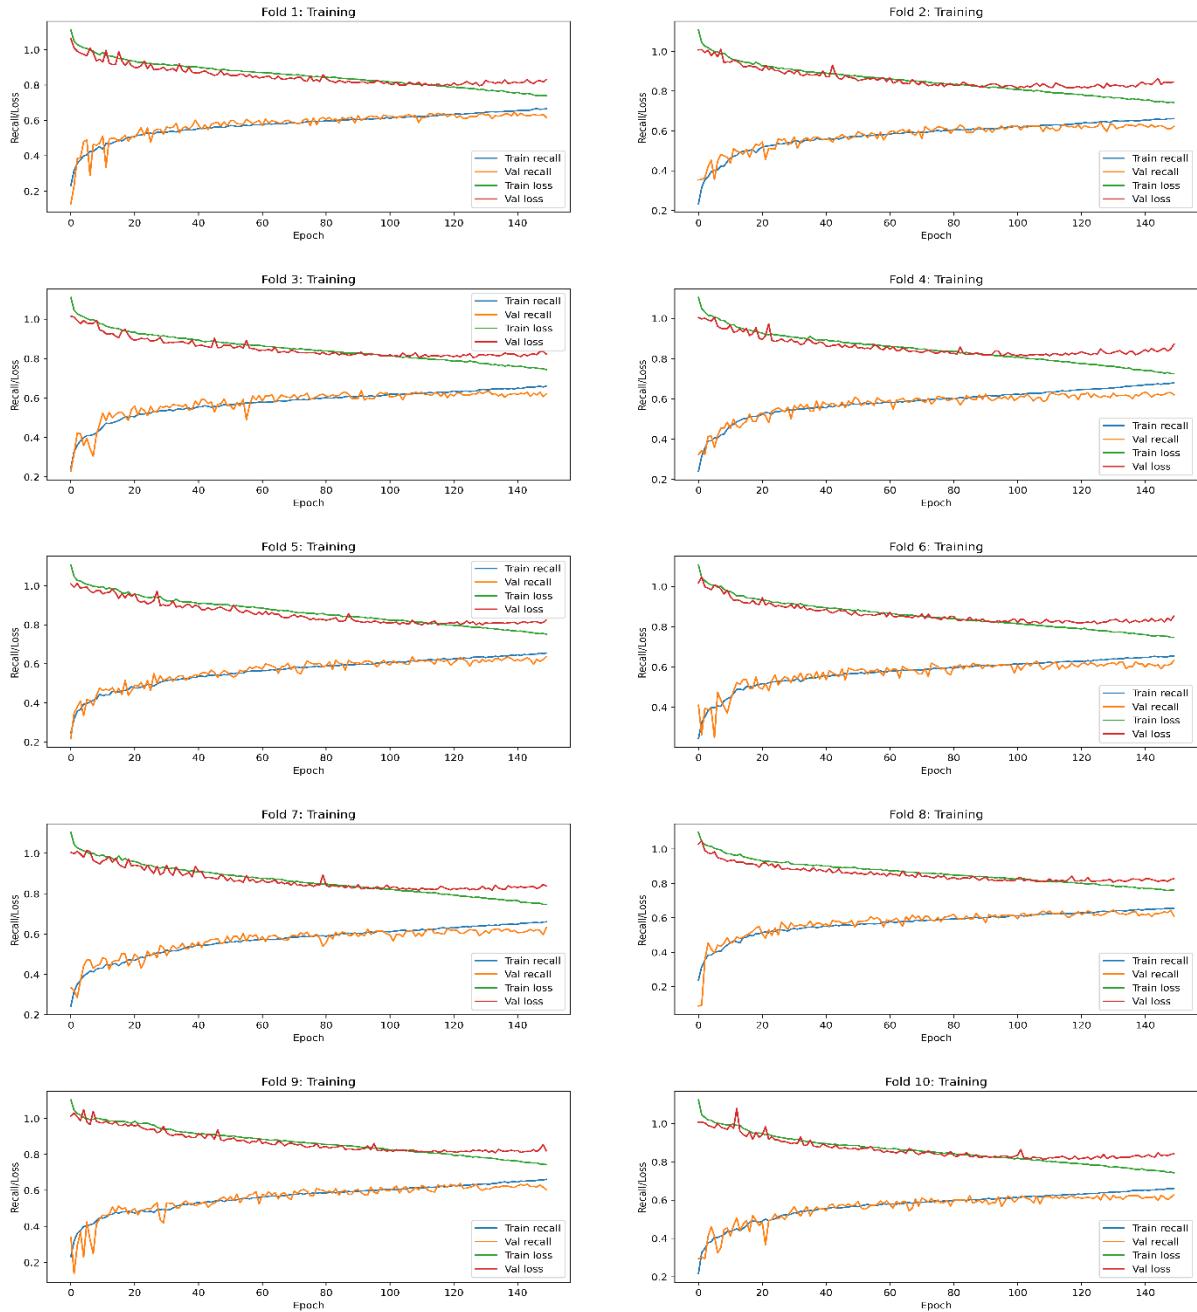
مجموع	آپنه مختلط	آپنه مرکزی	آپنه انسدادی	نرمال	مجموعه داده
۷۵۵۴۸	۱۸۳۶	۹۱۰۸	۳۹۴۵۶	۲۵۱۴۸	آموزش
۸۳۹۵	۲۱۵	۱۰۲۴	۴۳۹۷	۲۷۵۹	اعتبار سنジ
۹۳۲۷	۲۳۷	۱۱۵۱	۴۸۵۶	۳۰۸۳	آزمون
۹۳۲۷۰	۲۲۸۸	۱۱۲۸۳	۴۸۷۰۹	۳۰۹۹۰	کل

باید به این نکته توجه شود که به بدليل استفاده از تکنیک اعتبارسنジ متقابل ۱۰ برابری، تعداد دقیق داده های مربوط به هر کلاس برای هر دسته ممکن است با مقدار بیان شده کمی اختلاف داشته باشد.

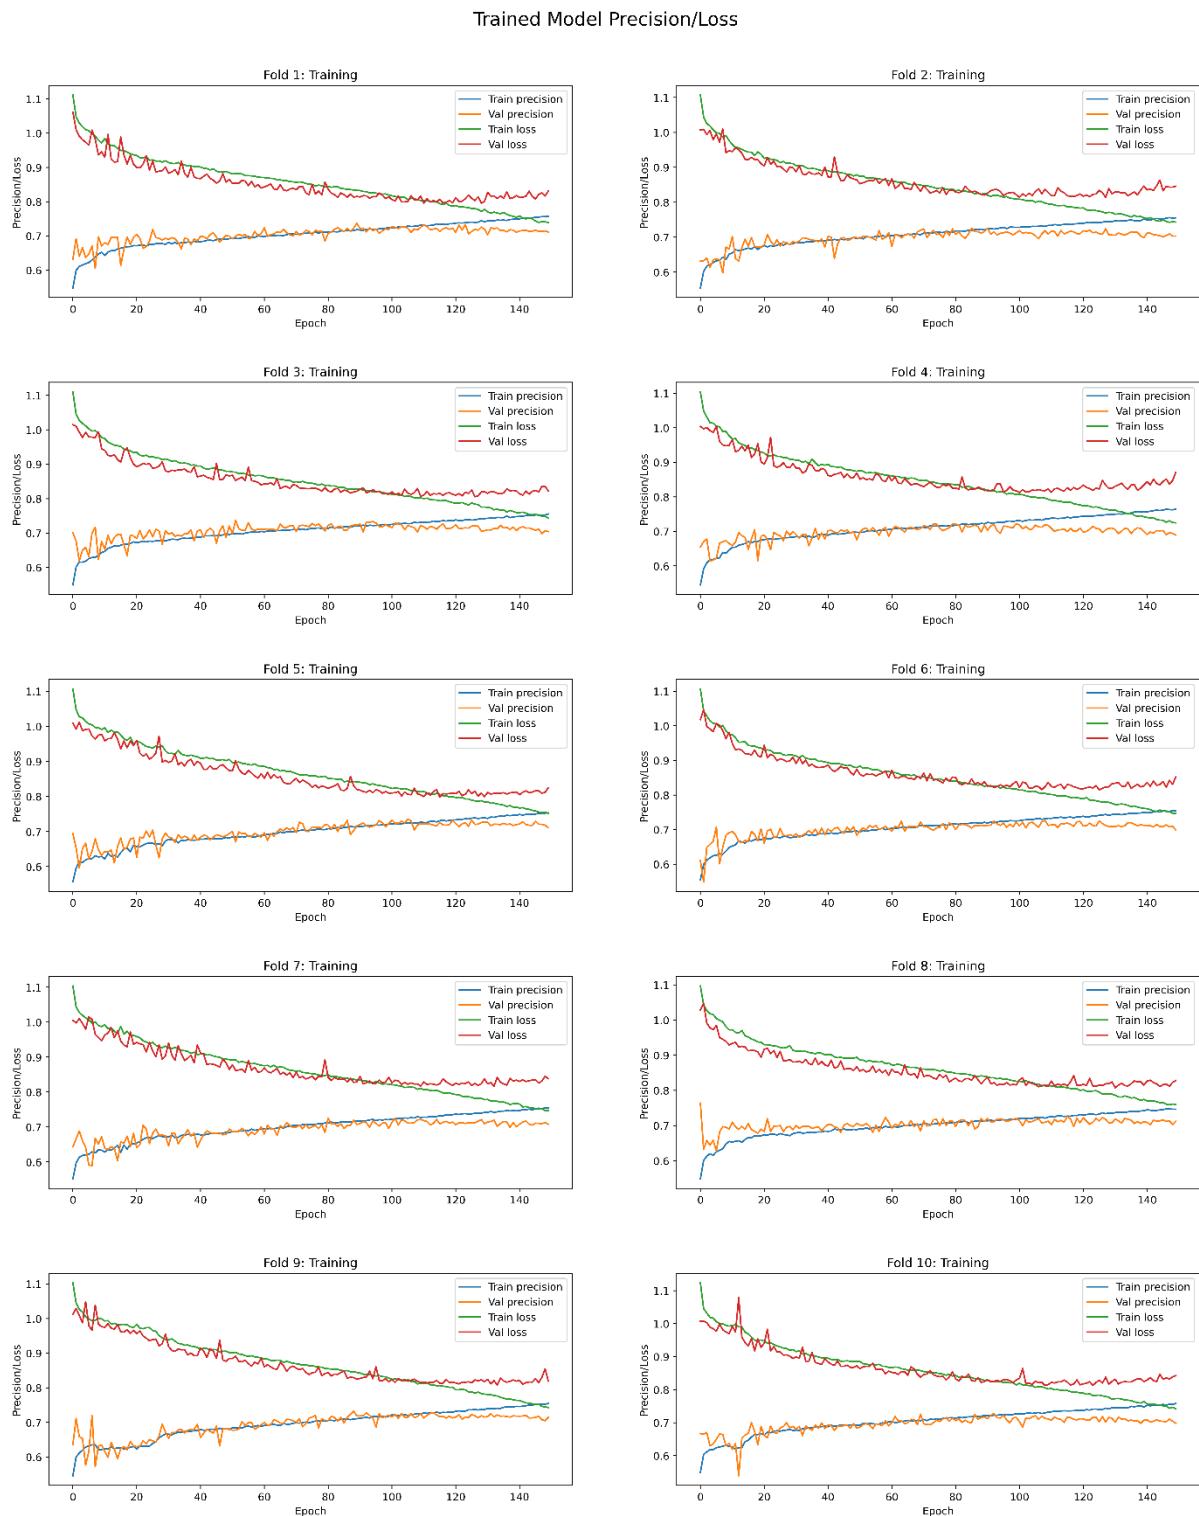
۴-۴ مرحله آموزش شبکه عصبی

بعد از تقسیم داده ها، پنج مولفه اصلی انتخاب شده از ویژگی های بدست آمده از تغییرپذیری ضربان قلب و سیگنال تنفس مشتق شده از ECG مربوط به دو زیر مجموعه آموزش و اعتبار سنジ به عنوان ورودی به شبکه پیشنهادی داده می شوند. شکل ۳-۴ و شکل ۴-۴ نمودار های مربوط به مرحله آموزش مدل برای هر یک از ۱۰ دسته را نشان می دهد.

Trained Model Recall/Loss



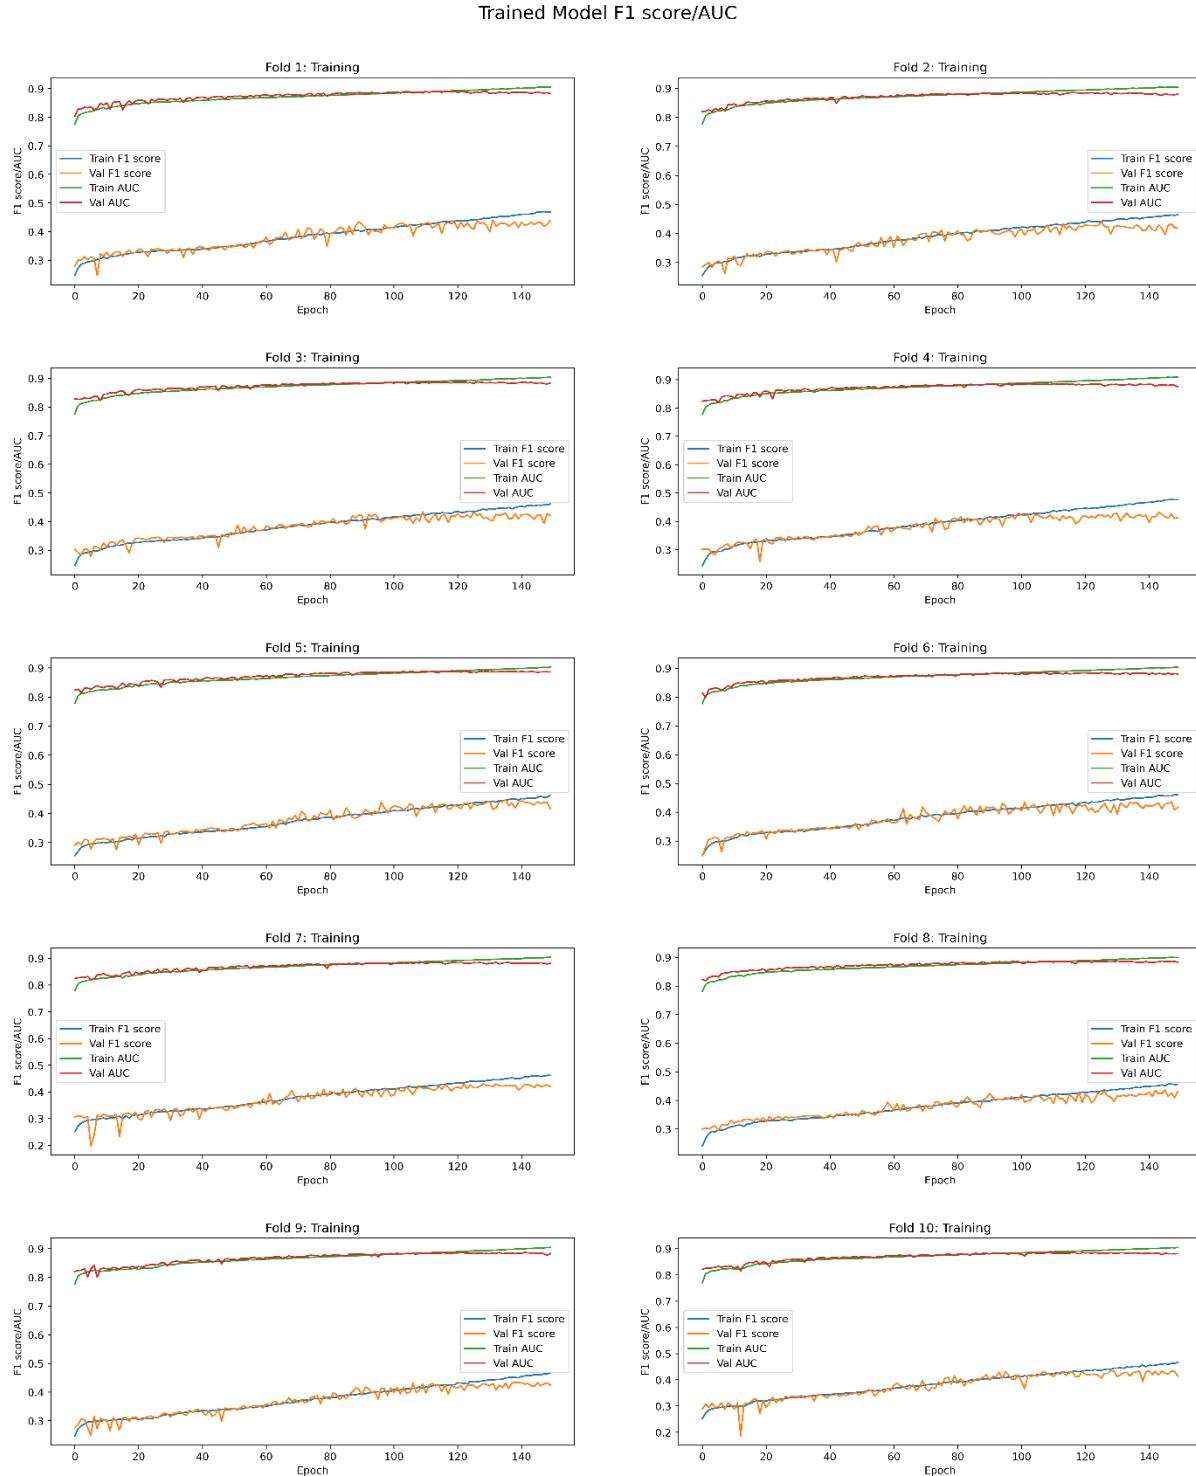
شکل ۳-۴ نمودار یادآوری و خطا آموزش و اعتبار سنجی بر حسب تکرار برای هر دسته.



شکل ۴-۴ نمودار دقت و خطا آموزش و اعتبار سنجی بر حسب تکرار برای هر دسته.

با توجه به نمودار های مربوط به آموزش و اعتبار سنجی مشاهده می شود که در تمامی دسته ها در بین بازه تکرار ۹۰ تا ۱۱۰ دو محنی آموزش و اعتبار سنجی یکدیگر را قطع کرده و از آن پس مقدار خطای اعتبار سنجی شروع به افزایش مجدد و مقدار دقت و یادآوری اعتبار سنجی شروع به کاهش کرده اند. به طور معمول نقطه تقاطع دو منحنی زمان وقوع و شروع بیش برازش بوده و برای داشتن مدل با بهترین نتیجه عملکرد بر

روی داده های دیده نشده باید آموزش در این نقطه متوقف شود. بنابراین در این مطالعه مدل نهایی انتخاب شده برای هر دسته، مدل بدست آمده با بیشترین معیار یادآوری اعتبار سنجی در زمان شروع بیش برآش بوده است. دلیل انتخاب بیشترین مقدار یادآوری به جای بیشترین مقدار دقت اعتبار سنجی، اهمیت بیشتر موارد منفی اشتباه نسبت به موارد مثبت اشتباه است. شکل ۴-۵ نیز نمودار تغییرات آموزش و اعتبار سنجی دو معیار امتیاز F1 و AUC را نشان می دهد.



شکل ۴-۵ نمودار امتیاز F1 و AUC آموزش و اعتبار سنجی بر حسب تکرار برای هر دسته.

مقادیر خطأ و χ^2 معیار معرفی شده برای مدل انتخاب شده از هر دسته در جدول ۲-۴ آورده شده اند.

جدول ۲-۴ مقداری خطأ، صحت، یادآوری، امتیاز F1 و AUC مدل منتخب در هر دسته.

دسته	آموزش						اعتبار سنجی					
	AUC	F1	امتیاز	یادآوری	صحت	خطا	AUC	F1	امتیاز	یادآوری	صحت	خطا
۱	۰,۸۸۴	۰,۴۲۳	۰,۵۸۷	۰,۷۲۵	۰,۸۱۵	۰,۸۸۸	۰,۴۲۶	۰,۶۲۲	۰,۷۳۱	۰,۸۰۳	۰,۷۳۱	۰,۸۰۳
۲	۰,۸۸۳	۰,۴۰۸	۰,۶۲۱	۰,۷۱۲	۰,۸۲۱	۰,۸۸۶	۰,۴۱۹	۰,۶۲۳	۰,۷۲۸	۰,۸۰۸	۰,۷۲۸	۰,۸۰۸
۳	۰,۸۸۵	۰,۴۱۱	۰,۶۲۷	۰,۷۱۹	۰,۸۱۲	۰,۸۸۴	۰,۴۱۴	۰,۶۱۵	۰,۷۲۴	۰,۸۱۵	۰,۷۲۴	۰,۸۱۵
۴	۰,۸۸۳	۰,۴۱۲	۰,۵۹۷	۰,۷۱۸	۰,۸۱۸	۰,۸۸۲	۰,۴۱۲	۰,۶۱۱	۰,۷۲۲	۰,۸۲۲	۰,۷۲۲	۰,۸۲۲
۵	۰,۸۸۷	۰,۴۲۵	۰,۶۱۴	۰,۷۲۲	۰,۸۰۴	۰,۸۸۵	۰,۴۱۷	۰,۶۱۷	۰,۷۲۶	۰,۸۱۳	۰,۷۲۶	۰,۸۱۳
۶	۰,۸۷۸	۰,۴۱۷	۰,۵۹۱	۰,۷۱۱	۰,۸۳۸	۰,۸۸۲	۰,۴۰۶	۰,۶۰۸	۰,۷۲۱	۰,۸۲۴	۰,۷۲۱	۰,۸۲۴
۷	۰,۸۸۲	۰,۴۱۱	۰,۵۹۷	۰,۷۱۶	۰,۸۲۴	۰,۸۸۱	۰,۴۰۸	۰,۶۱۱	۰,۲۱	۰,۸۲۶	۰,۶۱۱	۰,۸۲۶
۸	۰,۸۸۶	۰,۴۱۱	۰,۶۲۹	۰,۷۱۲	۰,۸۱۱	۰,۸۸۵	۰,۴۱۹	۰,۶۲۲	۰,۷۲۳	۰,۸۱۳	۰,۷۲۳	۰,۸۱۳
۹	۰,۸۸۳	۰,۴۱۷	۰,۵۸۵	۰,۷۲۵	۰,۸۲۰	۰,۸۸۲	۰,۴۰۸	۰,۶۰۶	۰,۷۱۲	۰,۸۲۳	۰,۷۱۲	۰,۸۲۳
۱۰	۰,۸۸۲	۰,۴۰۵	۰,۶۱۷	۰,۷۱۴	۰,۸۲۴	۰,۸۸۲	۰,۴۱۰	۰,۶۰۶	۰,۷۲۴	۰,۸۲۴	۰,۷۲۴	۰,۸۲۴
میانگین	۰,۸۸۳	۰,۴۱۴	۰,۶۰۶	۰,۷۱۷	۰,۸۱۸	۰,۸۸۳	۰,۴۱۴	۰,۶۱۴	۰,۶۷۲	۰,۸۱۷	۰,۶۷۲	۰,۸۱۷

نزدیک بودن مقادیر معیارها و خطأ بین حالت آموزش و اعتبار سنجی نشان دهنده عدم وجود بیش برازش در آموزش مدل منتخب می باشد. از طرف دیگر، نزدیک بودن این مقادیر بین دسته های مختلف اعتبار سنجی بیانگر توانایی مناسب شبکه برای آموزش الگو موجود در داده و همچنین انتخاب درست مقادیر پارامتر های مختلف شبکه (تابع بهینه سازی، تابع هزینه، سایز دسته و ...) می باشد.

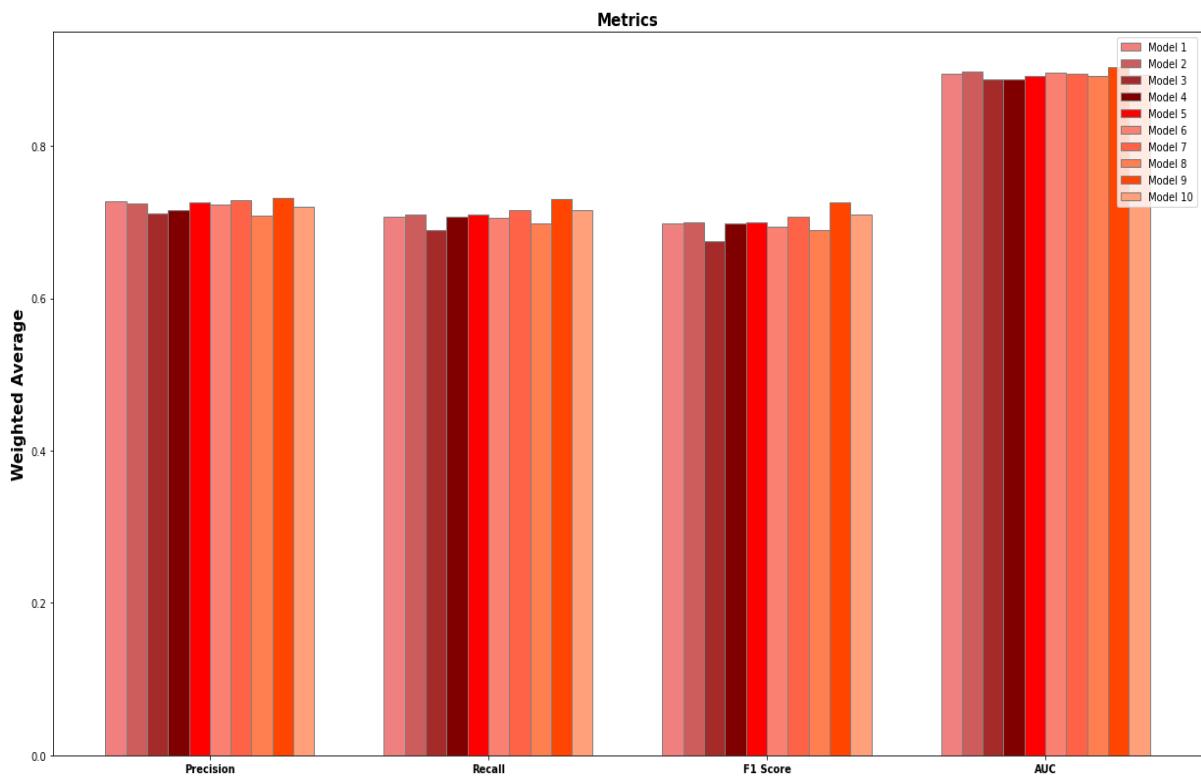
۵-۴ مرحله آزمون شبکه عصبی

در این قسمت به منظور ارزیابی عملکرد شبکه، مجموعه داده آزمون، که ۱۰٪ از کل داده ها را تشکیل می دهد و بطور کامل از مجموعه آموزش و اعتبار سنجی مجزا شده است، به مدل منتخب هر دسته داده شده و نتایج و شکل های مربوط به آن مورد بررسی قرار گرفته اند.

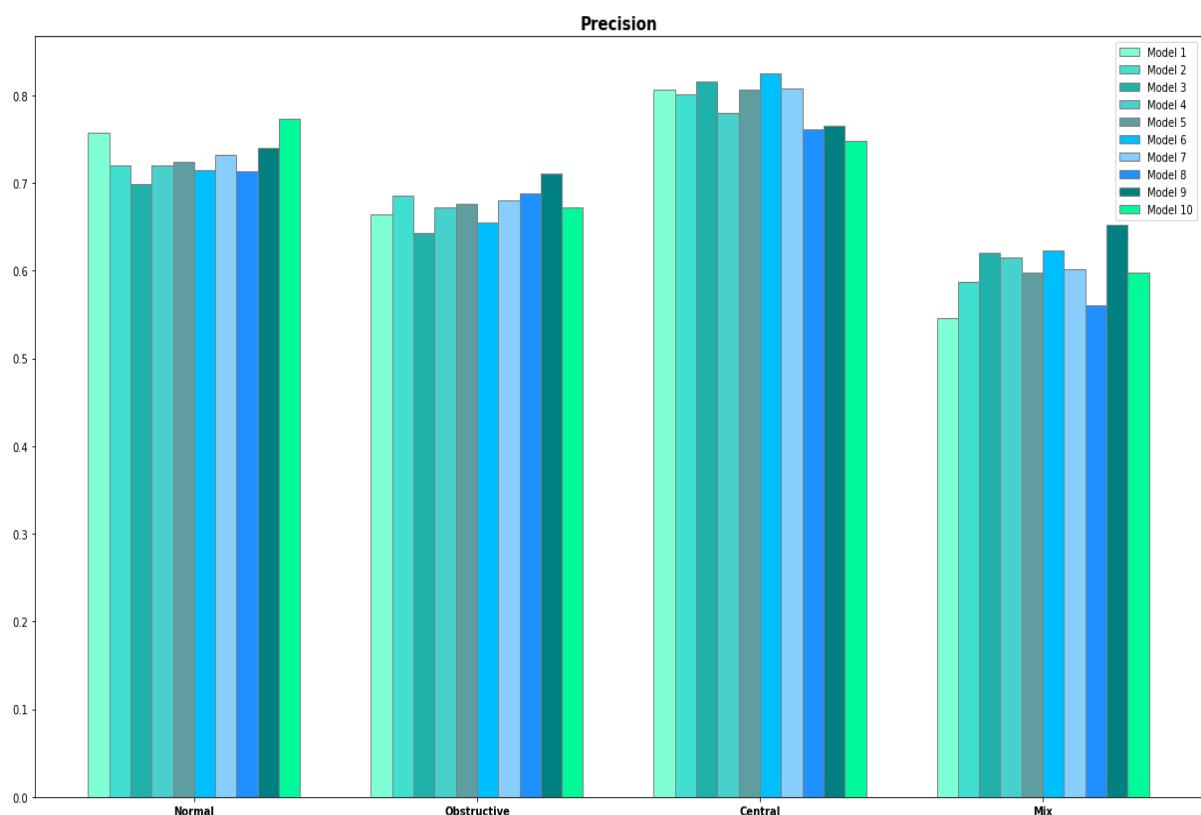
به بدليل عدم توازن بین کلاس ها برای نمایش کلی معیارها از میانگین وزنی^۱ استفاده شد. در محاسبه میانگین وزنی یک مجموعه نامتوازن، برای هر یک از کلاس ها، وزن یا ارزش معینی با توجه به سهم آن کلاس از کل داده ها در نظر گرفته می شود و سپس آن کلاس در وزن معین ضرب می گردد. نمودار میانگین وزنی چهار معیار ارزیابی استفاده شده برای هر یک از ۱۰ مدل منتخب در شکل ۴-۶ نشان داده شده است.

نمودار مستطیلی هر یک از معیارهای ارزیابی نیز به صورت مجزا و به تفکیک مدل منتخب هر دسته شکل ۴-۷، شکل ۴-۸ و شکل ۴-۹ نشان داده شده اند.

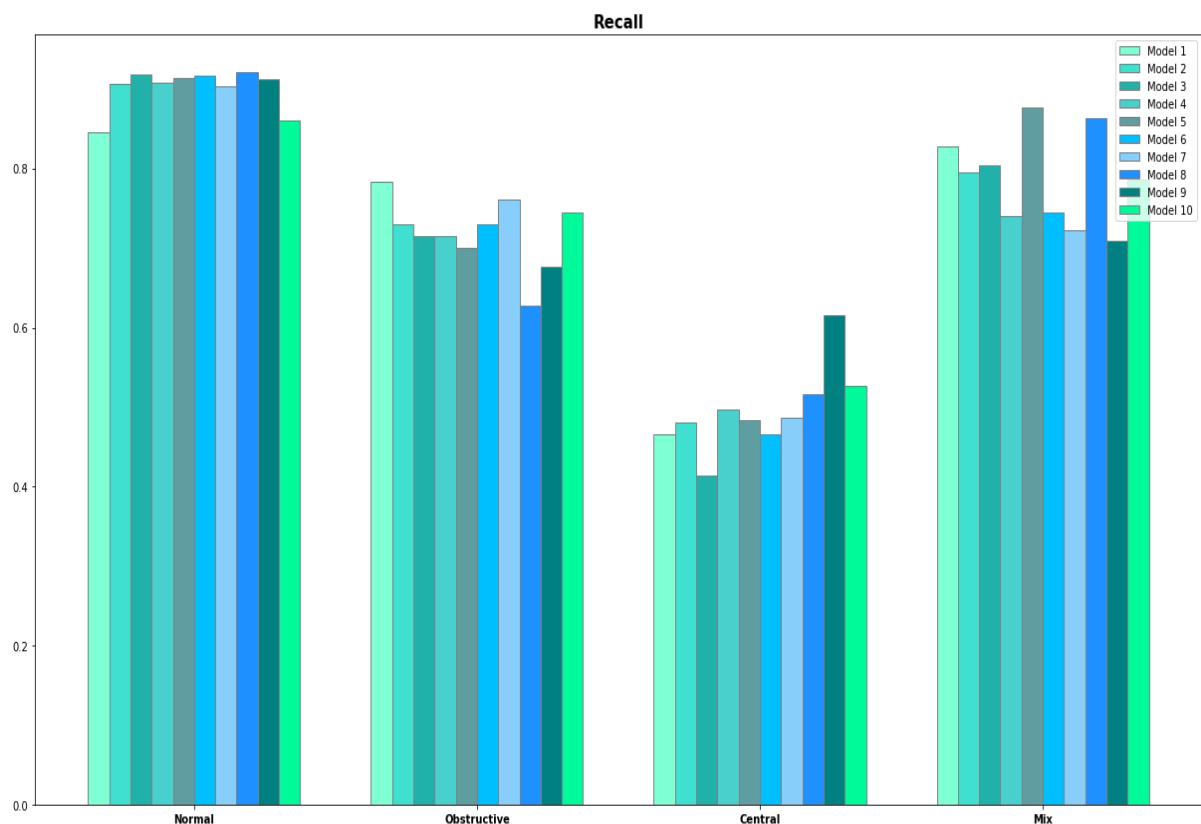
^۱ Weighted Average



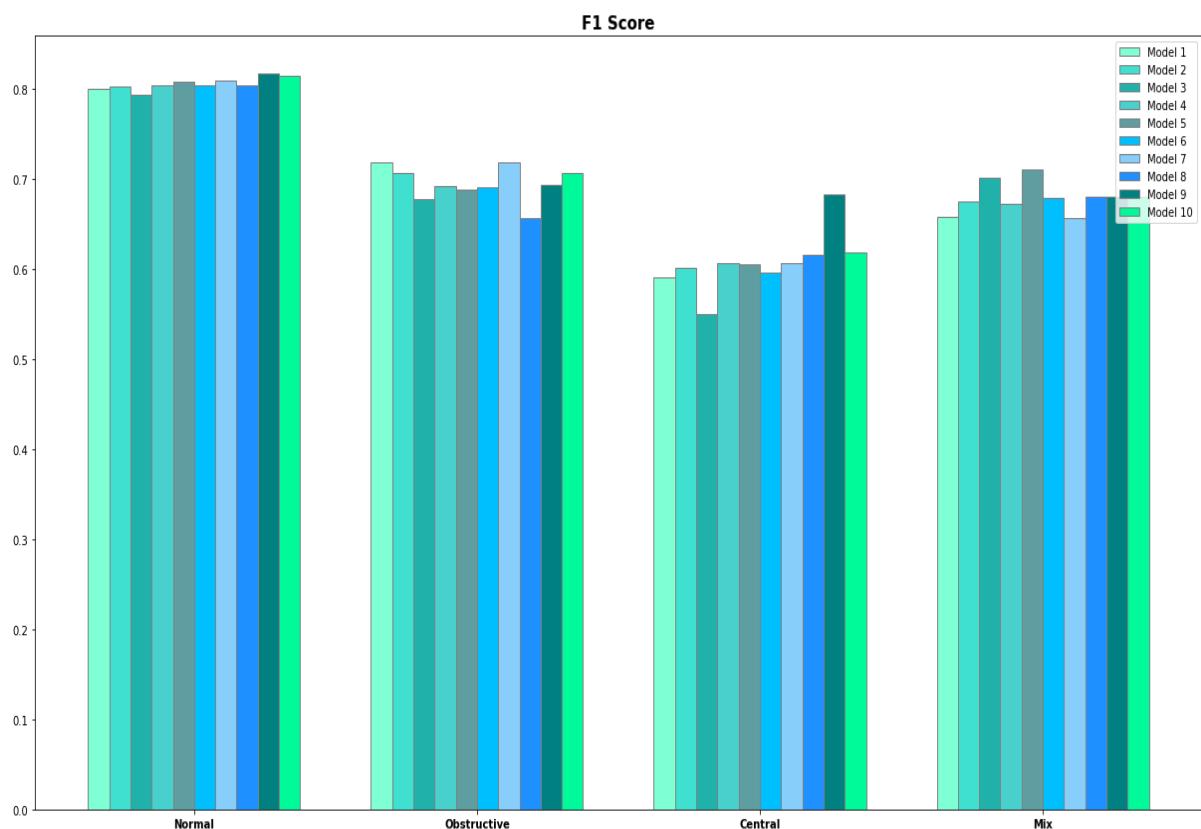
شکل ۴-۶ نمودار کلی مقادیر میانگین وزنی معیار های استفاده شده.



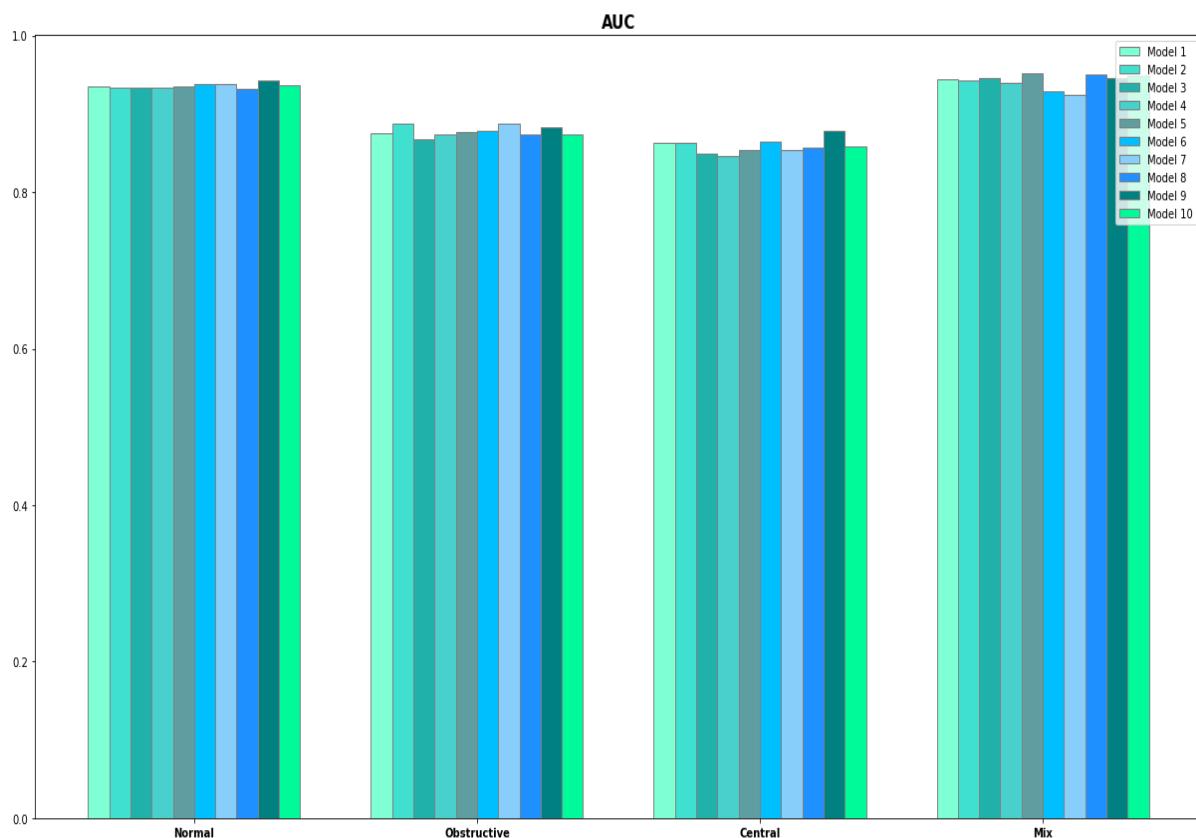
شکل ۷-۴ نمودار مقادیر معیار دقت مربوط به هر کلاس.



شکل ۸-۴ نمودار مقادیر معیار یادآوری مربوط به هر کلاس.



شکل ۹-۴ نمودار مقادیر معیار امتیاز F1 مربوط به هر کلاس.



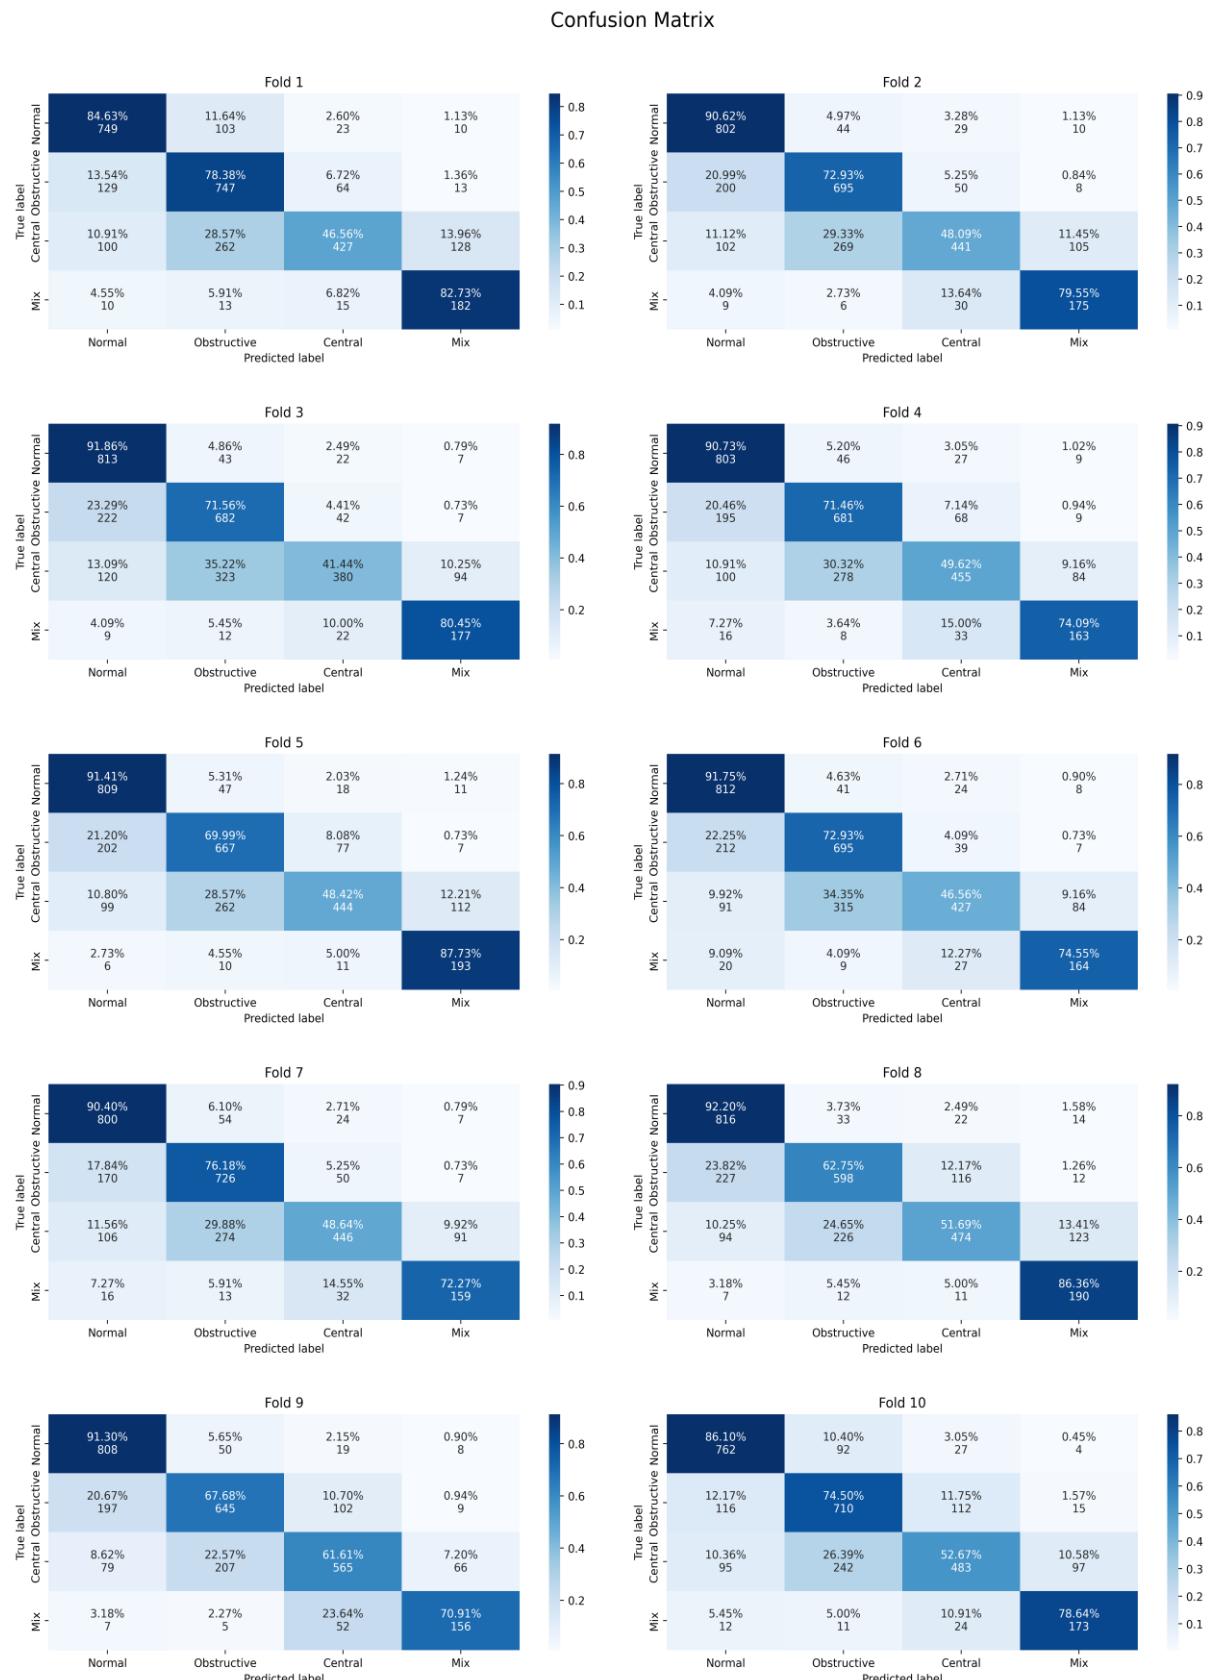
شکل ۱۰-۴ نمودار مقادیر معیار AUC مربوط به هر کلاس.

با توجه به نمودار مقادیر مختلف استفاده شده مشاهده می شود که تفاوت ناچیزی بین دسته های مختلف وجود دارد که این موضوع بیانگر توانایی کافی برای یادگیری مناسب داده و عمومیت^۱ مدل های آموزش دیده دارد. همچنین با مشاهده مقادیر معیار ها به تفکیک برای هر کلاس مشاهده می شود که اکثر مدل های آموزش دیده در تشخیص کلاس آپنه مرکزی نسبت به سایر کلاس ها با مشکل رو برو بوده اند اما به طور کلی در تشخیص و تمایز بین کلاس های مختلف عملکرد خوبی را داشتند.

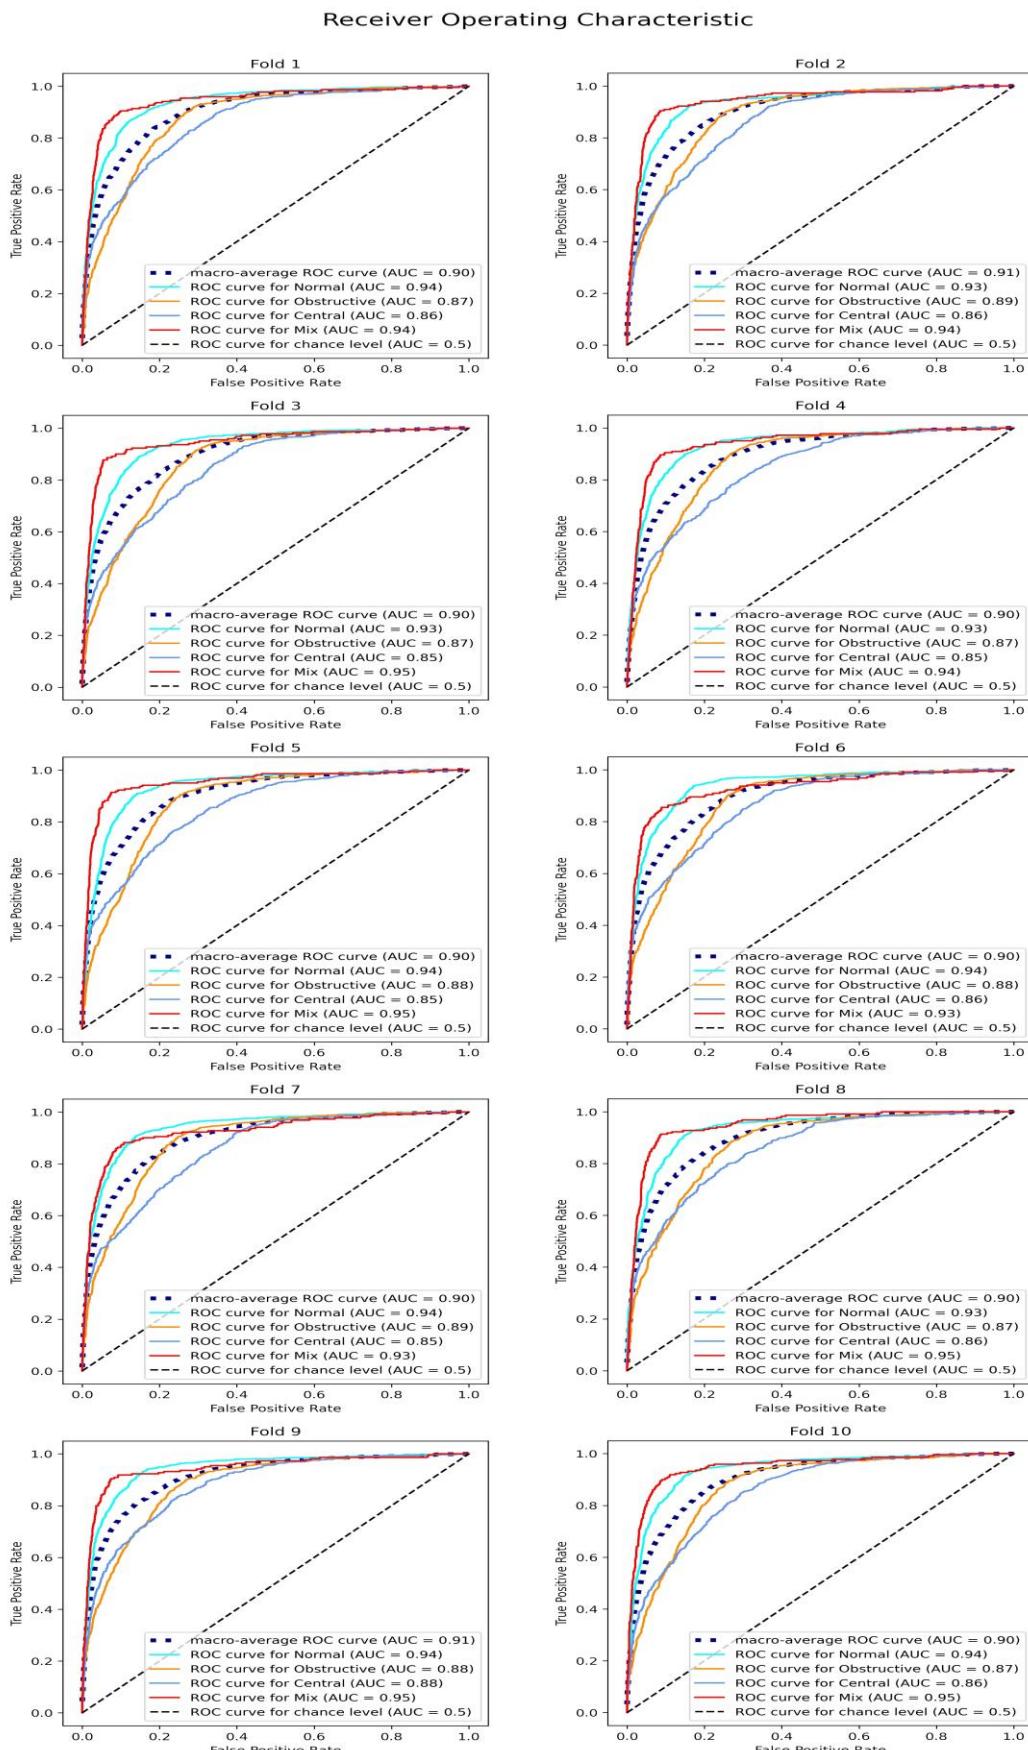
شکل ۱۱-۴ ماتریس درهم ریختگی مدل منتخب مربوط به هر دسته را نشان می دهد. درصد های موجود در هر سطر از ماتریس درهم ریختگی بیانگر درصد داده های کلاس مورد نظر است که به عنوان کلاس مربوط به هر ستون طبقه بندی شده اند.

شکل ۱۲-۴ نیز نمودار های ROC مربوط به هر کلاس و میانگین کلی آن ها را به ازای هر دسته نمایش می دهد.

^۱ Generalize



شكل ١١-٤ مatriس درهم ریختگی مربوط به هر دسته.



شکل ۱۲-۴ نمودار ROC مربوط به هر دسته.

مشاهده می شود که درایه های روی قطر ماتریس درهم ریختگی دارای بیشترین مقدار نسبت به سایر درایه های سطر هستند که این موضوع نشان دهنده طبقه بندی مناسب هر کلاس است. همچنین نمودار های ROC مربوط به هر کلاس در هر دسته نیز به حالت ایده آل (گوشه بالا چپ) نزدیک بوده و میانگین مساحت زیر نمودار تمامی دسته ها با مقدار حداقل ۰,۹ نشان دهنده عملکرد خوب مدل آموزش دیده در طبقه بندی است.

۶-۴ بحث

با توجه به مقادیر معیار های ارزیابی بررسی شده، مدل پیشنهادی به طور مناسب آموزش دیده و با توجه به تفاوت اندک بین نتایج آموزش و آزمون دارای کمترین میزان بیش برازش ممکن بود. همچنین مشاهده شد که مدل آموزش دیده عملکرد خوبی در شناسایی و جداسازی چهار کلاس بر روی داده های آزمون نشان داد. مدل آموزش دیده بهترین عملکرد را به ترتیب در جداسازی کلاس نرمال، آپنه انسدادی، آپنه مختلط و آپنه مرکزی داشت. با وجود عدم تعادل بین تعداد داده های موجود بین کلاس ها و کمترین تعداد داده در کلاس مختلط، عملکرد مدل در تفکیک کلاس مختلط مشابه کلاس انسدادی و حتی در برخی دسته ها بهتر از کلاس انسدادی بود.

با توجه به اینکه طبقه بندی چهار کلاسه انواع آپنه تنها با استفاده از سیگنال ECG برای اولین بار در این پژوهش انجام گرفته است، مطالعه دیگری با شرایط مشابه برای مقایسه دقیق عملکرد مدل پیشنهادی این پژوهش با سایر کارهای انجام شده وجود ندارد. با این وجود، مقادیر معیار های مورد استفاده در این پژوهش به تفکیک هر کلاس برای مقایسه این مطالعه با تعدادی از مطالعات اخیر انجام شده در این زمینه در جدول آورده شده اند.

جدول ۳-۴ مقایسه نتایج پژوهش با سایر مطالعات انجام شده

[۲۸]	[۲۴]	[۲۳]	مدل پیشنهادی	مطالعه
۳	۳	۳	۴	تعداد کلاس طبقه بند
EEG	تلاش تنفسی	EEG	ECG	سیگنال
SVM	شبکه عصبی	RF	شبکه عصبی	طبقه بند
-	-	%۹۵,۲۴	%۷۴,۰۶	نرمال
%۸۸,۲۴	%۵۰,۰۰	%۸۰,۴۳	%۷۱,۱۱	انسدادی
%۸۴,۸۱	%۳۵,۵۹	%۸۴,۸۵	%۷۶,۵۵	مرکزی
%۷۸,۶۸	%۴۸,۶۵	-	%۶۵,۲۷	مختلط
۸۳,۹۱%	%۴۴,۶۵	%۸۸,۹۹	%۷۳,۲۳	میانگین
-	-	-	%۹۱,۳۰	نرمال
%۸۰,۹۰	%۲۱,۱۵	-	%۶۷,۶۸	انسدادی
%۸۹,۹۵	%۳۸,۵۵	-	%۶۱,۶۱	مرکزی
%۸۰,۴۷	%۴۴,۷۱	-	%۷۰,۹۱	مختلط
%۸۳,۷۷	%۳۴,۶۱	%۸۱	%۷۳,۰۷	میانگین
-	-	-	۰,۸۱۷۸	نرمال
۰,۸۴۴۱	۰,۲۹۷۳	-	۰,۶۹۳۵	انسدادی
۰,۸۷۳۰	۰,۴۲۰۰	-	۰,۶۸۲۸	مرکزی
۰,۷۹۵۶	۰,۴۶۱۵	-	۰,۶۷۹۷	مختلط
۰,۸۳۸۳	۰,۳۹۲۹	۰,۸۷	۰,۷۲۶۲	میانگین

دقت

یادآوری

امتیاز F1

فصل ۵ - جمع بندی و پیشنهادها

۱-۱ جمع بندی

اختلالات مربوط به خواب و به طور خاص آپنه خواب که در این پژوهش به آن پرداخته شد می توانند به شدت کیفیت زندگی فرد را کاهش داده و مشکلات جسمی و روانی دیگری را نیز باعث شوند. در نتیجه شناسایی به موقع و دقیق این اختلالات از اهمیت بالایی برخوردار است. از طرفی، به دلیل منشا مختلف هریک از آپنه های خواب انسدادی، مرکزی و مختلط و همچنین روش های درمانی متفاوت، تمایز نوع آپنه از مراحل ضروری در شروع روند درمان به حساب می آید.

امروزه با پیشرفت روزافرون تکنولوژی به ویژه در زمینه سلامت، سیگنال قلبی ECG برخلاف سایر بیو سیگنال های مورد استفاده در تشخیص آپنه خواب نظیر EEG و سیگنال اشباع اکسیژن، به راحتی حتی با استفاده از ساعت های هوشمند قابل ثبت بوده و علاوه بر سادگی اخذ، اطلاعات ارزشمندی برای کاربرد های بررسی وضعیت قلب و سایر مکانیزم های تاثیر گذار بر قلب را دارا می باشد.

در این پژوهش تلاش شد تا مدلی مبتنی بر شبکه عصبی پیشنهاد و آموزش داده شود که بتواند تنها با استفاده از سیگنال ECG، حالت تنفس طبیعی و انواع آپنه خواب را شناسایی و جداسازی کند. یکی از مواردی که باعث تمایز این پژوهش از سایر مطالعه های پیشین می شود، انجام طبقه بندی چهار کلاسه تنها با استفاده از سیگنال ECG برای اولین بار در پژوهش حاضر است. در هیچ یک از مطالعات آپنه انجام شده نه تنها طبقه بندی همزمان ۴ کلاسه بین حالت نرمال و سه نوع مختلف آپنه خواب انجام نشده است، بلکه هیچ مطالعه با طبقه بندی سه کلاسه نیز تنها با استفاده از سیگنال ECG صورت نگرفته است.

با وجود اینکه به نسبت افزایش تعداد کلاس های پیش بینی طبقه بند، پیچیدگی مدل و آموزش آن افزایش می یابد و رسیدن به عملکرد مناسب دشوارتر می شود، روش ارائه شده و مدل پیشنهادی این پژوهش توانست به عملکرد مناسب و نتایج آماری خوبی با صحت ۰,۷۲۱، یادآوری ۰,۷۰۹، امتیاز F1 ۰,۶۹۹ و AUC ۰,۸۹۴ بررسد.

۲-۲ پیشنهادها

تعداد رویداد های آپنه مختلط موجود در پایگاه های داده نسبت به انواع دیگر آپنه خواب بسیار کمتر است و با توجه به پیچیدگی بیشتر طبقه بندی ۴ کلاسه و تعداد بالای پارامتر های شبکه عصبی عمیق، در صورت متعادل کردن داده های مربوط به هر کلاس، شبکه نمی تواند به خوبی آموزش دیده و دچار بیش برازش می

شود. در صورت در دسترس بودن مدل های طبقه بند آپنه از پیش آموزش دیده بر روی سیگنال ECG، این امکان وجود دارد که با استفاده از روش یادگیری انتقالی و متعادل سازی داده ها بتوان نتایج بدست آمده را بهبود بخشد.

همچنین، به دلیل وجود ارتباط بین احتمال رخداد انواع مختلف آپنه و برخی شاخص های فردی نظیر وزن، قد، فشار خون، سن و جنسیت، در صورت امکان پذیر بودن جمع آوری این اطلاعات و استفاده از آن ها در به عنوان دیگر ویژگی های ورودی شبکه عصبی، این احتمال وجود دارد که با بهره گیری از این اطلاعات بتوان دقیق تشخیص و طبقه بندی مدل نهایی را افزایش داد.

علاوه بر این، در صورت آموزش مدلی که در کنار طبقه بندی انواع آپنه خواب، قادر به شناسایی و طبقه بندی انواع هیپوپنه باشد، می توان علاوه بر تشخیص انواع آپنه و هیپوپنه، شدت آپنه-هیپوپنه را که شاخص مهمی برای بررسی وضعیت ناهنجاری و درمان فرد است، نیز تخمین زد.

فهرست مرجع ها

- [1] Xu, S., Faust, O., Seoni, S., Chakraborty, S., Barua, P. D., Loh, H. W., Elphick, H., Molinari, F., & Acharya, U. R. (2022). A review of automated sleep disorder detection. *Computers in Biology and Medicine*, 150, 106100. <https://doi.org/10.1016/j.compbioemed.2022.106100>
- [2] Murarka, S., Wadichar, A., Bhurane, A., Sharma, M., & Acharya, U. R. (2022). Automated classification of cyclic alternating pattern sleep phases in healthy and sleep-disordered subjects using convolutional neural network. *Computers in Biology and Medicine*, 146, 105594. <https://doi.org/10.1016/j.compbioemed.2022.105594>
- [3] Yüzer, A. H., Sümbül, H., Nour, M., & Polat, K. (2020). A different sleep apnea classification system with neural network based on the acceleration signals. *Applied Acoustics*, 163, 107225. <https://doi.org/10.1016/j.apacoust.2020.107225>
- [4] Shirani, A. (2021). The international classification of sleep disorders, third edition's classification of central disorders of hypersomnolence. *Reference Module in Neuroscience and Biobehavioral Psychology*. <https://doi.org/10.1016/B978-0-12-822963-7.00068-2>
- [5] Zarei, A., & Asl, B. M. (2020). Automatic classification of apnea and normal subjects using new features extracted from HRV and ECG-derived respiration signals. *Biomedical Signal Processing and Control*, 59, 101927. <https://doi.org/10.1016/j.bspc.2020.101927>
- [6] Sheta A, Turabieh H, Thaher T, Too J, Mafarja M, Hossain MS, Surani SR. Diagnosis of Obstructive Sleep Apnea from ECG Signals Using Machine Learning and Deep Learning Classifiers. *Applied Sciences*. 2021; 11(14):6622. <https://doi.org/10.3390/app11146622>
- [7] Mostafa SS, Mendonça F, G. Ravelo-García A, Morgado-Dias F. A Systematic Review of Detecting Sleep Apnea Using Deep Learning. *Sensors*. 2019; 19(22):4934. <https://doi.org/10.3390/s19224934>
- [8] Erdenebayar, U., Kim, Y. J., Park, J., Joo, E. Y., & Lee, K. (2019). Deep learning approaches for automatic detection of sleep apnea events from an electrocardiogram. *Computer Methods and Programs in Biomedicine*, 180, 105001. <https://doi.org/10.1016/j.cmpb.2019.105001>
- [9] Kumar Tyagi, P., & Agrawal, D. (2023). Automatic detection of sleep apnea from single-lead ECG signal using enhanced-deep belief network model. *Biomedical Signal Processing and Control*, 80, 104401. <https://doi.org/10.1016/j.bspc.2022.104401>
- [10] Salari, N., Hosseiniyan-Far, A., Mohammadi, M., Ghasemi, H., Khazaie, H., Daneshkhah, A., & Ahmadi, A. (2022). Detection of sleep apnea using Machine learning algorithms based on ECG Signals: A comprehensive systematic review. *Expert Systems with Applications*, 187, 115950. <https://doi.org/10.1016/j.eswa.2021.115950>
- [11] Tripathy, R. (2018). Application of intrinsic band function technique for automated detection of sleep apnea using HRV and EDR signals. *Biocybernetics and Biomedical Engineering*, 38(1), 136-144. <https://doi.org/10.1016/j.bbe.2017.11.003>

- [12] Setiawan F, Lin C-W. A Deep Learning Framework for Automatic Sleep Apnea Classification Based on Empirical Mode Decomposition Derived from Single-Lead Electrocardiogram. *Life*. 2022; 12(10):1509. <https://doi.org/10.3390/life12101509>
- [13] Drzazga, J., & Cyganek, B. (2021). An LSTM Network for Apnea and Hypopnea Episodes Detection in Respiratory Signals. *Sensors (Basel, Switzerland)*, 21(17), 5858. <https://doi.org/10.3390/s21175858>
- [14] W.W. Flemons, D. Buysse, S. Redline, A. Oack, K. Strohl, J. Wheatley, T. Young, N. Douglas, P. Levy, W. McNicolas, J. Fleetham, D. White, W. SchmidtNowarra, D. Car ley, J. Romaniuk, Sleep_related breathing disorders in adults: Recommendations for syndrome definition and measurement techniques in clinical research, *Sleep*. 22 (1999) 667–689. <https://doi.org/10.1093/sleep/22.5.667>
- [15] Eguchi, K., Yabuuchi, T., Nambu, M. et al. Investigation on factors related to poor CPAP adherence using machine learning: a pilot study. *Sci Rep* 12, 19563 (2022). <https://doi.org/10.1038/s41598-022-21932-8>
- [16] TİMÜŞ, OĞUZ HAN and BOLAT, EMİNE DOĞRU (2017) "k-NN-based classification of sleep apnea types using ECG," *Turkish Journal of Electrical Engineering and Computer Sciences*: Vol. 25: No. 4, Article 38. <https://doi.org/10.3906/elk-1511-99>
Available at: <https://journals.tubitak.gov.tr/elektrik/vol25/iss4/38>
- [17] Urtnasan E, Park JU, Joo EY, Lee KJ. Automated Detection of Obstructive Sleep Apnea Events from a Single-Lead Electrocardiogram Using a Convolutional Neural Network. *J Med Syst.* 2018 Apr 23;42(6):104. doi: 10.1007/s10916-018-0963-0. PMID: 29687192.
- [18] Bello, Saheed Ademola and Alqasemi, Umar, Computer Aided Detection of Obstructive Sleep Apnea from EEG Signals (June 28, 2021). Available at SSRN: <https://ssrn.com/abstract=3890660> or <http://dx.doi.org/10.2139/ssrn.3890660>
- [19] Sharma, M., Kumbhani, D., Tiwari, J., Kumar, T. S., & Acharya, U. R. (2022). Automated detection of obstructive sleep apnea in more than 8000 subjects using frequency optimized orthogonal wavelet filter bank with respiratory and oximetry signals. *Computers in Biology and Medicine*, 144, 105364. <https://doi.org/10.1016/j.compbiomed.2022.105364>
- [20] Gubbi, Jayavarhana et al. "Classification of sleep apnea types using wavelet packet analysis of short-term ECG signals." *Journal of clinical monitoring and computing* vol. 26,1 (2012): 1-11. doi:10.1007/s10877-011-9323-z
- [21] Akbarian, S., Ghahjaverestan, N. M., Yadollahi, A., & Taati, B. (2020). Distinguishing Obstructive Versus Central Apneas in Infrared Video of Sleep Using Deep Learning: Validation Study. *Journal of Medical Internet Research*, 22(5). <https://doi.org/10.2196/17252>
- [22] M. A. Prucnal and A. G. Polak, "Analysis of Features Extracted from EEG Epochs by Discrete Wavelet Decomposition and Hilbert Transform for Sleep Apnea Detection," 2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), 2018, pp. 287-290, doi: 10.1109/EMBC.2018.8512201.
- [23] Zhao, Xiaoyun et al. "Classification of sleep apnea based on EEG sub-band signal characteristics." *Scientific reports* vol. 11,1 5824. 12 Mar. 2021, doi:10.1038/s41598-021-85138-0

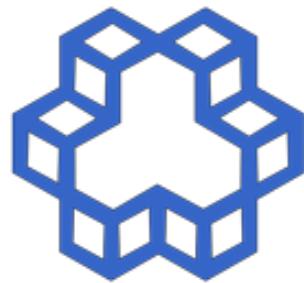
- [24] Fontenla-Romero, Oscar et al. "A new method for sleep apnea classification using wavelets and feedforward neural networks." *Artificial intelligence in medicine* vol. 34,1 (2005): 65-76. doi: 10.1016/j.artmed.2004.07.014
- [25] Emin Tagluk, M., et al. "Classification of sleep apnea by using wavelet transform and artificial neural networks." *Expert Systems with Applications*, vol. 37, no. 2, 2010, pp. 1600-1607, <https://doi.org/10.1016/j.eswa.2009.06.049>. Accessed 29 Dec. 2022.
- [26] Guijarro-Berdiñas, Bertha, et al. "A mixture of experts for classifying sleep apneas." *Expert Systems with Applications*, vol. 39, no. 8, 2012, pp. 7084-7092, <https://doi.org/10.1016/j.eswa.2012.01.037>. Accessed 29 Dec. 2022.
- [27] B. L. Koley and D. Dey, "Classification of sleep apnea using cross wavelet transform," 2013 IEEE 1st International Conference on Condition Assessment Techniques in Electrical Systems (CATCON), 2013, pp. 275-280, doi: 10.1109/CATCON.2013.6737512.
- [28] Alimardani, M., & de Moor, G. (2021). Automatic Classification of Sleep Apnea Type and Severity using EEG Signals. In *SCITEPRESS* (pp. 121-128)
- [29] Goldberger, A., Amaral, L., Glass, L., Hausdorff, J., Ivanov, P. C., Mark, R., ... & Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation* [Online]. 101 (23), pp. e215–e220.
- [30] Lee, Harlin, et al. "A large collection of real-world pediatric sleep studies." *Scientific Data*, vol. 9, 2022, <https://doi.org/10.1038/s41597-022-01545-6>. Accessed 1 Jan. 2023.
- [31] Łęski, Jacek, and Henzel, Norbert. "ECG baseline wander and powerline interference reduction using nonlinear filter bank." *Signal Processing*, vol. 85, no. 4, 2005, pp. 781-793, <https://doi.org/10.1016/j.sigpro.2004.12.001>. Accessed 1 Jan. 2023.
- [32] A. S. Berson and H. V. Pipberger, "Errors caused by inadequacy of low-frequency response of electrocardiographs," in Proceedings of the Digest of 6th International Conference on Biomedical Engineering, Society of Med Electr Biomed Eng, Ed., pp. 13–14, Okomura Printing Co, Tokyo, Japan, August 1965.
- [33] Alickovic E., Subasi A.: 'Effect of multiscale PCA de-noising in ECG beat classification for diagnosis of cardiovascular diseases', *Circuits Syst. Signal Process.*, 2015, 34, (2), pp. 513–533 (doi: 10.1007/s00034-014-9864-8)
- [34] Gadaleta, M., & Giorgio, A. (2012). A method for ventricular late potentials detection using time-frequency representation and wavelet denoising. *ISRN Cardiology*, 2012, 258769. <https://doi.org/10.5402/2012/258769>
- [35] Kligfield, Paul et al. "Recommendations for the standardization and interpretation of the electrocardiogram: part I: The electrocardiogram and its technology: a scientific statement from the American Heart Association Electrocardiography and Arrhythmias Committee, Council on Clinical Cardiology; the American College of Cardiology Foundation; and the Heart Rhythm Society: endorsed by the International Society for Computerized Electrocardiology." *Circulation* vol. 115,10 (2007): 1306-24. doi:10.1161/CIRCULATIONAHA.106.180200
- [36] Gasparini F, Grossi A, Giltri M, Bandini S. Personalized PPG Normalization Based on Subject Heartbeat in Resting State Condition. *Signals*. 2022; 3(2):249-265. <https://doi.org/10.3390/signals3020016>

- [37] McCraty R, Shaffer F. Heart rate variability: new perspectives on physiological mechanisms, assessment of self-regulatory capacity, and health risk. *Glob Adv Health Med* (2015) 4:46–61. 10.7453/gahmj.2014.073
- [38] Bolanos M, Nazeran H, Haltiwanger E. Comparison of heart rate variability signal features derived from electrocardiography and photoplethysmography in healthy individuals. In: Annual International Conference of the IEEE Engineering in Medicine and Biology - Proceedings. 2006. pp. 4289-4294
- [39] Pan J, Tompkins JW. A real-time QRS detection algorithm. *IEEE Transactions on Biomedical Engineering*. 1985; 32:230-236. DOI: 10.1109/TBME.1985.325532
- [40] Malarvili BK, Aimie S, Pranshul S. In: Ismail I, editor. Introduction to ECG Signal Processing using MATLAB. 1st ed. Johor Bahru, Malaysia: Penerbit UTM Press; 2018
- [41] S. Sarkar, S. Bhattacherjee and S. Pal, "Extraction of respiration signal from ECG for respiratory rate estimation," Michael Faraday IET International Summit 2015, 2015, pp. 336-340, doi: 10.1049/cp.2015.1654.
- [42] Guo, Han Wen et al. "Heart Rate Variability Signal Features for Emotion Recognition by Using Principal Component Analysis and Support Vectors Machine." *2016 IEEE 16th International Conference on Bioinformatics and Bioengineering (BIBE)* (2016): 274-277.
- [43] X. Zeng and T. R. Martinez, "Distribution-balanced stratified cross validation for accuracy estimation," *J. Experim. Theor. Artif. Intell.*, vol. 12, no. 1, pp. 1–12, 2000.
- [44] T. -Y. Lin, P. Goyal, R. Girshick, K. He and P. Dollár, "Focal Loss for Dense Object Detection," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 2, pp. 318-327, 1 Feb. 2020, doi: 10.1109/TPAMI.2018.2858826
- [45] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [46] M. Brennan, M. Palaniswami and P. Kamen, "Do existing measures of Poincare plot geometry reflect nonlinear features of heart rate variability?" in *IEEE Transactions on Biomedical Engineering*, vol. 48, no. 11, pp. 1342-1347, Nov. 2001, doi: 10.1109/10.959330.
- [47] Toichi M, Sugiura T, Murai T, Sengoku A. A new method of assessing cardiac autonomic function and its comparison with spectral analysis and coefficient of variation of R-R interval. *J Auton Nerv Syst*. 1997;62(1-2):79-84. doi:10.1016/s0165-1838(96)00112-9
- [48] Huikuri HV, Mäkikallio TH, Perkiomäki J. Measurement of heart rate variability by methods based on nonlinear dynamics. *J Electrocardiol*. 2003;36 Suppl:95-99. doi: 10.1016/j.jelectrocard.2003.09.021
- [49] Bravi, A., Longtin, A. & Seely, A.J. Review and classification of variability analysis techniques with clinical applications. *BioMed Eng OnLine* **10**, 90 (2011). <https://doi.org/10.1186/1475-925X-10-90>

Abstract

Sufficient and high-quality sleep is one of the essential things to maintain human health. In case of lack of sleep, the body's circadian rhythm is disrupted, and the risk of health problems such as cardiovascular diseases, cognitive disorders, memory loss, obesity, and stroke increases. Sleep apnea is one of the most common sleep disorders worldwide that must be recognized and investigated from different aspects. Sleep apnea is generally divided into three categories: obstructive sleep apnea (OSA), central sleep apnea (CSA), and mixed sleep apnea (MSA). Considering the difference in the treatment of different types of apnea, the distinction between the three types of apnea has a critical value, and diagnosis in the early stages can increase the quality of a person's life and reduce treatment costs. In this research, for the first time, an attempt was made to develop a method for automatically classifying obstructive apnea, central apnea, mixed apnea, and normal breathing events using only the electrocardiogram signal. For this purpose, three databases, including MIT-BIH, NCHSDB, and CFS, were used. First, to remove noise, the electrocardiogram (ECG) signals were filtered using a Band-pass Butterworth filter and standardized to zero mean and unit standard deviation. Then, these signals are divided into 30 seconds segments, and the heart rate variability (HRV) and ECG-derived respiration (EDR) features are calculated using the ECG signal for each segment. The principal component analysis method was used to reduce the computational cost, and the first five principal components with the highest variance were selected. Finally, a recurrent neural network with two separate inputs and long short-term memory units was used to classify different apnea types. The five chosen principal components and the ECG-derived respiration were given as inputs to the neural network. Also, due to the unbalanced data in each class, 10-fold cross-validation was used in the training stage of the network. The selected model of each fold showed similar and good statistical results. The proposed model of this research was able to achieve a precision of 0.721, recall of 0.709, F1 score of 0.699, and AUC of 0.894. The final results of this study show that the ECG signal alone has the necessary and sufficient potential to identify and classify types of sleep apnea.

Keywords: obstructive apnea, central apnea, deep learning, signal, electrocardiogram, deep neural network, recurrent neural network.



K. N. Toosi
University of Technology

Faculty of Electrical Engineering

**A Thesis Submitted in Partial Fulfillment of the Requirements
For the Degree of Master of Science (M.Sc.)
In Biomedical Engineering-Bioelectronics**

**Sleep Apnea Classification using Deep Learning
Algorithm**

By:
Mina Moazami Goudarzi

Supervisor:
Maryam Mohebbi

Winter 2023